

# NinaXander：共有潜在表現による異種モデル族の凍結言語モデル合成の成立条件と限界

樹神 宇徳<sup>1</sup> 林 俊一郎<sup>1</sup> 椋木 大地<sup>2</sup> 星野 哲也<sup>2</sup> 片桐 孝洋<sup>2</sup>

**概要：**NinaXander は、異なる事前学習系統の凍結層を共有潜在アダプタで接続して得られる合成言語モデル群の名称である。本研究では、再帰型の RWKV-4-Raven-7B と Transformer 型の Tulu-Pythia-6.9b を対象とし、個々の合成モデルを Pythia→RWKV ( $L=4$ ) のように系統横断経路と切替層で指定する。対応層間の表現が比較的軽量なアダプタで接続可能か、またその接続がモデルの言語性能にどのような影響を与えるか検証する。主な結果は四つである。第一に、同一トークナイザ・幅・層数・学習領域という条件下で、中心化潜在相関  $\rho_{ctr}=0.901$  を得た。行対応をシャッフルすると整合は消失する一方、生表現の CKA は同一層で最大にならず、WikiText への領域シフトでも性能が大きく低下する。したがって、本結果が示すのは一般的な意味空間ではなく、好条件下で学習可能なトークン対応表現である。第二に、四経路の読み出しは RWKV 自己再構成 / RWKV→Pythia / Pythia 自己再構成 / Pythia→RWKV の順に 0.695/0.559/0.711/0.590 であり、本手法は圧縮工程を用いていないが再構成誤差が残る。第三に、最良直接アフィン写像は RWKV→Pythia / Pythia→RWKV で 0.487/0.535 に達する一方、学習済みアダプタ出力の 13.4%/12.0% は、それぞれの最良アフィン適合では説明されずに残る。同一アダプタの非線形枝を無効化すると両横断読み出しは負の  $R^2$  まで崩れる。第四に、単一境界で合成したキメラは構文的に妥当な生成と多肢選択の遂行が可能だが、強い親モデルには届かない。Pythia→RWKV は深い境界の正答率が同層の RWKV→Pythia より 8.9–18.8 点高く、Pythia 前段→RWKV 後段の Pythia→RWKV ( $L=4$ ) は Transformer を 5 層だけ残して KV を 84.4% 削減しつつ、ARC-Easy 62.2%, SciQ 69.2% を保つ。ただし RWKV を有意には上回らず、この  $L=4$  の選択も同じ二つのテスト集合上の事後選択である。また領域外 WikiText への汎化には大きな課題が残る。

## NinaXander: Conditions and Limits of Composing Frozen Language Models Across Model Families via a Shared Latent Representation

### 1. はじめに

言語モデルの事前学習には膨大な計算を要するが、その成果は特定のアーキテクチャに固定された重みとしてしか残らない。推論時の特性を変えたいとき、たとえば文脈長に比例して増える KV キャッシュを減らしたいときには、再帰型の層と Transformer の層を混ぜたハイブリッドモデルを新たに事前学習するか、既存モデルの注意機構などの系列混合層を軽量な方式へ置き換えて変換または蒸留することになる。いずれもモデル本体の重みを新たに学習する方法であり、学習済みのブロックを凍結した部品として組

み替えているわけではない。

既存の手法はこの制約を共有している。一から学習するハイブリッドはモデル全体を事前学習し、変換・蒸留の系統は系列混合層の重みを学習し直す。凍結したモデル同士を接合する研究も現れているが、接合できるのは同一系統の Transformer どうしに限られる。重み空間でモデルを統合するマージ系の手法は、重みが互換であることを前提とする。完成済みの凍結チェックポイントを、系統をまたいだまま部品として組み替える経路は空いたままである。

本研究が検証するのはこの構想である。独立に学習された異種モデルの中間表現を相互に変換できれば、既存モデルは凍結された再利用可能な部品になる。アダプタを一度学習すれば多数の接続位置が同時に使えるようになり、以後は精度と推論メモリのトレードオフを、構成ごとの再学

<sup>1</sup> 名古屋大学大学院情報学研究科  
Graduate School of Informatics, Nagoya University  
<sup>2</sup> 名古屋大学情報基盤センター  
Information Technology Center, Nagoya University

習なしに**事後**に探索できる。実際に本研究は4個の切替位置を両方向に用い、単一のアダプタから8通りの構成を取り出して非支配集合を求めている。ただしアダプタ自体の学習には相応の計算を要する。学習構成は§3.6に示す。本研究では、新たなハイブリッドの事前学習や蒸留に対する総学習費用の優位を検証していない。

その第一歩として、本研究は、異なる系統の凍結ブロックを単一の学習済みアダプタで接続する**キメラモデル**群 NinaXander<sup>\*1</sup>を構築する。個々のモデルは、§3で定義する系統横断経路と切替層の組で指定する。RWKVは線形注意の計算を再帰形式でも実行できるモデル族であり、Tulu-Pythiaは指示チューニング済みのTransformerである。本研究では、同一トークナイザ・同一幅・同一層数という好条件下のRWKV-4-Raven-7BとTulu-Pythia-6.9bを対象に、三つの問いを検証する。系統をまたぐ合成は成立するか。接続位置によって機能とKV量はどうか変わるか。何が接続を律速するか。

結果は競争力のある新モデルではない。強い親モデルはどの構成でも超えない。示されるのは、凍結資産の事後的な再構成が部分的に可能であること、そして整合の不完全さ・再構成誤差・領域シフトがその障害になることである。具体的な利得は、Transformerを5層だけ残してKVを84.4%削減しつつ多肢選択の正答率の一部を保つ構成が存在することである。本研究の貢献は四つある。共通モードを除いた整合測定、RWKV自己再構成／RWKV→Pythia／Pythia自己再構成／Pythia→RWKVの四経路を比較する対照実験、RWKV→Pythia／Pythia→RWKVの両方でアダプタの非線形性を測る同一画像内の介入実験、および単一境界で合成したRWKV→Pythia／Pythia→RWKVキメラモデル群における精度・メモリ・領域汎化と経路非対称性の実測である。

## 2. 背景と関連研究

### 2.1 残差ストリームと合成の形式

自己回帰言語モデルは、位置ごとの表現を残差ストリームとして層で更新する。幅 $d$ のモデルのブロック $\ell$ は $h^{(\ell+1)} = h^{(\ell)} + f_\ell(h^{(\ell)})$ の形をとり、 $f_\ell$ が系列混合とチャネル混合を担う。深さ境界 $L$ での合成とは、一方のモデルでブロック0から $L$ まで走らせて得た $h^{(L+1)}$ を、他方のモデルのブロック $L+1$ の入力として与えることをいう。幅と層数が一致していても、 $h^{(L+1)}$ はそれぞれの学習が定めた座標系にあり、一方の値をそのまま渡しても後段の重みが期待する分布とは一致しない。合成の可否は、したがって二つの系統の残差が相互に変換可能かという問いに帰着する。

<sup>\*1</sup> NinaXanderは『鋼の錬金術師』のキメラに由来する。合成は成立するが合成元には及ばない、という対応による。

### 2.2 推論費用の非対称性

二つの系統は推論時の費用の増え方が異なる。softmax注意を持つ層は過去のトークンすべてのkeyとvalueを保持するため、文脈長 $T$ に対して $O(T)$ のキャッシュを要する。線形注意や等価な再帰形式で実行できる層は固定サイズの状態のみを持ち越すため $O(1)$ である。この非対称性が、本研究で合成が意味を持つ理由である。前段と後段のどちらかに再帰型を置くかで残るTransformer層数が変わり、保持すべきキャッシュ量も変わるからである。

### 2.3 残差の尺度

残差の尺度は層ごとに異なり、系統間でも揃わない。したがって層をまたいで残差を比較するにも、境界で受け渡すにも、層ごとに推定した統計で標準化が必要がある。本研究がアダプタの入出力に層別の標準化と逆標準化を挟むのはこのためである。具体的な処理は§3で述べる。

### 2.4 モデル・スティッチング

凍結した2モデルの層を学習可能な接合層でつなぐ手法は、表現の**等価性**を測るためにLencとVedaldi [1]が導入した。彼らは線形の接合層で一方の下層と他方の上層を接いだ「Franken-CNN」を元の課題損失で評価した。対象には、ImageNetとMIT Placesという異なる学習データを用いたネットワークの組だけでなく、AlexNet、VGG-16、ResNet-50という異なるアーキテクチャの組も含まれる。Bansalら [2]は表現比較のプロープとして再訪し、同一アーキテクチャ間で乱数種・学習量・幅を変え、教師あり学習と自己教師あり学習という異なる目的関数の間でも接合する一方、異種アーキテクチャ間の接合は難点として残した。Csiszáríkら [3]は単一のアフィン接合層によって二つの学習済みネットワークの中間表現を対応付け、その一致を表現空間上の類似度だけでなく、接合後ネットワークのタスク性能という機能的観点から評価する枠組みを提案した。さらに、既存の表現類似度指標がタスク性能を必ずしも反映しないことを示した。本研究が整合と復号可能性を分けて評価するのは、この立場に沿う。いずれも視覚モデルであり、本研究はRNNとTransformerという異なる**系統**を各層で1度だけ翻訳する共有潜在で接合する点で異なる。

### 2.5 凍結LLMの合成

近年は凍結したLLMどうしを学習可能な接続で合成する研究が続いている。StitchLLM [4]は規模の異なるTransformerのブロックをstitching層で接いでserving時に経路を選び、BTS [5]は同一シードから分岐した凍結専門家群と凍結シードの間で、Experts-into-HubとHub-into-Expertsのstitch層を数層おきに交互に挿入して隠れ状態を**双方向**に交換する。CALM [6]は凍結した2つ

の Transformer の中間表現を cross-attention で融合し、Manticore [7] は Transformer と Mamba のブロック列を射影付きで**並列に実行**し、学習された凸結合で混ぜたハイブリッドを end-to-end に微調整する。このとき埋め込みと LM ヘッドは新規に初期化される。

凍結モデル間で活性そのものを翻訳する研究も現れている。Moschella ら [8] は固定アンカーへの相対表現によって独立に学習された潜在空間を隔てる変換を吸収し、翻訳器を学習せずに接合できることを示した。Maiorca ら [9] は少数の意味的対応から二つの潜在空間の間の写像を閉形式で推定する。表 1 のアフィン対照は、こうした低容量の直接写像に対応する基準である。

Model Alignment Search [10] は凍結した再帰型ネットワークと凍結 Transformer の間で活性を双方向に写像するが、表現の類似度を測る手法であって合成モデルを構築しない。Chen ら [11] は凍結した 2 つの言語モデルの残差ストリームを単一層で双方向にアフィン写像し、一方の前段と他方の後段をつないだ合成モデルの次トークン交差エントロピーまで評価する。ただし対象は同一系統・同一トークナイザの Transformer 対に限られ、著者自身が異種系統での検証を今後の課題として挙げている。

プレプリントの Bicameral Model [12] は凍結した 2 つの言語モデルを双方向の翻訳網で結合するが、各モデルが自身の全段を実行したまま並列に走る。同じくプレプリントの GoldFinch [13] は RWKV-6 の上に Transformer を積む単一境界の構成で KV キャッシュを 756-2550 倍圧縮するが、事前学習済みの親を組み合わせるのではなくスクラッチから学習する。Oozeer ら [14] は異なる系統の凍結 LLM の間で活性の写像を学習し、安全性介入やステアリングベクトルを転送する。アフィン対照を併記する点も含めて本研究に近いが、単一層での転送に留まり、モデルを合成して走らせることはしない。本研究のアフィン対照は対応残差を教師として直接適合するため、zero-shot の相対表現より強い条件にある。

以上の先行研究は、両側が Transformer であるか、Manticore のように合成体を微調整するか、事前学習済みの親を一つしか持たない。単一境界・双方向・親凍結という接合機構それ自体は、Chen ら [11] が同一系統・同一トークナイザの Transformer 対で既に確立しており、本研究はその機構の新規性を主張しない。本研究が扱うのは、彼らが未解決として残した**異種系統**の場合である。線形注意の再帰モデルと Transformer の間でも同じ接合が成立するかを検証する。我々の知る限り、この二系統を両親と LM ヘッドを凍結したまま単一境界で合成し、動作する生成器として評価した研究はない。あわせて、その合成が Transformer の KV キャッシュに与える削減量を報告する。

## 2.6 表現類似度

中心化カーネル整合、すなわち CKA [15] や SVCCA / PWCCA [16], [17] はネットワーク間の表現類似度を測る標準的な道具である。本研究はこれらを補助指標として全層対応を調べる一方、主眼を**再構成を介した機能的な接合**に置く。系統をまたぐ表現の普遍性については、Wang ら [18] が Transformer と Mamba の間で疎自己符号器の特徴と誘導回路が概ね類似することを報告しており、先行する証拠を与える。ただし、彼らの対象は Mamba であって RWKV ではない。

## 2.7 モデルマージ・知識統合

重み空間でモデルを統合する model soups [19], TIES [20], 進化的マージ [21] は、**同一または互換な重み**を前提とする。出力分布を融合する FuseLLM [22] は重みの互換を要しないが、語彙間のトークン整列と対象モデルの継続学習を必要とする。本研究は重みを一切マージせず**活性化空間**を翻訳して凍結ブロックを組み替える点で相補的である。

## 3. 手法

### 3.1 対象モデル

本研究では、指示追従モデルである RWKV-4-Raven-7B と Tulu-Pythia-6.9b を用いる。以下では前者をモデル A、後者をモデル B と書く。いずれも 32 ブロック、隠れ幅  $d=4096$  であり、GPT-NeoX-20B トークナイザを共有する。したがって、同じ入力を同じトークン列に変換でき、各位置の残差をそのまま対応付けられる。層数が同じなので第  $j$  ブロックどうしを組にでき、隠れ幅が同じなので境界でベクトルの次元も揃う。この三条件は接続を容易にするため意図的に選んだものであり、トークナイザ、層数、隠れ幅が異なるモデル対は本研究の対象外である。

両者の基盤モデルは、EleutherAI が構築した英語コーパス The Pile [23] で事前学習されている。The Pile は、学術文書、ウェブ文書、書籍、ソースコードなど 22 種類のデータを集めた 825 GiB の言語モデル用コーパスである。基盤コーパスが共通する一方、その後の指示チューニングに用いたデータとプロンプト形式は異なる。

RWKV [24] は、softmax 内積注意の代わりに WKV 作用素による線形時間の系列混合を用い、同じ計算を並列形式と再帰形式のどちらでも実行できる。本研究で用いる Raven は、RWKV プロジェクトが開発し BlinkDL が公開した RWKV-4 の指示追従版である。元の RWKV-4-Pile-7B に対し、一般的な指示データである Alpaca, Guanaco, GPT4All, コード課題を集めた Code-Alpaca, 会話データを集めた ShareGPT などで追加学習している。Code-Alpaca は、コード生成、編集、最適化を中心とする約 20,000 件の指示と応答からなる合成データである [25]。ShareGPT

は、利用者が共有した ChatGPT との複数ターンの会話を集めたデータである [26]。本研究では BlinkDL が配布した Raven 7B を Hugging Face 形式へ変換し、fp16 で再保存して用いる<sup>\*2</sup>。実際に使用した重みは 7,392,649,216 パラメータであり、32 ブロック、隠れ幅 4096、内部幅 16384 を持つ。変換後の設定では context\_length が 1024 である。これは一回の順伝播で扱う最大系列長として定義された値であり、再帰形式では文脈長に依存しない大きさの状態を引き継げる<sup>\*3</sup>。ただし、変換元の .pth ファイル名とリビジョンは保存されていないため、上流チェックポイントが掲げた学習時のコンテキスト長は特定できない。再帰形式の性質も、学習時または設定上の長さを超えた言語性能を保証しない。

Pythia [27] は EleutherAI が研究用に開発した GPT-NeoX 系 Transformer 群である。Tulu-Pythia-6.9b は、その Pythia-6.9b を Allen Institute for AI が Tulu の混合指示データで全パラメータ微調整したモデルである [28]。混合データには一般課題と推論課題を集めた FLAN V2, Chain-of-Thought, Dolly, OpenAssistant 1, GPT4-Alpaca に加え、Code-Alpaca と ShareGPT が含まれる<sup>\*4</sup>。本研究で使用した重みは 6,856,040,448 パラメータであり、32 ブロック、隠れ幅 4096、32 個の注意ヘッドを持つ。設定上の最大位置数は 2048 である<sup>\*5</sup>。両モデルの指示チューニング用データを配布元の記載に基づいて比較すると、共通する名称は Code-Alpaca と ShareGPT である。したがって、二つのモデルは完全に独立なデータで学習されたわけではない。一方、アーキテクチャと指示データの大部分は異なる。

### 3.2 残差ペアと記号

本稿でいう残差は誤差ではなく、各ブロックから次のブロックへ渡される隠れベクトルを指す。モデルを接続するとは、このベクトルを一方のモデルの座標系から他方の座標系へ変換して渡すことである。モデル  $M \in \{A, B\}$  の第  $j$  ブロック直後に、トークン位置  $t$  で得られる未標準化の残差を  $r_M^j[t] \in \mathbb{R}^{4096}$  と書く。ブロック番号は  $j \in \{0, \dots, 31\}$  であり、 $t$  は入力中のトークン位置である。同じトークン列を両モデルへ与え、 $r_A^j[t]$  と  $r_B^j[t]$  を一組の学習例とする。

残差の尺度はモデルと層によって異なるため、各層の学習データから次元別の平均と標準偏差を求める。 $\text{std}_M^j$  はこ

の統計量で残差を標準化する操作、 $\text{unstd}_M^j$  は元の尺度へ戻す逆操作を表す。標準化後の残差を  $x_M^j[t] = \text{std}_M^j(r_M^j[t])$  と書く。以下の学習式では読みやすさのため層番号  $j$  とトークン位置  $t$  を省略し、 $x_A, x_B$  と表す。

### 3.3 共有潜在アダプタ

アダプタは、各モデルに一つの符号器と一つの復号器を持つ。 $E_A, E_B$  は標準化残差を共有潜在空間へ移す符号器、 $D_A, D_B$  は共有潜在から各モデルの標準化残差を復元する復号器である。下付きの  $A, B$  は、その画像が属するモデルを示す。 $z_A, z_B \in \mathbb{R}^{d_z}$  は、同じトークン位置から得た二つの潜在ベクトルであり、潜在幅は  $d_z=4096$  である。潜在整合誤差を二つの自己再構成誤差に対してどの程度重視するかを定めるハイパーパラメータを  $\lambda \geq 0$  とし、学習目的を次式で定める。

$$\begin{aligned} z_A &= \text{LN}(E_A(x_A)), & z_B &= \text{LN}(E_B(x_B)), \\ \mathcal{L} &= \|D_A(z_A + \xi_A) - x_A\|^2 + \|D_B(z_B + \xi_B) - x_B\|^2 \\ &\quad + \lambda \|z_A - z_B\|^2. \end{aligned} \quad (1)$$

式 (1) の第 1 項と第 2 項は、それぞれ  $A$  と  $B$  の残差を元のモデルへ復元する自己再構成誤差である。第 3 項は、同じトークン位置から得た  $z_A$  と  $z_B$  を近づける潜在整合誤差である。 $\lambda$  が大きいほど、学習損失  $\mathcal{L}$  における第 3 項の相対的な重みが大きくなる。各ノルムは、全トークンと全次元にわたる平均二乗誤差として計算する。LN は学習可能な倍率と切片を持たない LayerNorm である。 $\xi_A, \xi_B \sim \mathcal{N}(0, \sigma^2 I)$  は復号前だけに加える、平均 0 の独立なガウスノイズである。 $\sigma > 0$  はノイズの標準偏差を定めるハイパーパラメータ、 $I$  は  $d_z \times d_z$  の単位行列である。本研究のアダプタ学習では  $\lambda=1, \sigma=0.4$  に固定する。 $\lambda=1$  は三つの平均二乗誤差項に同じ係数 1 を与える設定であり、学習中の各項の実測値が等しいことを意味しない。層・経路・課題ごとの調整や、両値のアブレーションは行っていない。

この損失には、 $A$  の残差から  $B$  の残差を直接当てる項も、その逆を当てる項も含まれない。横断写像では、 $A$  の符号器で得た  $z_A$  を  $B$  の復号器へ渡し、 $D_B(z_A)$  を得る。逆方向では  $D_A(z_B)$  を用いる。これらが成立するには、第 3 項によって  $z_A$  と  $z_B$  が同じ座標系に揃う必要がある。対応する残差ペアを用いているため、横断目標を直接与えていないことを「教師なし学習」とは呼ばない。

各符号器と復号器は同じ構造を持ち、線形射影、 $b$  個の pre-norm 残差ブロック、出力への線形射影からなる。報告する構成は潜在幅 4096、残差ブロック数  $b=1$ 、内部幅 4096 である。各残差ブロックの第 2 行列はゼロ初期化するため、初期状態の各ブロックは恒等写像となり、 $E$  と  $D$  は線形写像から学習を始める。ただし両者の間には非アフィン LN が入るので、横断写像全体は初期状態でも線形

<sup>\*2</sup> BlinkDL, RWKV-4 Raven モデルリポジトリ, <https://huggingface.co/BlinkDL/rwkv-4-raven>.

<sup>\*3</sup> Hugging Face Transformers, RWKV ドキュメント, [https://huggingface.co/docs/transformers/model\\_doc/rwkv](https://huggingface.co/docs/transformers/model_doc/rwkv).

<sup>\*4</sup> Allen Institute for AI, open-instruct-pythia-6.9b-tulu model card, <https://huggingface.co/allenai/open-instruct-pythia-6.9b-tulu>.

<sup>\*5</sup> 公開モデルの設定ファイルは <https://huggingface.co/allenai/open-instruct-pythia-6.9b-tulu/blob/main/config.json> にあり、max.position\_embeddings は 2048 とされている。




図 1 共有潜在アダプタ。実線は式 (1) で学習する自己再構成、破線は損失に直接含まれない横断読み出しを表す。 $x_A, x_B$  は層別標準化残差であり、ノイズは復号直前だけに加える。

ではない。ゼロ初期化は学習開始時だけの性質であり、学習後の写像が線形であることを意味しない。親モデルの合計 14.25B パラメータに対し、アダプタは 268.5M であり、その比率は 1.9% である。本論文でいう軽量とは、絶対的な小ささではなく、親モデルに対する相対量と低い層の深度を指す。

ノイズ  $\xi$  は、潜在が**共通モード**と呼ぶトークン非依存の定数だけで整合項を満たしてしまうことを抑えるために置く。定数はノイズを回避できない、というのが設計上の根拠である。 $\sigma=0.4$  に固定し、効果のアブレーションは行わない。

### 3.4 四経路とキメラの構成

四経路は RWKV 自己再構成, RWKV→Pythia, Pythia 自己再構成, Pythia→RWKV である。RWKV→Pythia と Pythia→RWKV は系統横断キメラ, RWKV 自己再構成 と Pythia 自己再構成 は同じ境界・アダプタを通る自系統再構成対照である。切替層  $L$  は 0 から始まる添字であり、前段親が最後に実行するブロックを表す。ブロック 0 も数えるため、前段が実行するブロック数は  $L+1$  となる。ここで  $h_A^L[t]$  は、 $A$  のブロック  $L$  がトークン位置  $t$  に出力する未標準化の残差である。 $h_B^L[t]$  も同様に  $B$  のブロック  $L$  が出力する残差を表す。これらを相手側の座標系へ翻訳した残差にはチルダを付ける。 $x_A^L[t] = \text{std}_A^L(h_A^L[t])$  と  $x_B^L[t] = \text{std}_B^L(h_B^L[t])$  を用いると、切替境界は次式となる。

$$\begin{aligned} \tilde{h}_B^L[t] &= \text{unstd}_B^L(D_B(\text{LN}(E_A(x_A^L[t])))), \\ \tilde{h}_A^L[t] &= \text{unstd}_A^L(D_A(\text{LN}(E_B(x_B^L[t])))). \end{aligned} \quad (2)$$

チルダ付きの  $\tilde{h}_B^L[t]$  は  $B$  のブロック  $L+1$  へ、 $\tilde{h}_A^L[t]$  は  $A$  のブロック  $L+1$  へ入力する。式 (2) には学習時ノイズを加えない。実行手順は、前段親のブロック 0 から  $L$  を走らせ、残差を一度だけ翻訳し、後段親のブロック  $L+1$  から 31 と言語モデルヘッドを走らせる、という三段階である。

したがって、どのキメラも合計 32 ブロックを実行し、その内訳は前段  $L+1$  ブロックと後段  $31-L$  ブロックになる。

### 3.5 評価指標

残差をどの程度復元できたかは決定係数  $R^2 = 1 - \text{SSE}/\text{SST}$  で測る。SSE は予測残差と正解残差の差の二乗和、SST は正解残差から次元ごとのトークン平均を引いた値の二乗和である。値が 1 なら完全に復元でき、0 なら各次元の平均を常に返す予測と同程度であり、負の値ならその平均予測より悪い。系統をまたぐ  $A \rightarrow B$  と  $B \rightarrow A$  に加え、同じアダプタを往復する  $A \rightarrow A$  と  $B \rightarrow B$  も測る。後二者は、系統をまたぐ前から符号化と復号だけでどれほど情報が失われるかを示す対照である。

$R^2$  は層ごとに保留トークンと全 4096 次元をプールして計算する。SST は次元ごとにトークン平均を除いた全変動なので、分散の大きい次元ほど寄与が大きい。潜在空間の一致度は中心化相関  $\rho_{\text{ctr}}$  で測る。これは、各次元からトークン平均を引いた  $z_A, z_B$  を平坦化して求める Pearson 相関である。1 に近いほど二つの潜在が同じ方向へ変化し、0 は線形相関がないことを表す。さらに、潜在のうちトークンごとに変動する成分の割合を  $f = \|z - \bar{z}\|^2 / \|z\|^2$  とする。 $\bar{z}$  は層内の次元別トークン平均であり、 $f$  は  $A$  と  $B$  で別々に求めて平均する。各指標は層ごとに算出し、32 層の単純平均を報告する。

保留集合は二つある。見出し値を与える学習時評価には 1,000 窓、すなわち 112,000 トークンを用いる。層別分析とシャッフル対照には 400 窓、すなわち 44,800 トークンを用いる。各窓の長さは 112 トークンである。評価集合が異なるため、層別分析の 32 層平均 0.561/0.592 は、見出し値 0.559/0.590 と厳密には一致しない。全層対応の適合  $R^2$  は、各層ペアに共通する 22,400 行を用い、同じ標本内で適合と評価を行う in-sample のリッジ線形プローブである。

キメラの言語機能は三通りに評価する。第一に、英語プロンプトを原文どおり与え、温度 0 の決定的 argmax で生成例を得る。生成は最大 40 新規トークンとし、EOS を出力した場合だけ早期終了する。第二に、ARC-Easy と SciQ の各選択肢について対数尤度を求め、最大の選択肢を答えとして正答率を測る。第三に、Alpaca と WikiText の次トークン交差エントロピーを測り、学習領域内と領域外の言語モデリング性能を比較する。

### 3.6 再現情報

- モデル：BlinkDL が配布した Raven 7B を Hugging Face 形式へ変換して fp16 で再保存したモデルと、fp16 の allenai/open-instruct-pythia-6.9b-tulu。ともに 32 層、 $d=4096$ 、GPT-NeoX-20B トークナイザである。変換または再保存に用いた上流リビジョンは両親とも未記録である。配布成果物の parent\_fingerprints.json には、実際に学習へ用いたローカル親モデルの SHA-256 を収録する。
- アダプタ： $d_z=d=4096$ 、内部幅 4096 の残差ブロック 1、非アフィン LN、潜在整合の重み  $\lambda=1$ 、ノイズ標準偏差  $\sigma=0.4$ 、268.5M パラメータ。残差ブロックの第 2 行列はゼロ初期化する。AdamW と  $4\times V100$  を用い、有効バッチは 4096、学習率は  $10^{-3}\rightarrow 10^{-5}$  とした。保留集合の  $A\rightarrow B$  が改善しなくなるたびに学習率を 0.5 倍した。乱数種 0 で 416,000 反復を走らせ、保留  $A\rightarrow B$  が最良となる 415,000 反復目を報告する。
- データ：残差は Alpaca 学習分割の先頭側から、112 トークンの窓を用いて取得した。独立なトークン位置は約 232k である。評価窓は文字位置 2,000,000 以降という、学習トークン数に依存しない固定オフセットから取り、両者は重ならない。標準化統計は各層の学習残差から算出し逆標準化に用いる。
- 評価：保留集合の  $R^2$  は各層で全トークン・全次元をプールして算出し、32 層の単純平均を報告する。多肢選択は各選択肢を連結した系列の対数尤度で決定する。総和スコアと、プロンプト以降のトークン数で割った平均スコアを求める。全評価集合を用い、その内訳は ARC-Easy test 2376 問と SciQ test 1000 問である。SciQ は support 文を与えない closed-book 形式で評価する。構成間の差は McNemar 検定と対応 bootstrap によるペア化検定で評価する。Pythia $\rightarrow$ RWKV の RWKV 後段では選択肢を常に batch 1 で評価する。Pythia $\rightarrow$ RWKV も RWKV $\rightarrow$ Pythia と同じ、保留  $A\rightarrow B$  で選んだ step 415,000 の配布チェックポイントに固定し、 $B\rightarrow A$  または Pythia $\rightarrow$ RWKV QA を見たチェックポイントの再選択は行わない。た

だし方向固定した二つの配布 runtime は、評価後に各経路の四境界について報告テスト平均が最大だった  $L=4$  を既定値とし、独立な deployment-selection 分割はない。

- コード・構造化データ：本研究のリポジトリは <https://github.com/Katagiri-Hoshino-Lab/NinaXander> である。実験コード、各評価の生データと論文報告値の集約表、再現手順、および本文の数値を表データと自動照合する検査を含む。
- Hugging Face 配布物：2026 年 7 月 30 日時点の推論用成果物を、次の三つの model repository へ保存した。
  - 共有アダプタ：<https://huggingface.co/Katagiri-Hoshino-Lab/ninaxander-raven7b-tulu69-adapter>
  - 既定値を  $L=4$  とする Pythia $\rightarrow$ RWKV：<https://huggingface.co/Katagiri-Hoshino-Lab/ninaxander-tulu69-to-raven7b-best>
  - 既定値を  $L=4$  とする RWKV $\rightarrow$ Pythia：<https://huggingface.co/Katagiri-Hoshino-Lab/ninaxander-raven7b-to-tulu69-best>各 repository は英語・日本語・簡体字中国語の model card と notice, SafeTensors, SHA-256 manifest を含む。配布 License はいずれも、より制約の強い親である Tulu-Pythia に合わせた AI2 AI Model License であり、用途を非商用研究に限定する。各 NOTICE に親モデルの帰属を記載する。

## 4. 結果

以下では、まず対応層間の表現が揃うかを調べ、その表現から各モデルの残差をどこまで復元できるかを測る。次にアダプタの非線形性を切り分け、最後に合成したキメラの生成、正答率、推論メモリを評価する。

### 4.1 対応層間には学習可能な共通表現がある

同じトークナイザ、層数、隠れ幅を持つ二つの 7B 指示追従モデルを、Alpaca [29] の指示形式テキストで整合させると、残差ブロック 1 個のアダプタが未学習の文章における中心化潜在相関  $\rho_{ctr}=0.901$  に達する。本論文では、中心化相関 0.901 に加え、各復号器が自系統の残差を  $A\rightarrow A$  0.70,  $B\rightarrow B$  0.71 で再構成できることを共通表現の根拠とする。また、各横断課題へ直接あてはめた最良の線形写像だけでも  $A\rightarrow B$  0.487,  $B\rightarrow A$  0.535 に届く。この線形対照だけでも相当な値に達するため、観測された予測可能性の大部分は深い非線形写像の表現力だけでは説明

できない。ただし、同一層ペアが内在的に特別なわけではない。図 2 のように、アダプタを介さない生の残差どうしを全  $32 \times 32$  層で比べると、線形 CKA は総じて弱く、対角平均は 0.05、非対角平均は 0.03 となる。 $A$  の層  $j$  が  $B$  の層  $j$  に最も似るのは 32 行中 2 行にすぎない。最類似の列は層 0 が 14 行、最終層が 12 行を占める。直接の線形回帰しやすさでも同一層は特別ではない。同じ全層ペアへ層別の線形写像をあてはめると、適合  $R^2$  は 0.62–0.94 とほぼ全ペアで高い。平均を比べると、適合  $R^2$  は対角平均 0.87 対 非対角平均 0.84 であり、同番号層が最良となるのは 32 行中 3 行にすぎない。ゆえに  $\rho_{\text{ctr}} = 0.901$  は**選んだ同一層ペア上で学習して回復した整合**であって、層番号どうしに固有の対応ではない。本論文は任意の層ペアに存在する回帰可能性の上に、同一層という選択をしたケーススタディであると位置づける。

整合が**学習可能**であることは確認できるが、同じ層番号が自然に対応していたとは言えない。

以降の数値はすべて、同一構成の単一の学習から得たものである。潜在の幅は  $d_z = d = 4096$ 、32 ブロックすべてを対応付け、アダプタは 268.5M パラメータ、 $\sigma = 0.4$ 、学習率は  $10^{-3}$  から plateau 方式で下限  $10^{-5}$  まで下げた。学習信号は Alpaca 学習分割の 2,075 窓から取った残差である。各窓は 112 トークンであり、独立なトークン位置は約 232k となる。これらの残差は 32 層で 7.44M ペアを成し、このペア集合を約 228 回復した。報告値は、保留  $A \rightarrow B$  が最良となる最深点、すなわち 415,000 回復目のチェックポイントから得た。Pythia  $\rightarrow$  RWKV の系統横断写像は  $B \rightarrow A$  0.590 で、わずかに  $A \rightarrow B$  0.559 を上回る。すなわち RNN 側の残差の方が Transformer 潜在から復元しやすい。両者とも、 $A \rightarrow A$  0.695 と  $B \rightarrow B$  0.711 という自系統再構成を下回る。高い潜在整合のもとでも自系統再構成の段階ですでに誤差が残り、系統横断の読み出しはそれをさらに下回る。この誤差が符号器・潜在の正規化・復号器・学習時ノイズのいずれに由来するかは切り分けていない。次節では、自己再構成と横断読み出しの差を比較する。これらの整合・読み出しがトークンごとの真の対応であって分布の重なりではないことは、負の対照で確かめた： $A$  の行順を保ったまま  $B$  の残差行を単一の乱数置換で入れ替えて再対応させると、 $\rho_{\text{ctr}}$  は  $0.901 \rightarrow 0.000$ 、 $A \rightarrow B$  は  $0.561 \rightarrow -0.592$ 、 $B \rightarrow A$  は  $0.592 \rightarrow -0.609$  へ崩壊する。自系統写像  $A \rightarrow A$ 、 $B \rightarrow B$  は構成上変化しない。すなわち両方向の読み出しとも、正しいトークン対応なしには得られない。

以下では、 $z$  は  $z_A$  または  $z_B$  を表し、 $\bar{z}$  はその層内で求めた次元別トークン平均を表す。 $\rho_{\text{raw}}$  はこのトークン平均を引く前の  $z_A, z_B$  の Pearson 相関である。align は式 (1) の第 3 誤差項に対応する  $z_A, z_B$  間の平均二乗距離であり、重み  $\lambda$  は含めない。潜在のうちトークンごとに変動する成

分の割合  $f$  を使うと、要素ごとの係数を持たない層正規化のもとで、生の相関と中心化相関の関係を次のように分解できる。

$$\begin{aligned} f &= \frac{\|z - \bar{z}\|^2}{\|z\|^2}, \\ \rho_{\text{raw}} &= (1 - f) + f \rho_{\text{ctr}}, \\ \text{align} &= 2f(1 - \rho_{\text{ctr}}). \end{aligned} \quad (3)$$

ここで報告する  $f$  は  $A, B$  それぞれの変動割合の平均である。式 (3) が等式として成り立つには、両者の変動割合が等しく、共通モードが平行でなければならない。実測では、学習が進んだ後の評価点でこの関係は  $3 \times 10^{-4}$  程度の精度で成り立つ。ただし学習初期には成り立たず、0 回復目では残差が  $6.6 \times 10^{-2}$  に達する。式 (3) が示すのは、生の相関が中心化相関と定数項の影響をともに含むということである。そのうち  $1 - f$  の割合は、情報を持たない定数項として与えられる。最深点の  $f$  は 0.350 であるから、潜在の持つエネルギーの 65% はトークンに依存しない定数であり、生の相関はその定数に支配される。実際、中心化した  $\rho_{\text{ctr}}$  が 0.901 であるのに対し生の相関は 0.965 を示し、式 (3) はこれを  $(1 - 0.350) + 0.350 \times 0.901 = 0.965$  と過不足なく再現する。

#### $f$ が示すこと、示さないこと

$f$  は二次モーメントであって情報量ではなく、そこから引ける推論は一方向に限られる。 $f \rightarrow 0$  は潜在が定数に崩壊したことを証明し、したがってトークンごとの情報を一切持たないことを示す。 $f$  が大きいことが意味するのは、トークンごとの潜在が角度方向に散らばっていることだけであり、係数を持たない層正規化のもとで  $f$  は倍率に対して厳密に不変である。散らばりは意味のある変動からも無意味な変動からも等しく生じる。変動する成分が情報を担っていると言えるのは、 $f$  ではなく読み出しの側である。読み出しは中心化  $R^2$  であり、トークンに依存しない予測器は 0 を超えられず、最良の定数がちょうど 0 点となる。ゆえに  $B \rightarrow B = 0.711$  はいかなる定数からも得られず、潜在のエネルギーの 65% が定数であることと矛盾しない。

#### 4.2 両横断読み出しは全層で自系統再構成を下回る

測定した五つの診断値を図 3 に示す。

$$\begin{aligned} \rho_{\text{ctr}} &= 0.901, \\ R^2(B \rightarrow B) &= 0.711, \quad R^2(A \rightarrow B) = 0.559, \\ R^2(A \rightarrow A) &= 0.695, \quad R^2(B \rightarrow A) = 0.590. \end{aligned}$$

$\rho_{\text{ctr}}$  は相関係数、後四者は決定係数であり、両者を同じ尺度の量として比較することはできない。本節の結論は、 $R^2$  同士では全 32 層で  $A \rightarrow B \leq B \rightarrow B$  かつ  $B \rightarrow A \leq A \rightarrow A$  であること、および後述する自系統再構成対照で、符号化と復号の往復による損失が下流性能にも現れることに基づく。この損失は、Pythia 自己再構成では全切替層の両課題




図 2 生残差の全 32×32 層対応。左は線形 CKA, 右は層別線形写像の適合  $R^2$  を示す。破線は同番号層であり、二つのパネルで色尺度が異なる。

で、RWKV 自己再構成 では  $L=16, 24$  の両課題で有意となる。

高い潜在相関は、高い再構成精度を保証しない。RWKV→Pythia は同一の復号器  $D_B$  を通る Pythia 自己再構成 と、Pythia→RWKV は同一の復号器  $D_A$  を通る RWKV 自己再構成 と比較でき、入力が自系統潜在か他系統潜在かだけが異なる。両不等式は経験的な観測であって定理ではないが、いずれの方向でも自己再構成の段階ですでに相当の誤差があり、系統横断だけを改善してもその誤差は残る。

$d_z=d=4096$  では潜在の幅が残差の幅に等しく、非アフィン LN が落とすのもトークンごとの平均とノルムの二自由度にすぎないため、幅や階数が再構成を強く制約するとは考えにくい。それでも  $B \rightarrow B$  は 0.711 に留まる。これがノイズ  $\sigma$  が定める天井なのかは不明であり、何が律速となっているかは未解決問題として残っている。

#### 4.3 アダプタは両横断経路で非線形である

アダプタの  $E$  と  $D$  はそれぞれ 2 つの線形写像に挟まれたゼロ初期化の残差ブロック 1 個であり、いずれも線形写像から学習を始める。だがそれは学習前の性質であって、415,000 反復後の性質ではない。最深点のアダプタが実際どれだけ線形かを、RWKV→Pythia / Pythia→RWKV と同じ代表 5 層、同じあてはめ行・保留行で測った。

アダプタ自身の出力を模倣する最良のアフィン写像が説明する出力分散は、RWKV→Pythia で 86.6%, Pythia→RWKV で 88.0% である。したがって残る 13.4% / 12.0% は、適合したアフィン写像では捉えられない。学習後の写像は両経路で明確に非線形である。

比較対象はアダプタを近似したものではなく、層ごとに各経路の標準化した入力残差から標準化した出力残差へ

の最良のアフィン写像を、リッジ付き最小二乗で別々に直接あてはめた対照である。代表 5 層 {4, 10, 16, 22, 28} の保留行で評価すると、最良直接アフィン写像は RWKV→Pythia 0.487, Pythia→RWKV 0.535 に達する。対応するアダプタは同じ行で RWKV→Pythia 0.558, Pythia→RWKV 0.576 であり、非線形写像の増分は +0.071 / +0.041 である。低容量のアフィン写像でも両経路で相当な系統横断予測ができるため、共有表現の主張はこの線形到達性で担保される。

**別途適合したアフィン対照。** この対照は切替層ごとに、Alpaca のうちアダプタの学習に用いていない保留領域から取った 40,096 行の標準化残差へ、正則化係数  $10^{-3}$  の切片つきリッジ回帰で適合したものである。表 1 では、RWKV→Pythia のアダプタを直接アフィン写像へ置き換えると正答率が 8-23 点崩れる。一方 Pythia→RWKV では差が小さく、SciQ @8 ではアフィン対照の方が 3.4 点高い。これは経路差として重要だが、二つの写像は学習目的・データ・正則化が異なるため、非線形性の因果効果とはみなさない。

**交絡を抑えた介入：同一アダプタの MLP 枝を無効化する。** そこで、同一の学習済みアダプタに含まれる残差ブロックだけを係数  $\alpha$  でスケールする。このブロックは、 $\text{fc}_2(\text{GELU}(\text{fc}_1(\cdot)))$  という唯一の学習非線形性を与える。 $\alpha=1$  は完全な写像、 $\alpha=0$  は枝を外した同一写像を表す。表現  $R^2$  の  $\alpha = 0, .25, .5, .75, 1$  掃引は、RWKV→Pythia で  $-0.41, -0.75, 0.35, 0.52, 0.56$ , Pythia→RWKV で  $-0.30, -0.66, 0.36, 0.53, 0.58$  となる。両経路で枝を外すと負の  $R^2$  まで崩れ、しかも非単調である。二つの線形層は残差ブロックと協調して学習されており、この学習済みアダプタでは、非線形枝は RWKV→Pythia だけでなく




図 3 共有潜在から四つの読み出しへの遷移。同色の経路は同じ復号器を共有する。

表 1 学習済みアダプタと、各経路へ直接適合したアフィン対照の長さ正規化正答率。単位は百分率であり、同じ問題・切替層・後段を用いる。

|     | ARC-Easy      |        |               |        | SciQ          |        |               |        |
|-----|---------------|--------|---------------|--------|---------------|--------|---------------|--------|
|     | RWKV → Pythia |        | Pythia → RWKV |        | RWKV → Pythia |        | Pythia → RWKV |        |
| $L$ | adapter       | affine | adapter       | affine | adapter       | affine | adapter       | affine |
| 4   | 59.6          | 41.9   | 62.2          | 60.2   | 70.9          | 47.5   | 69.2          | 69.6   |
| 8   | 59.0          | 43.1   | 57.3          | 56.0   | 67.7          | 49.1   | 64.6          | 68.0   |
| 16  | 48.6          | 34.8   | 57.5          | 57.5   | 54.5          | 35.9   | 68.0          | 69.6   |
| 24  | 47.0          | 39.4   | 59.6          | 59.2   | 51.1          | 42.7   | 69.9          | 68.2   |

Pythia → RWKV の読み出しにも除去不能である。これは学習済み写像の性質であって、本論文が同目的で学習した線形アダプタとの比較は行っていないことに注意が必要である。多肢選択でも同じ  $\alpha = 0/1$  を同一問題上でベア化して評価する。

表 2 の枝効果は RWKV → Pythia で +11.1–+39.6 点、Pythia → RWKV で +11.2–+36.6 点であり、16 比較すべてで同一問題上の McNemar 正確検定  $p < 2 \times 10^{-9}$  となる。したがって、この学習済みアダプタから非線形枝を外すと、RWKV → Pythia / Pythia → RWKV の両方で表現と下流精度がともに崩れることが直接確認される。ただしこれは同時に学習された写像から枝だけを除いた場合の性質であり、非線形性が系統間の接続に一般に必要なことは示さない。少なくとも Pythia → RWKV の正答率では、別途適合したアフィン対照とアダプタの差は小さく、8 セルで −3.4 ~ +2.0 点に収まる。表 1 が示すように、アダプタが一貫して上回るわけではない。

#### 4.4 構文的に妥当な生成は得られるが事実性は劣化する

ここで実際に 7B で両横断経路を合成する。切替層  $L$  では、前段親をブロック 0 から  $L$  まで、合計  $L+1$  ブロック走らせる。その残差を式 (2) で一度だけ他方の空間へ翻訳し、後段親のブロック  $L+1$  以降と言語モデルヘッドを走らせる。ブロックごとに往復する構成ではない。したがって RWKV → Pythia ( $L=16$ ) は RWKV 17 ブロックと Pythia 15 ブロック、Pythia → RWKV ( $L=16$ ) はその反対で、いずれも厳密な半分ではない。

最深点の同一アダプタを RWKV → Pythia / Pythia → RWKV とも  $L=4$  に挿入し、同じ四つの英語プロンプトを

温度 0、最大 40 新規トークンで食欲復号した。 $L=4$  は、二課題平均が各横断方向の四境界中で最大であり、SciQ の KV-精度平面でも両方向が非支配集合に入る共通境界である。図 5 にこの関係を示す。ただしこれは同じ報告タスクを見た後の代表点選択であり、独立な生成用選択基準ではない。本比較は網羅的な生成ベンチマークではないが、両モデルの元モデル及びキメラモデルの出力を同条件で観察する。

これらのケーススタディから、RWKV → Pythia / Pythia → RWKV とも構文的にもっともらしい出力を生成できることが観測できる。両方がフランスの首都へ正答し、三原色も正しく開始する。RWKV → Pythia はブラックホールにも一文で正答しており、指示に沿った文生成そのものは成立している。他方で、流暢さが保たれても内容や指示形式を失い得る。両方向とも水の補完を“hydrogen”と誤り、Pythia → RWKV は三原色への正答後に対話形式へ逸脱し、ブラックホールを循環的に説明する。したがって 0.559/0.590 の横断読み出しでも事実性は十分でない。より忠実なキメラには両横断読み出しと自系統再構成の改善が必要である。

#### 4.5 親モデルとの機能・推論メモリ比較

NinaXander の実用上の価値を評価するには、内部表現の指標だけでなく、凍結した両親との機能比較が必要である。ここでは三点を測る。第一は強い親モデルに対してどこまで性能を保てるか、第二は弱い親を上回るか、第三はその代わりにどの程度 KV キャッシュを削減できるかである。

この比較は、各選択肢の対数尤度を求めて最大のものを

表 2 同一アダプタの非線形枝を無効化したときの長さ正規化正答率。単位は百分率であり、各セルは完全な写像から枝だけを除いた変化  $\alpha: 1 \rightarrow 0$  を示す。

| $L$ | ARC-Easy                  |                           | SciQ                      |                           |
|-----|---------------------------|---------------------------|---------------------------|---------------------------|
|     | RWKV $\rightarrow$ Pythia | Pythia $\rightarrow$ RWKV | RWKV $\rightarrow$ Pythia | Pythia $\rightarrow$ RWKV |
| 4   | 59.6 $\rightarrow$ 31.9   | 62.2 $\rightarrow$ 31.8   | 70.9 $\rightarrow$ 31.3   | 69.2 $\rightarrow$ 32.6   |
| 8   | 59.0 $\rightarrow$ 29.9   | 57.3 $\rightarrow$ 35.5   | 67.7 $\rightarrow$ 31.4   | 64.6 $\rightarrow$ 37.0   |
| 16  | 48.6 $\rightarrow$ 28.5   | 57.5 $\rightarrow$ 43.7   | 54.5 $\rightarrow$ 31.7   | 68.0 $\rightarrow$ 47.3   |
| 24  | 47.0 $\rightarrow$ 34.8   | 59.6 $\rightarrow$ 48.4   | 51.1 $\rightarrow$ 40.0   | 69.9 $\rightarrow$ 49.1   |

$A = \text{RWKV, KV 不要}$      $B = \text{Pythia, KV 要}$




図 4 RWKV $\rightarrow$ Pythia / Pythia $\rightarrow$ RWKV キメラの構成。前段をブロック  $L$  まで実行して残差を一度翻訳し、後段をブロック  $L+1$  から実行する。

表 3 両親と  $L=4$  の RWKV $\rightarrow$ Pythia / Pythia $\rightarrow$ RWKV による同一プロンプトへの生成例。temperature 0 の argmax, 最大 40 新規トークン, EOS のみ早期終了とした。

| Prompt (verbatim)                                                                  | pure Pythia                                                                                                           | RWKV $\rightarrow$ Pythia<br>横断読み出し $R^2=0.559$                                                                     | pure RWKV                                                                                                               | Pythia $\rightarrow$ RWKV<br>横断読み出し $R^2=0.590$                                                                        |
|------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------|
| ### Instruction:<br>What is the capital of France?<br>### Response:                | “The capital of France is Paris.”                                                                                     | “ <b>The capital of France is Paris.</b> ” ✓                                                                        | “Paris.”                                                                                                                | “ <b>Paris.</b> ” ✓                                                                                                    |
| The three primary colors are                                                       | “red, yellow, and blue. These colors are often used in combination to create a wide variety of colors.”               | “ <b>red, yellow, and blue.</b> ” ✓                                                                                 | “red, blue, and yellow.” と正答後、赤の反対色である緑を問う Q&A へ逸脱                                                                      | “red, blue, and yellow.” と正答後、Bob/Alice の緑についての対話へ逸脱                                                                   |
| Question: Water is made of hydrogen and<br>Answer:                                 | “Hydrogen is made of hydrogen and oxygen.”                                                                            | “Hydrogen.” 誤り                                                                                                      | “hydrogen.” 誤り                                                                                                          | “hydrogen.” 誤り                                                                                                         |
| ### Instruction:<br>Explain what a black hole is in one sentence.<br>### Response: | “A black hole is a region of spacetime where gravity is so strong that nothing, not even light, can escape its pull.” | “A black hole is a region in space where gravity is so strong that nothing, not even light, can escape its pull.” ✓ | “A black hole is a region of space where the gravitational pull is so strong that nothing, not even light, can escape.” | “A black hole is a type of celestial object that is formed when a star collapses and collapses into a black hole.” 循環的 |

選ぶ多肢選択形式で行う。生成も文字列の照合も主観的な判定も介在しないため、結果は一意に定まる。全評価集合として、ARC-Easy [30] test 2376 問と SciQ [31] test 1000 問を用いる。アダプタは  $d_z=4096$  の最深点、すなわち 415,000 反復目であり、四つの切替位置を評価する。同

一問題集合上の構成間比較はペア化データなので、差はセルごとの独立な二項 SE ではなく、McNemar の正確検定と対応 bootstrap によるペア化検定で評価する。選択肢は長さが異なり総和／長さ正規化で順位が食い違い得るので両方を構造化データに保存し、本文は長さ正規化を報告・

検定に用いる。また SciQ は付属の support 文を与えず、Question と Answer だけからなる closed-book 形式で評価するため、本稿の SciQ 値は support を与える標準プロトコルの公表値と直接比較できない。

四経路の同時比較から六つのことが読み取れる。第一に、前段と後段が異なる系統であっても、RWKV→Pythia / Pythia→RWKV とともに実際に問いへ答えられる。全横断構成が当て推量を大きく上回り、SciQ では RWKV→Pythia 70.9%, Pythia→RWKV 69.9% に達する。第二に、深さ効果は経路依存である。RWKV→Pythia は  $L = 4 \rightarrow 24$  で SciQ  $70.9 \rightarrow 67.7 \rightarrow 54.5 \rightarrow 51.1$ , ARC-Easy  $59.6 \rightarrow 59.0 \rightarrow 48.6 \rightarrow 47.0$  と単調に下がるが、Pythia→RWKV は SciQ  $69.2 \rightarrow 64.6 \rightarrow 68.0 \rightarrow 69.9$ , ARC-Easy  $62.2 \rightarrow 57.3 \rightarrow 57.5 \rightarrow 59.6$  と非単調である。局所読み出しは同じ四層で RWKV→Pythia 0.570/0.555/0.575/0.567, Pythia→RWKV 0.552/0.517/0.604/0.608 であり、接続する層や  $R^2$  だけから順位は決定できない。第三に、強いほうの親はどちらの経路でも超えられない。全 8 横断構成が両タスクで Tulu-Pythia を下回り、各同一問題の McNemar 検定でも有意である。第四に、RWKV に対する差も経路・課題依存である。RWKV→Pythia ( $L=4$ ) は SciQ で RWKV を +3.9 点上回り、 $p=0.018$  となる一方、ARC-Easy では -2.2 点、 $p=0.042$  となる。ただし総和スコアではこの優位は消える。総和スコアにおける RWKV→Pythia ( $L=4$ ) は SciQ -2.7 点であり、Pythia→RWKV ( $L=4$ ) は ARC -4.6 点、SciQ -5.7 点である。したがって、弱い親に対する優劣の判定は長さ正規化の選択に依存する。Pythia→RWKV はいずれの境界も RWKV を有意に上回らない。Pythia→RWKV ( $L=4$ ) は ARC +0.4 点で  $p=0.66$ , SciQ +2.2 点で  $p=0.14$  となり、統計的に同等である。第五に、別途適合したアフィン対照の差も経路依存である。RWKV→Pythia ではアダプタが全セルで 8-23 点高いが、Pythia→RWKV では差が小さく、SciQ @8 ではアフィンが 3.4 点高い。すなわち、学習済みアダプタがつねにアフィン写像を上回るわけではない。第六に、自系統対照との差は翻訳誤差だけではない。B 後段では純 Pythia, Pythia 自己再構成, RWKV→Pythia の順に下がり、Pythia 自己再構成→RWKV→Pythia 差は SciQ 4-19 点、ARC 3-12 点である。一方 A 後段では Pythia→RWKV が RWKV 自己再構成を深い境界で逆に上回り、 $L = 16/24$  の差は ARC +2.7/+7.4 点、SciQ +8.2/+12.0 点となる。自系統対照は符号化と復号の往復による損失を切り分けるが、横断との差には前段親の能力と翻訳のずれがともに入るため、普遍的な「翻訳コスト」とは読めない。

#### RWKV→Pythia と Pythia→RWKV では深さ依存が異なる

表 4 のとおり、Pythia→RWKV は  $L=16, 24$  で同じ層の RWKV→Pythia を ARC で +8.9/+12.6 点、SciQ で

+13.5/+18.8 点上回る。同一問題の McNemar 検定では、すべて  $p < 3 \times 10^{-15}$  となる。一方、 $L=4$  は ARC で +2.6 点、 $p=0.015$  だが、SciQ では -1.7 点、 $p=0.28$  であり、浅い境界では経路差は一樣でない。なお、どの Pythia→RWKV 構成も Pythia を有意に下回る。また RWKV に対して有意に優る Pythia→RWKV 構成はなく、Pythia→RWKV ( $L=4$ ) は ARC 62.2 対 61.8 で  $p=0.66$ , SciQ 69.2 対 67.0 で  $p=0.14$  となり、同等である。

Pythia→RWKV の最良アフィン写像は、各切替層でアダプタと別に適合した対照である。ARC @4 ではアダプタが +2.0 点で  $p=0.005$  となるが、他の多くは差がない。SciQ @8 では逆にアフィンが +3.4 点で  $p=0.003$  となる。この写像間比較とは別に、同一アダプタの非線形枝を  $\alpha = 0$  とする介入を RWKV→Pythia / Pythia→RWKV の同じ四層・同じ問題で実行し、因果的な非線形枝の寄与はそのペア化結果から評価する。RWKV 自己再構成対照との比較も、RWKV 前段を Pythia 前段と横断翻訳へ同時に置き換えるため、翻訳誤差だけを分離しない。

#### 合成によるメモリ上の効果：Transformer 層とともに KV キャッシュが消える

性能と推論メモリは同時に評価する必要がある。二つの系統は推論時の費用が同じではないからである。Transformer の層はトークンごとに key/value をキャッシュするが、RNN 層が持つのは系列長に対して  $O(1)$  の再帰状態である。RWKV→Pythia は Transformer を  $31-L$  層、Pythia→RWKV は  $L+1$  層だけ保持する。なお削減の対象は KV キャッシュであって常駐重みではない。アダプタ自体は fp16 で 0.50 GiB を占め、一方向のみを常駐させても約 0.25 GiB で、削減後の KV と同程度である。

RWKV→Pythia / Pythia→RWKV を含めると、Pythia→RWKV ( $L=4$ ) は RWKV→Pythia ( $L=4$ ) より Transformer 層を  $27 \rightarrow 5$  へ減らしながら、二タスク平均を  $65.25\% \rightarrow 65.70\%$  とほぼ保つ。置き換える RWKV の再帰状態は層あたり 64 KiB である。この値は、参照実装が持つ 5 状態ベクトルのうち 2 つを fp16, 3 つを fp32 として算出した。再帰状態の大きさは構成上、文脈長に依存しない。ただし純 RWKV は KV がゼロであり、順位はタスクに依存するため、図 5 は SciQ に限ったメモリと精度のフロンティアとして示す。

Pythia 前段の経路を加えると、高削減点 Pythia→RWKV ( $L=4$ ) が得られる。この点は RWKV 前段の経路だけでは現れない。一方、pure RWKV は依然 KV ゼロであり、Pythia→RWKV ( $L=4$ ) が RWKV を有意に上回るわけでもない。したがって利点は、凍結親の間に追加の交換点を作れることであって、新しい構成が親を一律に支配することではない。

結果は限定付きである：機能は保つが、正答率の一律な向上ではない。RWKV→Pythia / Pythia→RWKV とともに強

表 4 4 経路の長さ正規化正答率。単位は百分率であり，各行・各課題の最大値を太字で示す。

|          | RWKV 自己再構成  |      | RWKV→Pythia |      | Pythia 自己再構成 |             | Pythia→RWKV |      |
|----------|-------------|------|-------------|------|--------------|-------------|-------------|------|
| <i>L</i> | ARC         | SciQ | ARC         | SciQ | ARC          | SciQ        | ARC         | SciQ |
| 4        | <b>62.8</b> | 68.5 | 59.6        | 70.9 | 62.2         | <b>74.8</b> | 62.2        | 69.2 |
| 8        | 59.8        | 66.7 | 59.0        | 67.7 | <b>62.7</b>  | <b>74.8</b> | 57.3        | 64.6 |
| 16       | 54.8        | 59.8 | 48.6        | 54.5 | 57.4         | <b>71.1</b> | <b>57.5</b> | 68.0 |
| 24       | 52.2        | 57.9 | 47.0        | 51.1 | 59.4         | <b>70.1</b> | <b>59.6</b> | 69.9 |

表 5 RWKV→Pythia / Pythia→RWKV 両経路の正答率と推論メモリ。KV は実測値であり，RWKV 再帰状態は文脈長に依存しない。

| 構成                       | Transformer 層 | KV / token    | KV @ 4k 文脈      | 削減           | ARC / SciQ         |
|--------------------------|---------------|---------------|-----------------|--------------|--------------------|
| pure Tulu-Pythia         | 32            | 512 KiB       | 2.00 GiB        | 0%           | 65.3 / 81.0        |
| RWKV→Pythia (L=4)        | 27            | 432 KiB       | 1.69 GiB        | 15.6%        | 59.6 / 70.9        |
| RWKV→Pythia (L=8)        | 23            | 368 KiB       | 1.44 GiB        | 28.1%        | 59.0 / 67.7        |
| RWKV→Pythia (L=16)       | 15            | 240 KiB       | 0.94 GiB        | 53.1%        | 48.6 / 54.5        |
| RWKV→Pythia (L=24)       | 7             | 112 KiB       | 0.44 GiB        | 78.1%        | 47.0 / 51.1        |
| Pythia→RWKV (L=24)       | 25            | 400 KiB       | 1.56 GiB        | 21.9%        | 59.6 / 69.9        |
| Pythia→RWKV (L=16)       | 17            | 272 KiB       | 1.06 GiB        | 46.9%        | 57.5 / 68.0        |
| Pythia→RWKV (L=8)        | 9             | 144 KiB       | 0.56 GiB        | 71.9%        | 57.3 / 64.6        |
| <b>Pythia→RWKV (L=4)</b> | <b>5</b>      | <b>80 KiB</b> | <b>0.31 GiB</b> | <b>84.4%</b> | <b>62.2 / 69.2</b> |
| pure RWKV-Raven          | 0             | 0             | 0               | 100%         | 61.8 / 67.0        |




図 5 RWKV→Pythia / Pythia→RWKV の SciQ 正答率と実測 KV 削減率。緑線は両経路を含む非支配点を結ぶ。

い Pythia を有意に下回る。RWKV→Pythia は RWKV を SciQ でのみ上回り，Pythia→RWKV はどの境界も RWKV を有意に上回らない。得られた主な利点は，Pythia→RWKV (L=4) で Pythia の正答率の一部を保ちながら Transformer KV を 84.4% 除けることである。

#### 翻訳は領域特異的である

以上の正答率は，指示形式に近い短い設問で測ったものである。KV キャッシュの節約が意味を持つのは長い文脈

であり，そこでキメラが異なる領域のテキストコーパスに対してどれだけ言語モデルを保つかを測る必要がある。領域外コーパスには WikiText-103 [32] を用いる。文脈 512 の RWKV→Pythia (L=4) は Alpaca で perplexity 6.40, WikiText-103 で 93.87 である。Pythia→RWKV (L=4) は 3.85/45.00 と両領域で改善するが，WikiText はなお親の 11.33/16.22 から大きく離れる。文脈を 2048 へ伸ばすと Pythia→RWKV (L=4) は Alpaca 3.50, WikiText 34.78 となり，崩壊せずむしろ改善する。したがって主因は文脈長でなく領域シフトである。Pythia→RWKV はシフトを緩和するが，WikiText 34.78 は良い方の親 RWKV 8.27 の 4.2 倍であり，依然として高い perplexity にとどまる。




図 6 文脈 512 における Alpaca と WikiText-103 の perplexity。縦軸は対数である。

## 5. 考察

本実験では、凍結した異種系統の対応層間に、 $\rho_{ctr}=0.90$ となる共有表現を学習できる。ただし主張の射程は限定的である：本研究の対応は**同一トークナイザ・同一幅・同一層数・同一入力・Alpaca 近傍領域**という好条件で測ったものであり、シャッフル対照はトークン非依存の分布一致を排除するが、観測された対応が意味・語彙・位置・構文のいずれに由来するかは切り分けていない。§4.5で示したように、領域外 WikiText では perplexity が劣化する。この結果は、学習領域の外への汎化に疑問が残ることを示す。ゆえに「一般的な共通意味空間」を主張せず「好条件下でトークン対応した表現の共通空間」の存在を主張するにとどめる。

機能的な接合が成立することは、両者が同じ情報を表現していることを意味しない。Smith ら [33] は、異なる課題や異なるモダリティの間、さらにはクラスタ化した乱数由来の表現からでも接合が成立し得ることを示している。ただし彼らの接合層は下流課題の損失で学習されており、Balogh と Jelasity [34] が、その方式は対応しない層や領域外の表現を高く評価すると指摘した手法にあたる。本研究のアダプタは対応残差の直接整合で学習しており、同論文が構造的な要求と機能的な要求のバランスが良いとした側に属する。とはいえ Smith らは低容量の接合層でも偽の整合を得ており、本研究のアダプタはより表現力が高い。§4.3で示したように、低容量のアフィン写像でも相当な横断予測が得られる。この結果が、観測された整合をアダプタの表現力だけでは説明できないとする主たる根拠である。高い潜在相関が高い読み出し精度を保証しない点も重要であり、共有表現の有無と復号可能性は分けて評価する必要がある。この区別は独立にも報告されている。Zhang と Xin のプレプリント [35] は、Pythia 間の線形ブリッジがオフラインでは正規化  $R^2 = 0.883$  に達しながら、受信側へ置換注入すると多段推論の性能がかえって下がることを示し、受信側での因果的な利用を目的関数に含める必要があると結論づけた。本研究のアダプタも活性の再構成のみで学習しており、この指摘の射程内にある。ただし式 (2) は層別統計による逆標準化を含み、受信側本来のスケールを復元する点が、正規化目的で学習された彼らの線形ブリッジと異なる。この構造的差異が寄与しているかは、本研究では切り分けていない。この空間上に組んだキメラは機能するものの損失を伴い、生成例では両経路とも流暢さを保ったまま内容または形式を誤る。競争力のあるキメラには、 $B \rightarrow B$  を律速する要因の特定、領域をまたいだ学習、および事前学習側で相補的な親モデルの選定が必要である。

## 6. 限界

評価課題への露出がある。Tulu-Pythia は FLAN V2 の

部分集合で指示チューニングされており、FLAN の構成タスク一覧には ARC と SciQ が含まれる。公開されている混合データの当該成分を逐語照合すると、評価項目のうち ARC-Easy 19 問と SciQ 4 問が見つかる。照合は逐語一致に限られるため、言い換えや書式の差は検出できない。偶然の一致を避けるため除外した 6 語未満の問題も検出対象外であり、その内訳は ARC-Easy 40 問と SciQ 11 問である。したがって、検出数は下限となる。項目単位の正誤記録からこれらを除いて全構成の正答率を再計算しても変化は最大 0.22 点であり、本稿のどの比較の結論も変わらない。さらに、これらの項目は露出のない RWKV でも同方向に難化・易化する。変化は ARC で  $-9.2$  点、SciQ で  $+8.0$  点であり、差は露出ではなく項目自体の難易度で説明される。ただし ARC-Easy・SciQ が後段親のすでに持つ課題族であることは変わらないため、本稿の値は未知能力の獲得ではなく合成後の能力保持を測るものと読むべきである。

アダプタの学習は乱数種一つのみである。性能は ARC-Easy 2376 問と SciQ 1000 問からなる全評価集合で測り、構成間の差は McNemar の正確検定と対応 bootstrap による同一問題上のペア化検定で評価した。RWKV $\rightarrow$ Pythia が弱い親を上回るのは SciQ のみ、かつ長さ正規化スコアに限られる。総和スコアでは成立しない。Pythia $\rightarrow$ RWKV はどの境界も RWKV を有意に上回らない。2 タスク  $\times$  2 横断経路  $\times$  4 切替と複数対照を評価し、多重比較補正は行っていない。非線形枝の同一アダプタ介入は RWKV $\rightarrow$ Pythia / Pythia $\rightarrow$ RWKV と同じ層・問題で行ったが、単一チェックポイント上の介入であり、異なるアダプタ学習条件へ一般化できるとは限らない。

また合成は常に境界を一箇所しか持たず、複数境界で翻訳誤差がどう累積するかは測定していない。さらにキメラの評価は尤度に基づいており、これは正しい選択肢を選ぶ能力を測るものであって、生成する能力を直接測るものではない。RWKV $\rightarrow$ Pythia / Pythia $\rightarrow$ RWKV 各四つの生成例は定性的な補足にとどまり、生成能力の包括的評価ではない。

加えて、翻訳は**学習領域に特化**しており、WikiText では大きく劣化する。長文脈 CE は文脈 512/1024/2048 で測る。Tulu-Pythia の最大位置数が 2048 であり、どちらの横断経路も同モデルを含むため、共通の評価上限を 2048 とした。RWKV の変換後設定が指定する 1024 を超える測定点は、設定上の長さを越えた外挿にあたる。さらに、変換元となった BlinkDL のファイル名とリビジョンが残っていないため、元のチェックポイントが掲げた学習時のコンテキスト長は確認できない。これは言語モデリングの品質であって、遠距離依存を要する読解を直接測るものではない。 $\sigma \cdot \lambda \cdot$  潜在幅・残差ブロック数・学習データ量に対するアブレーション、および同じアーキテクチャを持つ同

一系統ペアでの整合は本 32 層構成では実施しておらず、今後の課題である。

## 7. おわりに

本研究は、異なる事前学習システムの凍結ブロックを単一の共有潜在アダプタで一箇所だけ接続するキメラモデル群 NinaXander を構築し、RWKV-4-Raven-7B と Tulu-Pythia-6.9b を対象に、系統をまたぐ合成について何が成立し何が成立しないかを、表現のレベルから下流の機能まで順に測った。同一トークナイザ・同一幅・同一層数・同一学習領域という好条件のもとで、対応層間の整合は**学習可能**であり、中心化潜在相関は 0.901 に達する一方、行対応をシャッフルすると 0.000 へ崩壊する。ただし生表現の CKA は同一層で最大にならず、領域外では性能が劣化する以上、示されたのは一般的な意味空間ではなく、好条件下で学習可能なトークン対応表現である。系統横断に入る前の、自系統再構成の段階ですでに誤差が残る。横断読み出しは、それぞれ同じ復号器を使う自系統対照を全層で下回るが、その誤差が符号器・潜在の正規化・復号器・学習時ノイズのいずれに由来するかは切り分けていない。学習済みアダプタから非線形枝を外すと両横断読み出しは負の  $R^2$  まで崩れるが、これは同時に学習された写像から枝だけを除いた場合の性質であって、非線形性が系統間の接続に一般に必要なことを示さない。実際 Pythia→RWKV では、別途適合したアフィン対照とアダプタの差は小さい。機能の側では、アダプタを一度学習すれば 4 切替位置  $\times$  2 方向の 8 構成が構成ごとの再学習なしに得られ、合成したキメラは構文的に妥当な生成と多肢選択の遂行が可能である。Pythia→RWKV ( $L=4$ ) は Transformer を 5 層だけ残して KV キャッシュを 84.4% 削減しながら ARC-Easy 62.2%, SciQ 69.2% を保つ。ただし削減されるのは KV キャッシュであって常駐重みではなく、アダプタ自体が fp16 で 0.50 GiB を占め、一方向のみを常駐させても約 0.25 GiB と、文脈 4k での削減後の KV 0.31 GiB と同程度の常駐費用が加わる。生成例では両経路とも流暢さを保ったまま内容または形式を誤り、どの構成も強い親 Tulu-Pythia を超えない。Pythia→RWKV ( $L=4$ ) は RWKV をも有意には上回らない。ARC は 62.2 対 61.8 で  $p=0.66$ , SciQ は 69.2 対 67.0 で  $p=0.14$  となり、統計的に同等である。この  $L=4$  という既定値自体も報告テスト上の事後選択であり、独立な deployment-selection 分割はない。

残された課題も同じ測定から導かれる。最大の弱点は領域外への汎化であり、文脈 2048 の Pythia→RWKV ( $L=4$ ) は WikiText で perplexity 34.78 と、良い方の親 RWKV の 8.27 から大きく離れたままである。あわせて、 $B \rightarrow B$  が 0.711 に留まる要因の特定、領域をまたいだ学習、事前学習側で相補的な親モデルの選定、複数境界における翻訳

誤差の累積の測定、 $\sigma \cdot \lambda$ ・潜在幅・残差ブロック数・学習データ量に対するアブレーション、そして複数の乱数種による再現が今後の課題として残る。本研究が示したのは競争力のある新モデルではなく、凍結資産の事後的な再構成が部分的に可能であること、および凍結した親の間に追加の交換点を作れることであり、その成立条件と限界を測定として記述したことが本稿の寄与である。

## 参考文献

- [1] Lenc, K. and Vedaldi, A.: Understanding Image Representations by Measuring Their Equivariance and Equivalence, *Int. J. Comput. Vision*, Vol. 127, No. 5, pp. 456–476 (online), DOI: 10.1007/s11263-018-1098-y (2019).
- [2] Bansal, Y., Nakkiran, P. and Barak, B.: Revisiting model stitching to compare neural representations, *Proceedings of the 35th International Conference on Neural Information Processing Systems, NIPS '21*, Red Hook, NY, USA, Curran Associates Inc. (2021).
- [3] Csizsárik, A., Körösi-Szabó, P., Matszangosz, A., Papp, G. and Varga, D.: Similarity and Matching of Neural Network Representations, *Advances in Neural Information Processing Systems* (Ranzato, M., Beygelzimer, A., Dauphin, Y., Liang, P. and Vaughan, J. W., eds.), Vol. 34, Curran Associates, Inc., pp. 5656–5668 (online), available from ([https://proceedings.neurips.cc/paper\\_files/paper/2021/file/2cb274e6ce940f47beb8011d8ecb1462-Paper.pdf](https://proceedings.neurips.cc/paper_files/paper/2021/file/2cb274e6ce940f47beb8011d8ecb1462-Paper.pdf)) (2021).
- [4] Hu, B., Li, S., Agarwal, S., Lee, M., Jajoo, A., Li, J., Xu, L., Kim, G.-W., Kim, D., Xu, H., Zhang, A. and Akella, A.: StitchLLM: Serving LLMs, One Block at a Time, *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)* (Che, W., Nabende, J., Shutova, E. and Pilehvar, M. T., eds.), Vienna, Austria, Association for Computational Linguistics, pp. 26887–26903 (online), DOI: 10.18653/v1/2025.acl-long.1305 (2025).
- [5] Zhang, Q., Bhargava, P., Bi, C., Cai, C. X., Forerster, J. N., Fu, J., Koura, P. S., Silva, R., Shen, S., Dinan, E., Gururangan, S. and Lewis, M.: BTS: Harmonizing Specialized Experts into a Generalist LLM, *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing* (Christodoulopoulos, C., Chakraborty, T., Rose, C. and Peng, V., eds.), Suzhou, China, Association for Computational Linguistics, pp. 6816–6834 (online), DOI: 10.18653/v1/2025.emnlp-main.347 (2025).
- [6] Bansal, R., Samanta, B., Dalmia, S., Gupta, N., Ganapathy, S., Bapna, A., Jain, P. and Talukdar, P.: LLM Augmented LLMs: Expanding Capabilities through Composition, *The Twelfth International Conference on Learning Representations*, (online), available from (<https://openreview.net/forum?id=jjA401vJRz>) (2024).
- [7] Roberts, N., Guo, S., Gao, Z., GNVP, S. S. S. N., Crompt, S., Wu, C., Duan, C. and Sala, F.: Pre-trained Hybrids with MAD Skills, *Second Conference on Language Modeling*, (online), available from (<https://openreview.net/forum?id=8xSbwT3763>) (2025).
- [8] Moschella, L., Maiorca, V., Fumero, M., Norelli, A., Locatello, F. and Rodolà, E.: Relative representations enable zero-shot latent space communication, *The Eleventh International Conference on Learning Representations*,

- (online), available from (<https://openreview.net/forum?id=Src-nwieGJ>) (2023).
- [9] Maiorca, V., Moschella, L., Norelli, A., Fumero, M., Locatello, F. and Rodolà, E.: Latent space translation via semantic alignment, *Proceedings of the 37th International Conference on Neural Information Processing Systems*, NIPS '23, Red Hook, NY, USA, Curran Associates Inc. (2023).
- [10] Grant, S.: Model Alignment Search, *Second Workshop on Representational Alignment at ICLR 2025*, (online), available from (<https://openreview.net/forum?id=8uNenpoGlh>) (2025).
- [11] Chen, A., Merullo, J., Stolfo, A. and Pavlick, E.: Transferring Linear Features Across Language Models With Model Stitching, *The Thirty-ninth Annual Conference on Neural Information Processing Systems*, (online), available from (<https://openreview.net/forum?id=Qvvy0X63Fv>) (2025).
- [12] Flamant, C., Ghai, U. and Shimizu, K.: The Bicameral Model: Bidirectional Hidden-State Coupling Between Parallel Language Models, arXiv:2605.11167, <https://arxiv.org/abs/2605.11167> (2026).
- [13] Goldstein, D., Obeid, F., Alcaide, E., Song, G. and Cheah, E.: GoldFinch: High Performance RWKV/Transformer Hybrid with Linear Pre-Fill and Extreme KV-Cache Compression, arXiv:2407.12077, <https://arxiv.org/abs/2407.12077> (2024).
- [14] Oozer, N. F., Nathawani, D., Prakash, N., Lan, M., HARRASSE, A. and Abdullah, A.: Activation Space Interventions Can Be Transferred Between Large Language Models, *Forty-second International Conference on Machine Learning*, (online), available from (<https://openreview.net/forum?id=HX0icJsmMQ>) (2025).
- [15] Kornblith, S., Norouzi, M., Lee, H. and Hinton, G.: Similarity of Neural Network Representations Revisited, *Proceedings of the 36th International Conference on Machine Learning* (Chaudhuri, K. and Salakhutdinov, R., eds.), Proceedings of Machine Learning Research, Vol. 97, PMLR, pp. 3519–3529 (online), available from (<https://proceedings.mlr.press/v97/kornblith19a.html>) (2019).
- [16] Raghu, M., Gilmer, J., Yosinski, J. and Sohl-Dickstein, J.: SVCCA: singular vector canonical correlation analysis for deep learning dynamics and interpretability, *Proceedings of the 31st International Conference on Neural Information Processing Systems*, NIPS'17, Red Hook, NY, USA, Curran Associates Inc., pp. 6078–6087 (2017).
- [17] Morcos, A. S., Raghu, M. and Bengio, S.: Insights on representational similarity in neural networks with canonical correlation, *Proceedings of the 32nd International Conference on Neural Information Processing Systems*, NIPS'18, Red Hook, NY, USA, Curran Associates Inc., pp. 5732–5741 (2018).
- [18] Wang, J., Ge, X., Shu, W., Tang, Q., Zhou, Y., He, Z. and Qiu, X.: Towards Universality: Studying Mechanistic Similarity Across Language Model Architectures, *The Thirteenth International Conference on Learning Representations*, (online), available from (<https://openreview.net/forum?id=2J18i8T0oI>) (2025).
- [19] Wortsman, M., Ilharco, G., Gadre, S. Y., Roelofs, R., Gontijo-Lopes, R., Morcos, A. S., Namkoong, H., Farhadi, A., Carmon, Y., Kornblith, S. and Schmidt, L.: Model soups: averaging weights of multiple fine-tuned models improves accuracy without increasing inference time, *Proceedings of the 39th International Conference on Machine Learning* (Chaudhuri, K., Jegelka, S., Song, L., Szepesvari, C., Niu, G. and Sabato, S., eds.), Proceedings of Machine Learning Research, Vol. 162, PMLR, pp. 23965–23998 (online), available from (<https://proceedings.mlr.press/v162/wortsman22a.html>) (2022).
- [20] Yadav, P., Tam, D., Choshen, L., Raffel, C. and Bansal, M.: TIES-MERGING: resolving interference when merging models, *Proceedings of the 37th International Conference on Neural Information Processing Systems*, NIPS '23, Red Hook, NY, USA, Curran Associates Inc. (2023).
- [21] Akiba, T., Shing, M., Tang, Y., Sun, Q. and Ha, D.: Evolutionary optimization of model merging recipes, *Nature Machine Intelligence*, Vol. 7, No. 2, pp. 195–204 (online), DOI: 10.1038/s42256-024-00975-8 (2025).
- [22] Wan, F., Huang, X., Cai, D., Quan, X., Bi, W. and Shi, S.: Knowledge Fusion of Large Language Models, *The Twelfth International Conference on Learning Representations*, (online), available from (<https://openreview.net/forum?id=jiDsk12qcz>) (2024).
- [23] Gao, L., Biderman, S., Black, S., Golding, L., Hoppe, T., Foster, C., Phang, J., He, H., Thite, A., Nabeshima, N., Presser, S. and Leahy, C.: The Pile: An 800GB Dataset of Diverse Text for Language Modeling, arXiv:2101.00027, <https://arxiv.org/abs/2101.00027> (2020).
- [24] Peng, B., Alcaide, E., Anthony, Q., Albalak, A., Arcadinho, S., Biderman, S., Cao, H., Cheng, X., Chung, M., Derczynski, L., Du, X., Grella, M., Gv, K., He, X., Hou, H., Kazienko, P., Koccon, J., Kong, J., Koptyra, B., Lau, H., Lin, J., Mantri, K. S. I., Mom, F., Saito, A., Song, G., Tang, X., Wind, J., Woźniak, S., Zhang, Z., Zhou, Q., Zhu, J. and Zhu, R.-J.: RWKV: Reinventing RNNs for the Transformer Era, *Findings of the Association for Computational Linguistics: EMNLP 2023* (Bouamor, H., Pino, J. and Bali, K., eds.), Singapore, Association for Computational Linguistics, pp. 14048–14077 (online), DOI: 10.18653/v1/2023.findings-emnlp.936 (2023).
- [25] Chaudhary, S.: Code Alpaca: An Instruction-following LLaMA Model Trained on Code Generation Instructions, <https://github.com/sahil280114/codealpaca> (2023).
- [26] LMSYS Org: FastChat: An Open Platform for Training, Serving, and Evaluating Large Language Model Based Chatbots, <https://github.com/lm-sys/FastChat> (2023).
- [27] Biderman, S., Schoelkopf, H., Anthony, Q., Bradley, H., O'Brien, K., Hallahan, E., Khan, M. A., Purohit, S., Prashanth, U. S., Raff, E., Skowron, A., Sutawika, L. and Van Der Wal, O.: Pythia: a suite for analyzing large language models across training and scaling, *Proceedings of the 40th International Conference on Machine Learning*, ICML'23, JMLR.org (2023).
- [28] Wang, Y., Ivison, H., Dasigi, P., Hessel, J., Khot, T., Chandu, K. R., Wadden, D., MacMillan, K., Smith, N. A., Beltagy, I. and Hajishirzi, H.: How far can camels go? exploring the state of instruction tuning on open resources, *Proceedings of the 37th International Conference on Neural Information Processing Systems*, NIPS '23, Red Hook, NY, USA, Curran Associates Inc. (2023).
- [29] Taori, R., Gulrajani, I., Zhang, T., Dubois, Y., Li, X., Guestrin, C., Liang, P. and Hashimoto, T. B.: Stanford Alpaca: An Instruction-following LLaMA model, [https://github.com/tatsu-lab/stanford\\_alpaca](https://github.com/tatsu-lab/stanford_alpaca) (2023).
- [30] Clark, P., Cowhey, I., Etzioni, O., Khot, T., Sabharwal, A., Schoenick, C. and Tafjord, O.: Think you have

- Solved Question Answering? Try ARC, the AI2 Reasoning Challenge, arXiv:1803.05457, <https://arxiv.org/abs/1803.05457> (2018).
- [31] Welbl, J., Liu, N. F. and Gardner, M.: Crowdsourcing Multiple Choice Science Questions, *Proceedings of the 3rd Workshop on Noisy User-generated Text* (Derczynski, L., Xu, W., Ritter, A. and Baldwin, T., eds.), Copenhagen, Denmark, Association for Computational Linguistics, pp. 94–106 (online), DOI: 10.18653/v1/W17-4413 (2017).
- [32] Merity, S., Xiong, C., Bradbury, J. and Socher, R.: Pointer Sentinel Mixture Models, *International Conference on Learning Representations*, (online), available from (<https://openreview.net/forum?id=Byj72udxe>) (2017).
- [33] Smith, D., Mannering, H. and Marcu, A.: Functional Alignment Can Mislead: Examining Model Stitching, *Proceedings of the 42nd International Conference on Machine Learning* (Singh, A., Fazel, M., Hsu, D., Lacoste-Julien, S., Berkenkamp, F., Maharaj, T., Wagstaff, K. and Zhu, J., eds.), Proceedings of Machine Learning Research, Vol. 267, PMLR, pp. 55972–55998 (online), available from (<https://proceedings.mlr.press/v267/smith25a.html>) (2025).
- [34] Balogh, A. and Jelasity, M.: How Not to Stitch Representations to Measure Similarity: Task Loss Matching Versus Direct Matching, *Proceedings of the AAAI Conference on Artificial Intelligence*, Vol. 39, No. 15, pp. 15472–15480 (online), DOI: 10.1609/aaai.v39i15.33698 (2025).
- [35] Zhang, P. and Xin, J.: A Negative Result on Cross-Model Activation Transfer in a Pythia Multi-Hop Setting, arXiv:2606.03280, <https://arxiv.org/abs/2606.03280> (2026).