

NinaXander：共有潜在表現による異種モデル族の凍結言語モデル合成——成立条件と限界

樹神 宇徳*, 林 俊一郎*, 椋木 大地†, 星野 哲也†, 片桐 孝洋†

* 名古屋大学大学院情報学研究科

† 名古屋大学情報基盤センター

Abstract—NinaXander は、異なる事前学習システムの凍結層を、共有潜在アダプタを介して接続する言語モデルである。本研究では、RWKV-4-Raven-7B (再帰型) と Tulu-Pythia-6.9b (Transformer 型) を対象に、対応層間の表現が比較的軽量なアダプタで接続可能か、またその接続がモデルの言語性能にどのような影響を与えるかを検証する。主な結果は四つである。(i) 同一トークナイザ・幅・層数・学習領域という条件下で、中心化潜在相関 $\rho_{ctr}=0.901$ を得た。行対応をシャッフルすると整合は消失する一方、生表現の CKA は同一層で最大にならず、WikiText への領域シフトでも性能が大きく低下する。したがって、本結果が示すのは一般的な意味空間ではなく、好条件下で学習可能なトークン対応表現である。(ii) 四経路の読み出しは RWKV 自己再構成 / RWKV→Pythia / Pythia 自己再構成 / Pythia→RWKV の順に 0.695/0.559/0.711/0.590 であり、本手法は圧縮工程を用いていないが再構成誤差が残る。(iii) 最良直接アフィン写像は RWKV→Pythia / Pythia→RWKV で 0.487/0.535 に達する一方、学習済みアダプタ出力の 13.4%/12.0% はアフィン写像で説明できない。同一アダプタの非線形性を無効化すると両横断読み出しは負の R^2 まで崩れる。(iv) 単一境界で合成したキメラは構文的に妥当な生成と多肢選択の遂行が可能だが、強い親モデルには届かない。Pythia→RWKV は深い境界の正答率が同層の RWKV→Pythia より 8.9–18.8 点高く、Pythia 前段→RWKV 後段の Pythia→RWKV ($L=4$) は Transformer を 5 層だけ残して KV を 84.4% 削減しつつ、ARC-Easy 62.2%, SciQ 69.2% を保つ。ただし RWKV を有意には上回らず、この $L=4$ の選択も同じ二つのテスト集合上の事後選択である。また領域外 WikiText への汎化には大きな課題が残る。

I. はじめに

大規模な事前学習に投じた計算資源は、特定のアーキテクチャに固定された重みとして残る。推論時の特性を変えたいとき——たとえば文脈長に比例して増える KV キャッシュを減らしたいとき——通常はハイブリッドを新たに事前学習するか、既存モデルから系列混合の重みを蒸留し直すことになる。いずれも学習をやり直す点で、すでに投じた計算を部品として再利用してはいない。

既存の手法はこの制約を共有している。from-scratch のハイブリッドは全体を事前学習し、変換・蒸留の系統は新しい系列混合の重みを学習する。凍結したモデル同士を接合する研究も現れているが、両側が同一系統の Transformer に限られる。重み空間のマージは互換な重みを前提とする。完成済みの凍結チェックポイントを、系統をまたいだまま部品として組み替える経路は空いたままである。

本研究が検証するのはこの構想である。独立に学習された異種モデルの中間表現を相互に変換できれば、既存モデルは凍結された再利用可能な部品になる。アダプタを一度学習すれば多数の接続位置が同時に使えるようになり、精度と推論メモリのトレードオフを、大規模な再学習なしに事後的に探索できる。実際に本研究は単一のアダプタから

8 通りの構成 (4 切替位置 $\times$ 2 方向) を取り出し、その非支配集合を求めている。

その第一歩として、本研究は NinaXander¹——異なる系統の凍結ブロックを単一の学習済みアダプタで接続するキメラモデル——を構築し、同一トークナイザ・同一幅・同一層数という好条件下の RWKV-4-Raven-7B と Tulu-Pythia-6.9b を対象に、三つの問いを検証する。系統をまたぐ合成は成立するか。接続位置によって機能と KV 量はどう変わるか。何が接続を律速するか。

結果は競争力のある新モデルではない。強い親モデルはどの構成でも超えない。示されるのは、凍結資産の事後的な再構成が部分的に可能であること、そして整合・復号・領域シフトがその障害になることである。具体的な利得は、Transformer を 5 層だけ残して KV を 84.4% 削減しつつ多肢選択の正答率の一部を保つ構成が存在することである。本研究の貢献は、(i) 共通モードを除いた整合測定、(ii) RWKV 自己再構成 / RWKV→Pythia / Pythia 自己再構成 / Pythia→RWKV の四経路を比較する対照実験、(iii) RWKV→Pythia / Pythia→RWKV の両方でアダプタの非線形性を測る同一写像内の介入実験、(iv) 単一境界でのキメラモデル RWKV→Pythia / Pythia→RWKV における精度・メモリ・領域汎化と経路非対称性の実測である。

II. 背景と関連研究

a) 残差ストリームと合成の形式.: 自己回帰言語モデルは、位置ごとの表現を残差ストリームとして層で更新する。幅 d のモデルのブロック ℓ は $h^{(\ell+1)} = h^{(\ell)} + f_\ell(h^{(\ell)})$ の形をとり、 f_ℓ が系列混合とチャンネル混合を担う。深さ境界 L での合成とは、一方のモデルでブロック 0 から L まで走らせて得た $h^{(L+1)}$ を、他方のモデルのブロック $L+1$ の入力として与えることをいう。幅と層数が一致していても、 $h^{(L+1)}$ はそれぞれの学習が定めた座標系にあり、一方の値をそのまま渡しても後段の重みが期待する分布とは一致しない。合成の可否は、したがって二つの系統の残差が相互に変換可能かという問いに帰着する。

b) 推論費用の非対称性.: 二つの系統は推論時の費用の増え方が異なる。softmax 注意を持つ層は過去のトークンすべての key と value を保持するため、文脈長 T に対して $O(T)$ のキャッシュを要する。線形注意や等価な再帰形式で実行できる層は固定サイズの状態のみを持ち越すため $O(1)$ である。この非対称性が、本研究で合成が意味を持つ理由である。前段と後段のどちらに再帰型を置くかで残る

¹NinaXander は『鋼の錬金術師』のキメラに由来する。合成は成立するが合成元には及ばない、という対応による。

Transformer 層数が変わり、保持すべきキャッシュ量も変わるからである。

c) 残差の尺度.: 残差の尺度は層ごとに異なり、系統間でも揃わない。したがって層をまたいで残差を比較するにも、境界で受け渡すにも、層ごとに推定した統計で標準化する必要がある。本研究がアダプタの入出力に層別の標準化と逆標準化を挟むのはこのためである (§III)。

d) モデル・スティッチング.: 凍結した 2 モデルの層を学習可能な接合層でつなぐ手法は、表現の**等価性**を測るために Lenc と Vedaldi [1] が導入した。彼らは線形の接合層で一方の下層と他方の上層を接いだ「Franken-CNN」を元の課題損失で評価し、学習データの異なるネットワーク間 (ImageNet と MIT Places) にも、異なるアーキテクチャ間 (AlexNet, VGG-16, ResNet-50) にも適用している。Bansal ら [2] は表現比較のプロープとして再訪し、同一アーキテクチャ間で乱数種・学習量・幅・目的関数 (教師ありと自己教師あり) を変えて接合する一方、異種アーキテクチャ間の接合は難点として残した。Csiszárík ら [3] は単一のアフィン接合層によって二つの学習済みネットワークの中間表現を対応付け、その一致を表現空間上の類似度だけでなく、接合後ネットワークのタスク性能という機能的観点から評価する枠組みを提案した。さらに、既存の表現類似度指標がタスク性能を必ずしも反映しないことを示した。本研究が整合と復号可能性を分けて評価するのは、この立場に沿う。いずれも視覚モデルであり、本研究は異なる**系統** (RNN $\leftrightarrow$ Transformer) を各層で 1 度だけ翻訳する共有潜在で接合する点で異なる。

e) 凍結 LLM の合成.: 近年は凍結した LLM どうしを学習可能な接続で合成する研究が続いている。StitchLLM [4] は規模の異なる Transformer のブロックを stitching 層で接いで serving 時に経路を選び、BTS [5] は同一シードから分岐した凍結専門家群と凍結シードの間で、Experts-into-Hub と Hub-into-Experts の stitch 層を数層おきに交互に挿入して隠れ状態を**双方向**に交換する。CALM [6] は凍結した 2 つの Transformer の中間表現を cross-attention で融合し、Manticore [7] は Transformer と Mamba のブロック列を射影付きで**並列に実行**し、学習された凸結合で混ぜたハイブリッドを end-to-end に微調整する (埋め込みと LM ヘッドは新規初期化される)。凍結モデル間で活性そのものを翻訳する研究も現れている。Moschella ら [8] は固定アンカーへの相対表現によって独立に学習された潜在空間を隔てる変換を吸収し、翻訳器を学習せずに接合できることを示した。Maiorca ら [9] は少数の意味的対応から二つの潜在空間の間の写像を閉形式で推定する。表 III のアフィン対照はこうした低容量の直接写像に対応する基準であり (ただし本研究の対照は対応残差を教師として直接適合するため、zero-shot の相対表現より強い条件にある)、RWKV $\rightarrow$ Pythia ではアダプタが 8-23 点上回る一方、Pythia $\rightarrow$ RWKV では差が小さく SciQ @8 では逆転する。Model Alignment Search [10] は凍結した再帰型ネットワークと凍結 Transformer の間で活性を双方向に写像するが、表現の類似度を測る手法であって合成モデルを構築しない。Chen ら [11] は凍結した 2 つの言語モデルの残差ストリームを単一層で双方向にアフィン写像し、一方の前段と他方の後段をつないだ合成モデルの次トークン交差エントロピーまで評価する。ただし対象は同一系統・同一トークナイザの Transformer 対に限られ、著

者自身が異種系統での検証を今後の課題として挙げている。プレプリントの Bicameral Model [12] は凍結した 2 つの言語モデルを双方向の翻訳網で結合するが、各モデルが自身の全段を実行したまま並列に走る。同じくプレプリントの GoldFinch [13] は RWKV-6 の上に Transformer を積む単一境界の構成で KV キャッシュを 756-2550 倍圧縮するが、事前学習済みの親を組み合わせたのではなくスクラッチから学習する。Oozeer ら [14] は異なる系統の凍結 LLM の間で活性の写像を学習し、安全性介入やステアリングベクトルを転送する。アフィン対照を併記する点も含めて本研究に近いが、単一層での転送に留まり、モデルを合成して走らせることはしない。ただし、これらは両側が Transformer であるか、合成体を微調整するか (Manticore)、事前学習済みの親の一つしか持たない。単一境界・双方向・親凍結という接合機構それ自体は、Chen ら [11] が同一系統・同一トークナイザの Transformer 対で既に確立しており、本研究はその機構の新規性を主張しない。本研究が扱うのは、彼らが未解決として残した**異種系統**の場合である。両モデルは事前学習コーパスとして The Pile を共有するが、その上位では共有しない。アーキテクチャは無関係であり、深さの意味的な対応も整合すべき注意状態も存在せず、指示チューニングの混合データもプロンプト形式も異なる (重複するのは ShareGPT と Code-Alpaca のみである)。この条件で、線形注意の再帰モデルと Transformer の間に同じ接合が成立するかが問いである。なお共有コーパスは交絡をむしろ除く。両モデルが異なる分布を見たから接合が難しい、という説明が使えなくなるからである。我々の知る限り、この二系統を両親と LM ヘッドを凍結したまま単一境界で合成し、動作する生成器として評価した研究はない。あわせて、その合成が Transformer の KV キャッシュに与える削減量を報告する。

f) 表現類似度.: CKA [15] や (SV/PW)CCA [16], [17] はネットワーク間の表現類似度を測る標準的な道具である。本研究はこれらを補助指標として用いつつ (§IV-A の全層対応)、主眼を**再構成を介した機能的な接合**に置く。系統をまたぐ表現の普遍性については、Wang ら [18] が Transformer と Mamba の間で疎自己符号器の特徴と誘導回路が概ね類似することを報告しており、先行する証拠を与える (ただし対象は Mamba であって RWKV ではない)。

g) モデルマージ・知識統合.: 重み空間でモデルを統合する model soups [19], TIES [20], 進化的マージ [21] は、**同一または互換な重み**を前提とする。出力分布を融合する FuseLLM [22] は重みの互換を要しないが、語彙間のトークン整列と対象モデルの継続学習を必要とする。本研究は重みを一切マージせず**活性化空間**を翻訳して凍結ブロックを組み替える点で相補的である。

h) 対象モデル.: RWKV [23] は softmax 内積注意をチャネル方向の線形注意 (WKV 作用素) に置き換えたアーキテクチャで、等価な再帰形式でも実行できるため、推論時には文脈長とともに伸びる KV キャッシュではなく層あたり定数サイズの状態を持つ。本研究ではその第 4 世代の指示追従版 RWKV-4-Raven-7B を用いる。Pythia [24] とその Tulu SFT [25] 版は Transformer である。

III. 手法

対象は、同じ層数 (32)・同じ幅 ($d=4096$)・同じ GPT-NeoX トークナイザを共有する指示追従モデルとして選んだ RWKV-4-Raven-7B と Tulu-Pythia-6.9b である。トークナイザの共有が位置対応した残差ペアを可能にし、層数と幅の一致が層の対応付けを自明にする。これは合成に有利な条件を意図して揃えたものであり、同時に主張の射程を狭める選択でもある (§VI)。

a) 残差ペア.: トークナイザを共有する凍結 A, B に同一テキストを与え、位置 t ・ブロック j の出力 $r_A^j[t]$ と $r_B^j[t]$ を対応づけ、両系統・全 32 層を同種の量として扱う (取得実装の詳細は付録 A)。

b) 共有潜在アダプタ.: 各モデルに符号器・復号器を 1 組ずつ置き、全層に共通する**単一**の潜在 z へ写す：

$$z_A = \text{LN}(E_A(r_A)), \quad z_B = \text{LN}(E_B(r_B)), \\ \mathcal{L} = \|D_A(z_A + \xi_A) - r_A\|^2 + \|D_B(z_B + \xi_B) - r_B\|^2 \\ + \lambda \|z_A - z_B\|^2.$$

$\xi_A, \xi_B \sim \mathcal{N}(0, \sigma^2 I)$ (枝ごとに独立にサンプルする), $\lambda=1$, LN は非アフィン, σ は 0.4 とした。 E, D は浅い残差 MLP。横断写像 $A \rightarrow B := D_B(z_A) = D_B(\text{LN}(E_A(r_A)))$ と $B \rightarrow A := D_A(z_B) = D_A(\text{LN}(E_B(r_B)))$ のいずれにも横断的な教師目標を与えない。すなわち r_A は B の再構成損失に、 r_B は A の再構成損失に現れないよう学習するが、横断写像が「教師なし」で得られると主張するものではない。本論文が検証するのは**単純な変換**で空間が揃うことなので、表現力の大きい重いアダプタは用いず、写像の深さを残差ブロック 1 個に制限し、パラメータ数と RWKV→Pythia / Pythia→RWKV の線形対照を併記する (§IV-C)。

c) アダプタの構造.: E_A, E_B, D_A, D_B は同形：潜在幅への線形射影, b 個の pre-norm 残差ブロック, 出力への線形射影。報告する構成は $z=d=4096$, $b=1$, 内部幅 $h=4096$ である。各残差ブロックの第 2 行列は**ゼロ初期化**なので、初期状態で各ブロックは恒等写像であり、 E と D は**線形写像から学習を始める** (両者の間に非アフィン LN が入るため、横断写像全体は初期状態でも線形ではない)。ただしこれは初期化の性質であって学習後の性質ではない：§IV-C で測るように、収束後の写像は RWKV→Pythia / Pythia→RWKV の出力分散の 13.4%/12.0% が非線形であり、同じ非線形枝が両横断読み出しを担う。親モデルの合計 14.2B パラメータに対し、アダプタは 268.5M (1.9%) である。本論文で主張する軽量とは絶対的な小ささではなく、親モデルに対する相対量と低い層の深度を指す。

ノイズ ξ は、潜在がトークン非依存の定数 (**共通モード**) だけで整合項を満たしてしまうことを抑えるために置く。定数はノイズを回避できない、というのが設計上の根拠である。 $\sigma=0.4$ は固定して用い、 σ のアブレーションは本論文では取り扱わないため、この効果そのものは検証していない。

d) 4 経路の名称とキメラ.: 数式では A を RWKV, B を Tulu-Pythia と置くが、分かりやすさのため本文と図表では二文字コードを使わず、前段と後段を明示する。四経路は RWKV 自己再構成, RWKV→Pythia, Pythia 自己再構成, Pythia→RWKV である。RWKV→Pythia と Pythia→RWKV は系統横断キメラ, RWKV 自己再構成と Pythia 自己再構成 は同じ境界・アダプタを通る自系

統再構成対照である。切替層 L は前段親が最後に実行するブロックの添字 (0 始まり) であって、実行する層数ではない——ブロック 0 を含むため前段は $L+1$ 個になる。RWKV→Pythia では、 A の最初の $L+1$ ブロック (ブロック 0 から L) を走らせ、残差を**一度だけ** B 空間へ翻訳する： $h_B = \text{unstd}_B(D_B(\text{LN}(E_A(\text{std}_A(h_A))))))$ 。続いて B の残り $31-L$ ブロック ($L+1$ 以降) と言語モデルヘッドを走らせる。Pythia→RWKV も同じ学習済みアダプタで別個に評価し、 $h_A = \text{unstd}_A(D_A(\text{LN}(E_B(\text{std}_B(h_B))))))$ を RWKV ブロック $L+1$ の入力へ挿入する。いずれも合計は 32 ブロック、内訳は $L+1$ と $31-L$ であり、翻訳は 1 回だけである。

e) 評価指標.: 未学習の文章に対する決定係数 R^2 (層内の全トークン・全次元をプールし、SST は次元ごとに中心化) を、系統をまたぐ写像 ($A \rightarrow B, B \rightarrow A$) と自系統の写像 ($A \rightarrow A, B \rightarrow B$) の双方について測る。潜在の整合は**中心化**相関 ρ_{ctr} で測り、あわせてトークンごとに変動する成分の割合 f を報告する。両者は整合項と $2f(1-\rho_{\text{ctr}})$ の関係で結ばれる (指標の厳密な定義は付録 B)。各指標は層ごとに全トークン上で算出し、32 層にわたる単純平均を報告する。キメラについては、英語プロンプトを原文どおり与え、温度 0 の決定的 argmax (最大 40 新規トークン, EOS 出力時のみ早期終了) による生成例、多肢選択の正答率、および次トークン交差エントロピーで評価する。

IV. 結果

以下では、表現のレベルから下流の機能まで順に測る。§IV-A で対応層間の整合を、§IV-B で横断読み出しと自系統再構成の関係を、§IV-C でアダプタの非線形性を扱い、§IV-D と §IV-E で合成したキメラの生成・正答率・推論メモリを評価する。

A. 対応層間には学習可能な共通表現がある

§III の条件を満たす 7B 指示追従モデルのペアを、指示形式テキスト (Alpaca [26]) で整合させると、残差ブロック 1 個のアダプタが未学習の文章における中心化潜在相関 $\rho_{\text{ctr}}=0.901$ に達する。本論文では中心化相関 0.901 と、各復号器が自系統の残差を再構成できること ($A \rightarrow A$ 0.70, $B \rightarrow B$ 0.71) を併せて、共通表現の根拠として主張する。また、各横断課題へ直接あてはめた最良の**線形**写像だけでも $A \rightarrow B$ 0.487, $B \rightarrow A$ 0.535 に届く (§IV-C)。したがって、観測された予測可能性の大部分は深い非線形写像の表現力だけでは説明できない。ただし**同一層ペアが内在的に特別なわけではない**：アダプタを介さない生の残差どうしを全 32×32 層で比べると (図 2)、線形 CKA は総じて弱く (対角平均 0.05 対 非対角平均 0.03), A の層 j が B の層 j に最も似るのは 32 行中 2 行にすぎない (最類似は層 0 が 14 行、最終層が 12 行を占める)。直接の線形回帰しやすさでも同一層は特別ではない：同じ全層ペアへ層別の線形写像をあてはめると、適合 R^2 は対角平均 0.87 対 非対角平均 0.84 であり、同番号層が最良となるのは 32 行中 3 行にすぎない。ゆえに $\rho_{\text{ctr}}=0.901$ は**選んだ同一層ペア上で学習して回復した**整合であって、層番号どうしに固有の対応ではない。本論文は任意の層ペアに存在する回帰可能性の上に、同一層という選択をしたケーススタディであると位置づける。




Fig. 1. 共有潜在アダプタ。各凍結モデルの残差を単一の潜在 z (非アフィン LayerNorm) に符号化し、自系統へ復号する (実線の経路にて再構成と整合項 $\lambda \|z_A - z_B\|^2$ が損失関数となり学習が行われる)。ガウスノイズ $\xi_A, \xi_B \sim \mathcal{N}(0, \sigma^2)$ (独立) は復号の直前にのみ z へ加わり、整合項には乗らない。実線の $A \rightarrow A$ (RWKV 自己再構成) と $B \rightarrow B$ (Pythia 自己再構成) は自系統再構成、破線の $A \rightarrow B$ (RWKV $\rightarrow$ Pythia) と $B \rightarrow A$ (Pythia $\rightarrow$ RWKV) は横断読み出しである。後二者は横断目標に一度も適合されず、整合項が $z_A \approx z_B$ を作って初めて成立する。




Fig. 2. 生残差の全 32×32 層対応。左: 線形 CKA は総じて弱く、高い値は層 0 の行・列と最終層の角に集中する——対角 (破線) は特別でない。右: 同じ各ペアへ層別の線形写像をあてはめた適合 R^2 は 0.62–0.94 とほぼ全ペアで高い。二つのパネルの色スケールは異なる。

整合が学習可能であることは確認できるが、その射程はこの意味でも限定的である (§V)。

以降の数値はすべて、同一構成の単一の学習から得たものである。潜在の幅は $z=d=4096$, 32 ブロックすべてを対応付け、アダプタは 268.5M パラメータ, $\sigma=0.4$, 学習率は 10^{-3} から plateau 方式で下限 10^{-5} まで下げた。学習信号は Alpaca 学習分割の 2,075 窓 (各 112 トークン, 独立トークン位置 $\approx 232k$) から取った残差で、32 層で 7.44M ペアを成し、このペア集合を約 228 回反復した。報告値は、保留 $A \rightarrow B$ が最良となる最深点 (415,000 反復) のチェックポイントのものである。Pythia $\rightarrow$ RWKV の系統横断写像は $B \rightarrow A$ 0.590 で、わずかに $A \rightarrow B$ 0.559 を上回る (RNN 側の残差の方が Transformer 潜在から復元しやすい)。両者とも自系統再構成 ($A \rightarrow A$ 0.695, $B \rightarrow B$ 0.711) を下回っており、系統横断が整合ではなく復号で律速されることを裏づける。これらの整合・読み出しがトークンごとの真の対応であって分布の重なりではないことは、負の対照で確かめた: A の行順を保ったまま B の残差行を単一の乱数置換で入れ替えて再対応させると、 ρ_{ctr} は $0.901 \rightarrow 0.000$, $A \rightarrow B$ は $0.561 \rightarrow -0.592$, $B \rightarrow A$ は $0.592 \rightarrow -0.609$ へ崩壊する (自系統写像 $A \rightarrow A$, $B \rightarrow B$ は構成上不变)。すなわち両方向の読み出しとも、正しいトークン対応なしには

得られない。

潜在のうちトークンごとに変動する成分の割合 $f = \|z - \bar{z}\|^2 / \|z\|^2$ を導入する。要素ごとの係数を持たない層正規化のもとで、生の相関は $\rho_{\text{raw}} = (1 - f) + f \rho_{\text{ctr}}$, すなわち $\text{align} = 2f(1 - \rho_{\text{ctr}})$ と分解される。ここで報告する f は A, B それぞれの変動割合の平均であり、この形が等式として成り立つのは両者が等しく、かつ両者の共通モードが平行な場合である。実測では、学習が進んだ後の評価点でこの関係は 3×10^{-4} 程度の精度で成り立つ。ただし学習初期には成り立たず、0 反復目では残差が 6.6×10^{-2} に達する。等式が示すのは生の相関が中心化された相関と定数項の影響を含むということである。そのうち $1 - f$ の割合は、情報を持たない定数項として与えられる。最深点の f は 0.350 であるから、**潜在の持つエネルギーの 65% はトークンに依存しない定数**であり、生の相関はその定数に支配される。実際、中心化した ρ_{ctr} が 0.901 であるのに対し生の相関は 0.965 を示し、等式はこれを $(1 - 0.350) + 0.350 \times 0.901 = 0.965$ と過不足なく再現する。

a) f が示すこと、示さないこと。: f は二次モーメントであって情報量ではなく、そこから引ける推論は一方にに限られる。 $f \rightarrow 0$ は潜在が定数に崩壊したことを証明し、したがってトークンごとの情報を一切持たないことを示す。 f が大きいことが意味するのは、トークンごとの潜在が角度方向に散らばっていることだけであり、係数を持たない層正規化のもとで f は倍率に対して厳密に不変である。散らばりは意味のある変動からも無意味な変動からも等しく生じる。変動する成分が情報を担っていると言えるのは、 f ではなく読み出しの側である。読み出しは中心化 R^2 であり、トークンに依存しない予測器は 0 を超えられない (最良の定数がちょうど 0 点)。ゆえに $B \rightarrow B = 0.711$ はいかなる定数からも得られず、潜在のエネルギーの 65% が定数であることと矛盾しない。

B. 両横断読み出しは自系統再構成に制約される

測定した五つの診断値を図 3 に示す。

$$\begin{aligned} \rho_{\text{ctr}} &= 0.901, \\ R^2(B \rightarrow B) &= 0.711, \quad R^2(A \rightarrow B) = 0.559, \\ R^2(A \rightarrow A) &= 0.695, \quad R^2(B \rightarrow A) = 0.590. \end{aligned}$$

ρ_{ctr} は相関係数、後四者は決定係数であり、両者を同じ尺度の量として比較することはできない。本節の結論は、 R^2 同士では全 32 層で $A \rightarrow B \leq B \rightarrow B$ かつ $B \rightarrow A \leq A \rightarrow A$ であること、および §IV-E の自己符号器対照で復号のみの損失が下流性能にも現れることに基づく。

高い潜在相関は、高い再構成精度を保証しない。RWKV $\rightarrow$ Pythia は同一の復号器 D_B を通る Pythia 自己再構成 と、Pythia $\rightarrow$ RWKV は同一の復号器 D_A を通る RWKV 自己再構成 と比較でき、入力が自系統潜在か他系統潜在かだけが異なる。両不等式は経験的な観測であって定理ではないが、いずれの方向でも自己再構成の段階ですでに相当の誤差があり、系統横断だけを改善してもその誤差は残る。

$z=d=4096$ では合成画像 $D \circ E$ は恒等画像を表現でき、階数による制約は存在しない。それでも $B \rightarrow B$ は 0.711 に留まる。これがノイズ σ が定める天井なのかは不明であり、何が律速となっているかは未解決問題として残っている。

C. アダプタは両横断経路で非線形である

アダプタは 2 つの線形画像に挟まれたゼロ初期化の残差ブロック 1 個であり、 E と D は線形画像から学習を始める。だがそれは学習前の性質であって、415,000 反復後の性質ではない。最深点のアダプタが実際どれだけ線形かを、RWKV $\rightarrow$ Pythia / Pythia $\rightarrow$ RWKV と同じ代表 5 層、同じあてはめ行・保留行で測った。

アダプタ自身の出力を模倣する最良のアフィン画像が説明する出力分散は、RWKV $\rightarrow$ Pythia で 86.6%、Pythia $\rightarrow$ RWKV で 88.0% である。したがって残る 13.4% / 12.0% はいかなるアフィン画像でも表現できない。学習後の画像は両経路で明確に非線形である。

比較対象はアダプタを近似したものではなく、層ごとに各経路の標準化した入力残差から標準化した出力残差への最良のアフィン画像を、リッジ付き最小二乗で別々に直接あてはめた対照である。代表 5 層 {4, 10, 16, 22, 28} の保留行で評価すると、最良直接アフィン画像は RWKV $\rightarrow$ Pythia 0.487, Pythia $\rightarrow$ RWKV 0.535 に達する。対応するアダプタは同じ行で RWKV $\rightarrow$ Pythia 0.558, Pythia $\rightarrow$ RWKV 0.576 であり、非線形画像の増分は +0.071 / +0.041 である。低容量のアフィン画像でも両経路で相当な系統横断予測ができるため、共有表現の主張はこの線形到達性で担保される。

別途適合したアフィン対照。この対照は切替層ごとに、Alpaca のうちアダプタの学習に用いていない保留領域から取った 40,096 行の標準化残差へ、切片つきリッジ回帰 (10^{-3}) で適合したものである。表 III では、RWKV $\rightarrow$ Pythia のアダプタを直接アフィン画像へ置き換えると正答率が 8–23 点崩れる。一方 Pythia $\rightarrow$ RWKV では差が小さく、SciQ @8 ではアフィン対照の方が 3.4 点高い。これは経路差として重要だが、二つの画像は学習目的・データ・正則化が異なるため、非線形性の因果効果とはみなさない。

交絡を抑えた介入：同一アダプタの MLP 枝を無効化する。そこで、同一の学習済みアダプタの残差ブロック（唯一の学習非線形性 $\text{fc}_2(\text{GELU}(\text{fc}_1(\cdot)))$ ）だけを係数 α でスケールする ($\alpha=1$ 完全, $\alpha=0$ は枝を外した同一画像)。表現 R^2 の $\alpha = 0, .25, .5, .75, 1$ 掃引は、RWKV $\rightarrow$ Pythia で $-0.41, -0.75, 0.35, 0.52, 0.56$, Pythia $\rightarrow$ RWKV で $-0.30, -0.66, 0.36, 0.53, 0.58$ となる。

両経路で枝を外すと負の R^2 まで崩れ、しかも非単調である。二つの線形層は残差ブロックと協調して学習されており、この学習済みアダプタでは、非線形枝は RWKV $\rightarrow$ Pythia だけでなく Pythia $\rightarrow$ RWKV の読み出しにも除去不能である。これは学習済み画像の性質であって、本論文が同目的で学習した線形アダプタとの比較は行っていないことに注意が必要である。多肢選択でも同じ $\alpha = 0/1$ を同一問題上でペーア化して評価する。

TABLE I

同一アダプタの非線形枝を無効化したときの長さ正規化正答率 (%)。各セルは $\alpha: 1 \rightarrow 0$ (完全な学習済み画像 $\rightarrow$ 同じ画像から枝のみ除去) を表す。ARC-Easy 2376, SciQ 1000, 当て推量 25%。

L	ARC-Easy		SciQ	
	RWKV $\rightarrow$ Pythia	Pythia $\rightarrow$ RWKV	RWKV $\rightarrow$ Pythia	Pythia $\rightarrow$ RWKV
4	59.6 $\rightarrow$ 31.9	62.2 $\rightarrow$ 31.8	70.9 $\rightarrow$ 31.3	69.2 $\rightarrow$ 32.6
8	59.0 $\rightarrow$ 29.9	57.3 $\rightarrow$ 35.5	67.7 $\rightarrow$ 31.4	64.6 $\rightarrow$ 37.0
16	48.6 $\rightarrow$ 28.5	57.5 $\rightarrow$ 43.7	54.5 $\rightarrow$ 31.7	68.0 $\rightarrow$ 47.3
24	47.0 $\rightarrow$ 34.8	59.6 $\rightarrow$ 48.4	51.1 $\rightarrow$ 40.0	69.9 $\rightarrow$ 49.1

表 I の枝効果は RWKV $\rightarrow$ Pythia で +11.1–+39.6 点, Pythia $\rightarrow$ RWKV で +11.2–+36.6 点であり、16 比較すべてで同一問題上の McNemar 正確検定 $p < 2 \times 10^{-9}$ となる。したがって、非線形枝の必要性は一方の経路から推測したものではなく、RWKV $\rightarrow$ Pythia / Pythia $\rightarrow$ RWKV の両方の表現と下流精度で直接確認される。

D. 構文的に妥当な生成は得られるが事実性は劣化する

ここで実際に 7B で両横断経路を合成する。切替層 L では、前段親をブロック 0 から L まで走らせ (合計 $L+1$ ブロック)、その残差を §III の境界式で一度だけ他方の空間へ翻訳し、後段親のブロック $L+1$ 以降と言語モデルヘッドを走らせる——ブロックごとの往復ではない。したがって RWKV $\rightarrow$ Pythia ($L=16$) は RWKV 17 ブロックと Pythia 15 ブロック、Pythia $\rightarrow$ RWKV ($L=16$) はその反対で、いずれも厳密な半分ではない。

最深点の同一アダプタを RWKV $\rightarrow$ Pythia / Pythia $\rightarrow$ RWKV とともに $L=4$ に挿入し、同じ四つの英語プロンプトを温度 0, 最大 40 新規トークンで貪欲復号した。 $L=4$ は、二課題平均が各横断方向の四境界中で最大であり、SciQ の KV-精度平面でも両方向が非支配集合に入る共通境界である (図 5)。ただしこれは同じ報告タスクを見た後の代表点選択であり、独立な生成用選択基準ではない。本比較は網羅的な生成ベンチマークではないが、両モデルの元モデル及びキメラモデルの出力を同条件で観察する。

これらのケーススタディから、RWKV $\rightarrow$ Pythia / Pythia $\rightarrow$ RWKV とともに構文的にもっともらしい出力を生成できることが観測できる。両方がフランスの首都へ正答し、三原色も正しく開始する。RWKV $\rightarrow$ Pythia はブラックホールにも一文で正答しており、指示に沿った文生成そのものは成立している。他方で、流暢さが保たれても内容や指示形式を失い得る。両方向とも水の補完を “hydrogen” と誤り、Pythia $\rightarrow$ RWKV は三原色への正答後に対話形式へ逸脱し、ブラックホールを循環的に説明する。したがって 0.559/0.590 の横断読み出しでも事実性は十分でない。より忠実なキメラには両横断読み出しと自系統再構成の改善が必要である。




Fig. 3. 共有潜在から両方向の読み出し遷移。高い中心化相関と不完全な自己再構成が共存し、RWKV→Pythia / Pythia→RWKV の横断読み出しは、それぞれ同じ復号器を使う Pythia 自己再構成 / RWKV 自己再構成 自己再構成を全層で下回る。




Fig. 4. RWKV→Pythia / Pythia→RWKV キメラの対称な構成。図中左側の親をブロック L まで実行し、残差を一度だけ翻訳して、右側の親のブロック $L+1$ 以降とヘッドへ渡す。青は RWKV-Raven、橙は Tulu-Pythia。したがって Transformer 層数は RWKV→Pythia で $31-L$ 、Pythia→RWKV で $L+1$ となる。

TABLE II

最深点アダプタの RWKV→Pythia / Pythia→RWKV による再生成結果（ともに $L=4$ ）と、両親 pure Pythia / pure RWKV の同一プロンプト出力。英語原文をそのまま入力し、temperature 0 の argmax, 最大 40 新規トークン、EOS のみ早期終了とした。四つのプロンプトに限る定性的比較であり、生成品質の定量評価ではない。

Prompt (verbatim)	pure Pythia	RWKV→Pythia 横断読み出し $R^2=0.559$	pure RWKV	Pythia→RWKV 横断読み出し $R^2=0.590$
### Instruction: What is the capital of France?	“The capital of France is Paris.”	“The capital of France is Paris.” ✓	“Paris.”	“Paris.” ✓
### Response: The three primary colors are	“red, yellow, and blue. These colors are often used in combination to create a wide variety of colors.”	“red, yellow, and blue.” ✓	“red, blue, and yellow.” と正答後、赤の反対色（緑）を問う Q&A へ逸脱	“red, blue, and yellow.” と正答後、Bob/Alice の緑についての対話へ逸脱
Question: Water is made of hydrogen and Answer:	“Hydrogen is made of hydrogen and oxygen.”	“Hydrogen.” (誤り)	“hydrogen.” (誤り)	“hydrogen.” (誤り)
### Instruction: Explain what a black hole is in one sentence. ### Response:	“A black hole is a region of spacetime where gravity is so strong that nothing, not even light, can escape its pull.”	“A black hole is a region in space where gravity is so strong that nothing, not even light, can escape its pull.” ✓	“A black hole is a region of space where the gravitational pull is so strong that nothing, not even light, can escape.”	“A black hole is a type of celestial object that is formed when a star collapses and collapses into a black hole.” (循環的)

E. 親モデルとの機能・推論メモリ比較

NinaXander の実用上の価値を評価するには、内部表現の指標だけでなく、凍結した両親との機能比較が必要である。ここでは、(i) 強い親モデルに対してどこまで性能を保てるか、(ii) 弱い親を上回るか、(iii) その代わりにどの程度 KV キャッシュを削減できるかを測る。

この比較は、各選択枝の対数尤度を求めて最大のものを選ぶ多肢選択形式で行う。生成も文字列の照合も主観的な判定も介在しないため、結果は一意に定まる。用いたのは全

評価集合 (ARC-Easy [27] test 2376, SciQ [28] test 1000), 最深点 (415,000 反復) の $z=4096$ のアダプタ、そして四つの切替位置である。同一問題集合上の構成間比較はペア化データなので、差はセルごとの独立な二項 SE ではなく **ペア化検定** (McNemar の正確検定と対応 bootstrap) で評価する。選択枝は長さが異なり総和 / 長さ正規化で順位が食い違い得るので両方を構造化データに保存し、本文は長さ正規化を報告・検定に用いる。また SciQ は付属の support 文を与えない closed-book 形式 (Question / Answer のみ)

で評価するため、本稿の SciQ 値は support を与える標準プロトコルの公表値と直接比較できない。

TABLE III

RWKV→Pythia / Pythia→RWKV の学習済みアダプタと、各経路の入力・出力残差へ別々に適合した最良アフィン対照による長さ正規化多肢選択正答率 (%、ARC-Easy 2376, SciQ 1000, 当て推量 25)。各値は同じ問題、同じ切替層、同じ後段実行を用いる。

L	ARC-Easy				SciQ			
	adapter	affine	adapter	affine	adapter	affine	adapter	affine
4	59.6	41.9	62.2	60.2	70.9	47.5	69.2	69.6
8	59.0	43.1	57.3	56.0	67.7	49.1	64.6	68.0
16	48.6	34.8	57.5	57.5	54.5	35.9	68.0	69.6
24	47.0	39.4	59.6	59.2	51.1	42.7	69.9	68.2

TABLE IV

4 経路の長さ正規化正答率 (%). RWKV 自己再構成 / Pythia 自己再構成 は自系統再構成対照, RWKV→Pythia / Pythia→RWKV は系統横断キメラ。同じ問題・切替層の二つの横断経路差はペア化して検定した。

L	RWKV 自己再構成		RWKV→Pythia		Pythia 自己再構成		Pythia→RWKV	
	ARC	SciQ	ARC	SciQ	ARC	SciQ	ARC	SciQ
4	62.8	68.5	59.6	70.9	62.2	74.8	62.2	69.2
8	59.8	66.7	59.0	67.7	62.7	74.8	57.3	64.6
16	54.8	59.8	48.6	54.5	57.4	71.1	57.5	68.0
24	52.2	57.9	47.0	51.1	59.4	70.1	59.6	69.9

四経路の同時比較から六つのことが読み取れる。(a) 7B の半分が外来であっても、RWKV→Pythia / Pythia→RWKV とも実際に問いへ答えられる。全横断構成が当て推量を大きく上回り、SciQ では RWKV→Pythia 70.9%, Pythia→RWKV 69.9% に達する。(b) 深さ効果は経路依存である。RWKV→Pythia は $L = 4 \rightarrow 24$ で SciQ $70.9 \rightarrow 67.7 \rightarrow 54.5 \rightarrow 51.1$, ARC-Easy $59.6 \rightarrow 59.0 \rightarrow 48.6 \rightarrow 47.0$ と単調に下がるが、Pythia→RWKV は SciQ $69.2 \rightarrow 64.6 \rightarrow 68.0 \rightarrow 69.9$, ARC-Easy $62.2 \rightarrow 57.3 \rightarrow 57.5 \rightarrow 59.6$ と非単調である。局所読み出しは同じ四層で RWKV→Pythia 0.570/0.555/0.575/0.567, Pythia→RWKV 0.552/0.517/0.604/0.608 であり、接続する層や R^2 だけから順位は決定できない。(c) 強いほうの親はどちらの経路でも超えられない。全 8 横断構成が両タスクで Tulu-Pythia を下回り、各同一問題の McNemar 検定でも有意である。(d) RWKV に対する差も経路・課題依存である。RWKV→Pythia ($L=4$) は SciQ で RWKV を +3.9 点 ($p=0.018$) 上回る一方、ARC-Easy では -2.2 点 ($p=0.042$) である。ただし総和スコアではこの優位は消える (RWKV→Pythia ($L=4$) は SciQ -2.7 点, Pythia→RWKV ($L=4$) は ARC -4.6 点 / SciQ -5.7 点) — 弱い親に対する優劣の判定は長さ正規化の選択に依存する。Pythia→RWKV はいずれの境界も RWKV を有意に上回らず、Pythia→RWKV ($L=4$) は ARC +0.4 点 ($p=0.66$), SciQ +2.2 点 ($p=0.14$) で統計的に同等である。(e) 別途適合したアフィン対照の差も経路依存である。RWKV→Pythia ではアダプタが全セルで 8–23 点高いが、Pythia→RWKV では差が小さく、SciQ @8 ではアフィンが 3.4 点高い。すなわち、学習済みアダプタがつねにアフィン写像を上回るわけではない。(f) 自系統対照との差は翻訳誤差だけではない。B 後段では純 Pythia, Pythia 自

己再構成, RWKV→Pythia の順に下がり、Pythia 自己再構成 - RWKV→Pythia 差は SciQ 4–19 点, ARC 3–12 点である。一方 A 後段では Pythia→RWKV が RWKV 自己再構成を深い境界で逆に上回り、 $L = 16/24$ の差は ARC +2.7/+7.4 点, SciQ +8.2/+12.0 点となる。自系統対照は復号段を切り分けるが、横断との差には前段親の能力と翻訳のずれがともに入るため、普遍的な「翻訳コスト」とは読めない。

a) RWKV→Pythia と Pythia→RWKV では深さ依存が異なる.: 表 IV のとおり、Pythia→RWKV は $L=16, 24$ で同じ層の RWKV→Pythia を ARC で +8.9/+12.6 点, SciQ で +13.5/+18.8 点上回る (同一問題の McNemar 検定, すべて $p < 3 \times 10^{-15}$)。一方、 $L=4$ は ARC で +2.6 点 ($p=0.015$) だが SciQ で -1.7 点 ($p=0.28$) であり、浅い境界では経路差は一様でない。なお、どの Pythia→RWKV 構成も Pythia を有意に下回る。また RWKV に対して有意に優る Pythia→RWKV 構成はなく、Pythia→RWKV ($L=4$) は ARC 62.2 対 61.8 ($p=0.66$), SciQ 69.2 対 67.0 ($p=0.14$) で同等である。

Pythia→RWKV の最良アフィン写像は、各切替層でアダプタと別に適合した対照である。ARC @4 ではアダプタが +2.0 点 ($p=0.005$) だが、他の多くは差がなく、SciQ @8 では逆にアフィンが +3.4 点 ($p=0.003$) である。この写像間比較とは別に、同一アダプタの非線形枝を $\alpha = 0$ とする介入を RWKV→Pythia / Pythia→RWKV の同じ四層・同じ問題で実行し、因果的な非線形枝の寄与はそのペア化結果から評価する。 $A \rightarrow A$ 自己符号器との比較も、RWKV 前段を Pythia 前段と横断翻訳へ同時に置き換えるため、翻訳誤差だけを分離しない。

b) 合成によるメモリ上の効果: Transformer 層とともに KV キャッシュが消える.: 性能と推論メモリは同時に評価する必要がある。二つの系統は推論時の費用が同じではないからである。Transformer の層はトークンごとに key/value をキャッシュするが、RNN 層が持つのは系列長に対して $O(1)$ の再帰状態である。RWKV→Pythia は Transformer を $31-L$ 層, Pythia→RWKV は $L+1$ 層だけ保持する。なお削減の対象は KV キャッシュであって常駐重みではない。アダプタ自体は fp16 で 0.50 GiB を占め、一方向のみを常駐させても約 0.25 GiB で、削減後の KV と同程度である。

RWKV→Pythia / Pythia→RWKV を含めると、Pythia→RWKV ($L=4$) は RWKV→Pythia ($L=4$) より Transformer 層を $27 \rightarrow 5$ へ減らしながら、二タスク平均を 65.25% $\rightarrow$ 65.70% とほぼ保つ。置き換える RWKV の再帰状態は層あたり 64 KiB (5 状態ベクトルのうち 2 つが fp16, 3 つが fp32 という参照実装の構成からの算出値) で、構成上文脈長に依存しない。ただし純 RWKV は KV がゼロであり、順位はタスクに依存するため、図 5 は SciQ に限ったメモリ-精度フロンティアとして示す。

Pythia 前段の経路を加えると、高削減点 Pythia→RWKV ($L=4$) が得られる。この点は RWKV 前段の経路だけでは現れない。一方、pure RWKV は依然 KV ゼロであり、Pythia→RWKV ($L=4$) が RWKV を有意に上回るわけでもない。したがって利点は、凍結親の間に追加の交換点を作れることであって、新しい構成が親を一律に支配することではない。

TABLE V
RWKV→Pythia / Pythia→RWKV 両経路の正答率と推論メモリ。KV は実測値；RWKV 再帰状態は文脈長に対して定数である。

構成	Transformer 層	KV / token	KV @ 4k 文脈	削減	ARC / SciQ
pure Tulu-Pythia	32	512 KiB	2.00 GiB	—	65.3 / 81.0
RWKV→Pythia ($L=4$)	27	432 KiB	1.69 GiB	15.6%	59.6 / 70.9
RWKV→Pythia ($L=8$)	23	368 KiB	1.44 GiB	28.1%	59.0 / 67.7
RWKV→Pythia ($L=16$)	15	240 KiB	0.94 GiB	53.1%	48.6 / 54.5
RWKV→Pythia ($L=24$)	7	112 KiB	0.44 GiB	78.1%	47.0 / 51.1
Pythia→RWKV ($L=24$)	25	400 KiB	1.56 GiB	21.9%	59.6 / 69.9
Pythia→RWKV ($L=16$)	17	272 KiB	1.06 GiB	46.9%	57.5 / 68.0
Pythia→RWKV ($L=8$)	9	144 KiB	0.56 GiB	71.9%	57.3 / 64.6
Pythia→RWKV ($L=4$)	5	80 KiB	0.31 GiB	84.4%	62.2 / 69.2
pure RWKV-Raven	0	0	0	100%	61.8 / 67.0




Fig. 5. RWKV→Pythia / Pythia→RWKV の SciQ 正答率と実測 KV 削減率。両経路を含む非支配点は pure Pythia → RWKV→Pythia ($L=4$) → Pythia→RWKV ($L=24$) → Pythia→RWKV ($L=4$) → pure RWKV (緑) となる。これは SciQ 一課題上の事後的フロンティアであり、経路一般の優越や未知課題への汎化を意味しない。

結果は限定付きである：機能は保つが、正答率の一律な向上ではない。RWKV→Pythia / Pythia→RWKV とともに Pythia を有意に下回る。RWKV→Pythia は RWKV を SciQ のみ上回り、Pythia→RWKV はどの境界も RWKV を有意に上回らない。得られた主な利点は、Pythia→RWKV ($L=4$) で Pythia の正答率の一部を保ちながら Transformer KV を 84.4% 除けることである。

c) 翻訳は領域特異的である。：以上の正答率は、指示形式に近い短い設問で測ったものである。KV キャッシュの節約が意味を持つのは長い文脈であり、そこでカメラが異なる領域のテキストコーパス (WikiText-103 [29]) に対してどれだけ言語モデルを保つかを測る必要がある。文脈 512 の RWKV→Pythia ($L=4$) は Alpaca で perplexity 6.40, WikiText-103 で 93.87 である。Pythia→RWKV ($L=4$) は 3.85/45.00 と両領域で改善するが、WikiText はなお親の 11.33/16.22 から大きく離れる。文脈を 2048 へ伸ばすと Pythia→RWKV ($L=4$) は Alpaca 3.50, WikiText 34.78 となり、崩壊せずむしろ改善する。したがって主因は文脈

長でなく領域シフトである。Pythia→RWKV はシフトを緩和するが、WikiText 34.78 は良い方の親 RWKV 8.27 の 4.2 倍であり、依然として高い perplexity にとどまる。




Fig. 6. 領域シフト (文脈 512, 対数軸)。Pythia→RWKV は RWKV→Pythia ($L=4$) の WikiText perplexity を 93.87 → 45.00 に改善するが、両親 11.33/16.22 には届かない。同じアダプタが Alpaca では親の近傍にあるため、長さでなく領域が主要な差である。

V. 考察

本実験では、凍結した異種系統の対応層間に、共有表現を学習できる ($\rho_{\text{ctr}}=0.90$)。ただし主張の射程は限定的である：本研究の対応は同一トークナイザ・同一幅・同一層数・同一入力・Alpaca 近傍領域という好条件で測ったものであり、シャッフル対照はトークン非依存の分布一致を排除するが、観測された対応が意味・語彙・位置・構文のいずれに由来するかは切り分けていない。領域外 WikiText で perplexity が劣化すること (§IV-E) は、学習領域の外への汎化に疑問が残ることを示す。ゆえに「一般的な共通意味空間」を主張せず「好条件下でトークン対応した表現の共通空間」の存在を主張するにとどめる。機能的な接合が成立することは、両者が同じ情報を表現していることを意味しない。Smith ら [30] は、異なる課題や異なるモダリティの間、さらにはクラスタ化した乱数由来の表現からでも接合が成立し得ることを示している。ただし彼らの接合層は下流課題の損失で学習されており、Balogh と Jelasity [31] が、その方式は対応しない層や領域外の表現を高く評価すると指摘した手法にあたる。本研究のアダプタは対応残差の直接整合で学習しており、同論文が構造的な要求と機能的な要求のバランスが良いとした側に属する。とはいえ Smith らは低容量の接合層でも偽の整合を得ており、本研究のアダプ

タはより表現力が高い。低容量のアフィン写像でも相当な横断予測が得られること (§IV-C) が、観測された整合をアダプタの表現力だけでは説明できないとする主たる根拠である。高い潜在相関が高い読み出し精度を保証しない点も重要であり、共有表現の有無と復号可能性は分けて評価する必要がある。この区別は独立にも報告されている。Zhang と Xin のプレプリント [32] は、Pythia 間の線形ブリッジがオフラインでは正規化 $R^2 = 0.883$ に達しながら、受信側へ置換注入すると多段推論の性能がかえって下がることを示し、受信側での因果的な利用を目的関数に含める必要があると結論づけた。本研究のアダプタも活性の再構成のみで学習しており、この指摘の射程内にある。ただし本研究の境界式は層別統計による逆標準化 unstd_B を含み、受信側本来のスケールを復元する点が、正規化目的で学習された彼らの線形ブリッジと異なる。この構造的差異が寄与しているかは、本研究では切り分けていない。この空間上に組んだキメラは機能するものの損失を伴い、生成例では両経路とも流暢さを保ったまま内容または形式を誤る。競争力のあるキメラには、 $B \rightarrow B$ を律速する要因の特定、領域をまたいだ学習、および事前学習側で相補的な親モデルの選定が必要である。

VI. 限界

評価課題への露出がある。Tulu-Pythia は FLAN V2 の部分集合で指示チューニングされており、FLAN の構成タスク一覧には ARC と SciQ が含まれる。公開されている混合データの当該成分を逐語照合すると、評価項目のうち ARC-Easy 19 問と SciQ 4 問が含まれる。項目単位の正誤記録からこれらを除いて全構成の正答率を再計算しても変化は最大 0.22 点であり、本稿のどの比較の結論も変わらない。さらに、これらの項目は露出のない RWKV でも同方向に難化・易化しており (ARC で -9.2 点, SciQ で +8.0 点)、差は露出ではなく項目自体の難易度で説明される。ただし ARC-Easy・SciQ が後段親のすでに持つ課題族であることは変わらないため、本稿の値は未知能力の獲得ではなく合成後の能力保持を測るものと読むべきである。アダプタの学習は乱数種一つのみである。性能は**全評価集合** (ARC-Easy 2376, SciQ 1000) で測り、構成間の差は同一問題上のペア化検定 (McNemar の正確検定と対応 bootstrap) で評価した。RWKV→Pythia が弱い親を上回るのは SciQ のみ、かつ長さ正規化スコアに限られ (総和スコアでは成立しない)、Pythia→RWKV はどの境界も RWKV を有意に上回らない。2 タスク × 2 横断経路 × 4 切替と複数対照を評価し、多重比較補正は行っていない。非線形枝の同一アダプタ介入は RWKV→Pythia / Pythia→RWKV と同じ層・問題で行ったが、単一チェックポイント上の介入であり、異なるアダプタ学習条件へ一般化できるとは限らない。また合成は常に境界を一箇所しか持たず、複数境界で翻訳誤差がどう累積するかは測定していない。さらにキメラの評価は尤度に基づいており、これは正しい選択肢を**選ぶ**能力を測るものであって、**生成する**能力を直接測るものではない。RWKV→Pythia / Pythia→RWKV 各四つの生成例は定性的な補足にとどまり、生成能力の包括的評価ではない。加えて、翻訳は**学習領域に特化**しており、WikiText では大きく劣化する。長文脈 CE は文脈 512/1024/2048 で測る (両親がいずれも文脈長 ≤ 2048 のモデルであるため 2048

を上限とする)。これは言語モデリングの品質であって、遠距離依存を要する読解を直接測るものではない。 $\sigma \cdot \lambda \cdot$ 潜在幅・残差ブロック数・学習データ量に対するアブレーション、および同一系統ペア (同一アーキテクチャ) での整合は本 32 層構成では実施しておらず、今後の課題である。

References

- [1] K. Lenc and A. Vedaldi, “Understanding image representations by measuring their equivariance and equivalence,” *Int. J. Comput. Vision*, vol. 127, no. 5, p. 456–476, May 2019. [Online]. Available: <https://doi.org/10.1007/s11263-018-1098-y>
- [2] Y. Bansal, P. Nakkiran, and B. Barak, “Revisiting model stitching to compare neural representations,” in *Proceedings of the 35th International Conference on Neural Information Processing Systems*, ser. NIPS ’21. Red Hook, NY, USA: Curran Associates Inc., 2021.
- [3] A. Csizsárik, P. Körösi-Szabó, A. Matszangosz, G. Papp, and D. Varga, “Similarity and matching of neural network representations,” in *Advances in Neural Information Processing Systems*, M. Ranzato, A. Beygelzimer, Y. Dauphin, P. Liang, and J. W. Vaughan, Eds., vol. 34. Curran Associates, Inc., 2021, pp. 5656–5668. [Online]. Available: https://proceedings.neurips.cc/paper_files/paper/2021/file/2cb274e6ce940f47beb8011d8ecb1462-Paper.pdf
- [4] B. Hu, S. Li, S. Agarwal, M. Lee, A. Jajoo, J. Li, L. Xu, G.-W. Kim, D. Kim, H. Xu, A. Zhang, and A. Akella, “StitchLLM: Serving LLMs, one block at a time,” in *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, W. Che, J. Nabende, E. Shutova, and M. T. Pilehvar, Eds. Vienna, Austria: Association for Computational Linguistics, Jul. 2025, pp. 26 887–26 903. [Online]. Available: <https://aclanthology.org/2025.acl-long.1305/>
- [5] Q. Zhang, P. Bhargava, C. Bi, C. X. Cai, J. N. Foerster, J. Fu, P. S. Koura, R. Silva, S. Shen, E. Dinan, S. Gururangan, and M. Lewis, “BTS: Harmonizing specialized experts into a generalist LLM,” in *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing*, C. Christodoulopoulos, T. Chakraborty, C. Rose, and V. Peng, Eds. Suzhou, China: Association for Computational Linguistics, Nov. 2025, pp. 6816–6834. [Online]. Available: <https://aclanthology.org/2025.emnlp-main.347/>
- [6] R. Bansal, B. Samanta, S. Dalmia, N. Gupta, S. Ganapathy, A. Bapna, P. Jain, and P. Talukdar, “LLM augmented LLMs: Expanding capabilities through composition,” in *The Twelfth International Conference on Learning Representations*, 2024. [Online]. Available: <https://openreview.net/forum?id=jjA4O1vJRz>
- [7] N. Roberts, S. Guo, Z. Gao, S. S. N. GNVV, S. Crompt, C. Wu, C. Duan, and F. Sala, “Pretrained hybrids with MAD skills,” in *Second Conference on Language Modeling*, 2025. [Online]. Available: <https://openreview.net/forum?id=8xSbwT3763>
- [8] L. Moschella, V. Maiorca, M. Fumero, A. Norelli, F. Locatello, and E. Rodolà, “Relative representations enable zero-shot latent space communication,” in *The Eleventh International Conference on Learning Representations*, 2023. [Online]. Available: <https://openreview.net/forum?id=Src-nwieGJ>
- [9] V. Maiorca, L. Moschella, A. Norelli, M. Fumero, F. Locatello, and E. Rodolà, “Latent space translation via semantic alignment,” in *Proceedings of the 37th International Conference on Neural Information Processing Systems*, ser. NIPS ’23. Red Hook, NY, USA: Curran Associates Inc., 2023.
- [10] S. Grant, “Model alignment search,” in *Second Workshop on Representational Alignment at ICLR 2025*, 2025. [Online]. Available: <https://openreview.net/forum?id=8uNenpoGh>
- [11] A. Chen, J. Merullo, A. Stolfo, and E. Pavlick, “Transferring linear features across language models with model stitching,” in *The Thirty-ninth Annual Conference on Neural Information Processing Systems*, 2025. [Online]. Available: <https://openreview.net/forum?id=Qvvy0X63Fv>

- [12] C. Flamant, U. Ghai, and K. Shimizu, “The bicameral model: Bidirectional hidden-state coupling between parallel language models,” 2026. [Online]. Available: <https://arxiv.org/abs/2605.11167>
- [13] D. Goldstein, F. Obeid, E. Alcaide, G. Song, and E. Cheah, “Goldfinch: High performance rwkv/transformer hybrid with linear pre-fill and extreme kv-cache compression,” 2024. [Online]. Available: <https://arxiv.org/abs/2407.12077>
- [14] N. F. Oozer, D. Nathawani, N. Prakash, M. Lan, A. HAR-RASSE, and A. Abdullah, “Activation space interventions can be transferred between large language models,” in Forty-second International Conference on Machine Learning, 2025. [Online]. Available: <https://openreview.net/forum?id=HXOicJsmMQ>
- [15] S. Kornblith, M. Norouzi, H. Lee, and G. Hinton, “Similarity of neural network representations revisited,” in Proceedings of the 36th International Conference on Machine Learning, ser. Proceedings of Machine Learning Research, K. Chaudhuri and R. Salakhutdinov, Eds., vol. 97. PMLR, 09–15 Jun 2019, pp. 3519–3529. [Online]. Available: <https://proceedings.mlr.press/v97/kornblith19a.html>
- [16] M. Raghu, J. Gilmer, J. Yosinski, and J. Sohl-Dickstein, “Svcca: singular vector canonical correlation analysis for deep learning dynamics and interpretability,” in Proceedings of the 31st International Conference on Neural Information Processing Systems, ser. NIPS’17. Red Hook, NY, USA: Curran Associates Inc., 2017, p. 6078–6087.
- [17] A. S. Morcos, M. Raghu, and S. Bengio, “Insights on representational similarity in neural networks with canonical correlation,” in Proceedings of the 32nd International Conference on Neural Information Processing Systems, ser. NIPS’18. Red Hook, NY, USA: Curran Associates Inc., 2018, p. 5732–5741.
- [18] J. Wang, X. Ge, W. Shu, Q. Tang, Y. Zhou, Z. He, and X. Qiu, “Towards universality: Studying mechanistic similarity across language model architectures,” in The Thirteenth International Conference on Learning Representations, 2025. [Online]. Available: <https://openreview.net/forum?id=2J18i8T0oI>
- [19] M. Wortsman, G. Ilharco, S. Y. Gadre, R. Roelofs, R. Gontijo-Lopes, A. S. Morcos, H. Namkoong, A. Farhadi, Y. Carmon, S. Kornblith, and L. Schmidt, “Model soups: averaging weights of multiple fine-tuned models improves accuracy without increasing inference time,” in Proceedings of the 39th International Conference on Machine Learning, ser. Proceedings of Machine Learning Research, K. Chaudhuri, S. Jegelka, L. Song, C. Szepesvari, G. Niu, and S. Sabato, Eds., vol. 162. PMLR, 17–23 Jul 2022, pp. 23 965–23 998. [Online]. Available: <https://proceedings.mlr.press/v162/wortsman22a.html>
- [20] P. Yadav, D. Tam, L. Choshen, C. Raffel, and M. Bansal, “Ties-merging: resolving interference when merging models,” in Proceedings of the 37th International Conference on Neural Information Processing Systems, ser. NIPS ’23. Red Hook, NY, USA: Curran Associates Inc., 2023.
- [21] T. Akiba, M. Shing, Y. Tang, Q. Sun, and D. Ha, “Evolutionary optimization of model merging recipes,” Nature Machine Intelligence, vol. 7, no. 2, pp. 195–204, Feb. 2025. [Online]. Available: <https://doi.org/10.1038/s42256-024-00975-8>
- [22] F. Wan, X. Huang, D. Cai, X. Quan, W. Bi, and S. Shi, “Knowledge fusion of large language models,” in The Twelfth International Conference on Learning Representations, 2024. [Online]. Available: <https://openreview.net/forum?id=jiDsk12qcz>
- [23] B. Peng, E. Alcaide, Q. Anthony, A. Albalak, S. Arcadinho, S. Biderman, H. Cao, X. Cheng, M. Chung, L. Derczynski, X. Du, M. Grella, K. Gv, X. He, H. Hou, P. Kazienko, J. Kocon, J. Kong, B. Koptyra, H. Lau, J. Lin, K. S. I. Mantri, F. Mom, A. Saito, G. Song, X. Tang, J. Wind, S. Wozniak, Z. Zhang, Q. Zhou, J. Zhu, and R.-J. Zhu, “RWKV: Reinventing RNNs for the transformer era,” in Findings of the Association for Computational Linguistics: EMNLP 2023, H. Bouamor, J. Pino, and K. Bali, Eds. Singapore: Association for Computational Linguistics, Dec. 2023, pp. 14 048–14 077. [Online]. Available: <https://aclanthology.org/2023.findings-emnlp.936/>
- [24] S. Biderman, H. Schoelkopf, Q. Anthony, H. Bradley, K. O’Brien, E. Hallahan, M. A. Khan, S. Purohit, U. S. Prashanth, E. Raff, A. Skowron, L. Sutawika, and O. Van Der Wal, “Pythia: a suite for analyzing large language models across training and scaling,” in Proceedings of the 40th International Conference on Machine Learning, ser. ICML’23. JMLR.org, 2023.
- [25] Y. Wang, H. Ivison, P. Dasigi, J. Hessel, T. Khot, K. R. Chandu, D. Wadden, K. MacMillan, N. A. Smith, I. Beltagy, and H. Hajishirzi, “How far can camels go? exploring the state of instruction tuning on open resources,” in Proceedings of the 37th International Conference on Neural Information Processing Systems, ser. NIPS ’23. Red Hook, NY, USA: Curran Associates Inc., 2023.
- [26] R. Taori, I. Gulrajani, T. Zhang, Y. Dubois, X. Li, C. Guestrin, P. Liang, and T. B. Hashimoto, “Stanford alpaca: An instruction-following llama model,” https://github.com/tatsu-lab/stanford_alpaca, 2023.
- [27] P. Clark, I. Cowhey, O. Etzioni, T. Khot, A. Sabharwal, C. Schoenick, and O. Tafjord, “Think you have solved question answering? try arc, the ai2 reasoning challenge,” 2018. [Online]. Available: <https://arxiv.org/abs/1803.05457>
- [28] J. Welbl, N. F. Liu, and M. Gardner, “Crowdsourcing multiple choice science questions,” in Proceedings of the 3rd Workshop on Noisy User-generated Text, L. Derczynski, W. Xu, A. Ritter, and T. Baldwin, Eds. Copenhagen, Denmark: Association for Computational Linguistics, Sep. 2017, pp. 94–106. [Online]. Available: <https://aclanthology.org/W17-4413/>
- [29] S. Merity, C. Xiong, J. Bradbury, and R. Socher, “Pointer sentinel mixture models,” in International Conference on Learning Representations, 2017. [Online]. Available: <https://openreview.net/forum?id=Byj72udxe>
- [30] D. Smith, H. Mannering, and A. Marcu, “Functional alignment can mislead: Examining model stitching,” in Proceedings of the 42nd International Conference on Machine Learning, ser. Proceedings of Machine Learning Research, A. Singh, M. Fazel, D. Hsu, S. Lacoste-Julien, F. Berkenkamp, T. Maharaj, K. Wagstaff, and J. Zhu, Eds., vol. 267. PMLR, 13–19 Jul 2025, pp. 55 972–55 998. [Online]. Available: <https://proceedings.mlr.press/v267/smith25a.html>
- [31] A. Balogh and M. Jelasity, “How not to stitch representations to measure similarity: Task loss matching versus direct matching,” in Proceedings of the AAAI Conference on Artificial Intelligence, vol. 39, no. 15, 2025, pp. 15 472–15 480.
- [32] P. Zhang and J. Xin, “A negative result on cross-model activation transfer in a pythia multi-hop setting,” 2026. [Online]. Available: <https://arxiv.org/abs/2606.03280>

Appendix A 再現情報

- **モデル**: RWKV-4-Raven-7B (BlinkDL .pth を HF 形式へ変換し fp16 再保存) と allenai/open-instruct-pythia-6.9b-tulu (fp16)。ともに 32 層, $d=4096$, GPT-NeoX-20B トークナイザ。
- **アダプタ**: $z=d=4096$, 残差ブロック 1 (内部幅 4096, 第 2 行列ゼロ初期化), 非アフィン LN, $\sigma=0.4$, $\lambda=1$, 268.5M パラメータ。AdamW, $4 \times V100$ で有効バッチ 4096, 学習率 $10^{-3} \rightarrow 10^{-5}$ (保留集合の $A \rightarrow B$ が改善しなくなったら $\times 0.5$), 416,000 反復走行 (報告チェックポイントは保留 $A \rightarrow B$ 最良の 415,000 反復), 乱数種 0。
- **データ**: 残差は Alpaca 学習分割の先頭側 (窓 112 トークン, $\approx 232k$ 独立トークン位置) から, 評価窓は文字位置 2,000,000 以降から取り (学習トークン数に依存しない固定オフセット), 両者は重ならない。標準化統計は各層の学習残差から算出し逆標準化に用いる。
- **評価**: 保留集合の R^2 は各層で全トークン・全次元をプールして算出し, 32 層の単純平均を報告する。多肢選択は各選択肢を連結した系列の対数尤度 (プロンプ

ト以降のトークンの和／平均)で決定し、全評価集合 (ARC-Easy test 2376, SciQ test 1000)を用いる。SciQ は support 文を与えない closed-book 形式で評価する。構成間の差はペア化検定 (McNemar・対応 bootstrap) で評価する。Pythia→RWKV の RWKV 後段では選択肢を常に batch 1 で評価する。Pythia→RWKV も RWKV→Pythia と同じ、保留 $A \rightarrow B$ で選んだ step 415,000 の配布チェックポイントに固定し、 $B \rightarrow A$ または Pythia→RWKV QA を見たチェックポイントの再選択は行わない。ただし方向固定した二つの配布 runtime は、評価後に各経路の四境界について報告テスト平均が最大だった $L=4$ を既定値とし、独立な deployment-selection 分割はない。

- **コード・構造化データ**: 本研究のリポジトリは <https://github.com/Katagiri-Hoshino-Lab/NinaXander> である。実験コード、各評価の生データと論文報告値の集約表、再現手順、および本文の数値を表データと自動照合する検査を含む。
- **Hugging Face 配布物**: 2026 年 7 月 30 日時点の推論用成果物を、次の三つの model repository へ保存した。
 - 共有アダプタ: <https://huggingface.co/Katagiri-Hoshino-Lab/ninaxander-raven7b-tulu69-adapter>
 - Pythia→RWKV (既定 $L=4$): <https://huggingface.co/Katagiri-Hoshino-Lab/ninaxander-tulu69-to-raven7b-best>
 - RWKV→Pythia (既定 $L=4$): <https://huggingface.co/Katagiri-Hoshino-Lab/ninaxander-raven7b-to-tulu69-best>

各 repository は英語・日本語・簡体字中国語の model card と notice, SafeTensors, SHA-256 manifest を含む。配布 License はいずれも、より制約の強い親 (Tulu-Pythia) に合わせた AI2 AI Model License (非商用研究限定) であり、各 NOTICE に親モデルの帰属を記載する。

Appendix B 指標の定義

本節は指標の厳密な定義を述べる。

a) 指標の定義.: 残差は層ごとに、学習トークンから推定した次元別の平均・標準偏差で標準化して用いる (キメラ挿入時は逆標準化する)。損失の三項はいずれも全要素 (トークン $\times$ 次元) の平均であり、 z は非アフィン LN により単位分散であるから、 $\lambda=1$ は要素あたりの誤差を同一スケールで加えることに相当する。ノイズ ξ_A, ξ_B は独立にサンプルする。 R^2 は層ごとに保留トークンと全 4096 次元をプールして $1 - \text{SSE}/\text{SST}$ で計算する。SST は次元ごとにトークン平均を除いた全変動であり、分散の大きい次元ほど寄与が大きい。保留集合は二つある: 見出し値を与える学習時評価は $1,000 \text{ 窓} \times 112 = 112,000$ トークン、層別分析とシャッフル対照 (§IV-A) は $400 \text{ 窓} \times 112 = 44,800$ トークンで、評価集合が異なるため層別分析の 32 層平均 (0.561/0.592) は見出し値 (0.559/0.590) と厳密には一致しない。 ρ_{ctr} は層内で各次元のトークン平均を除去した後、(トークン $\times$ 次元) を平坦化した単一の Pearson 相関であ

る。 $f = \|z - \bar{z}\|^2 / \|z\|^2$ の $\bar{z}$ は層内の次元別トークン平均で、 A, B 各モデルで計算して平均する。いずれの指標も層ごとに算出し、32 層の単純平均を報告する。§IV-A の全層対応の適合 R^2 は、各層ペアの同一 22,400 行で適合・評価するサンプル内 (in-sample) のリッジ線形プローブである。