

# NinaXander：共有潜在表現による異種モデル族の凍結言語モデル合成——成立条件と限界

樹神 宇徳\*, 林 俊一郎\*, 椋木 大地†, 星野 哲也†, 片桐 孝洋†

\* 名古屋大学大学院情報学研究科

† 名古屋大学情報基盤センター

**Abstract**—NinaXander は、異なる事前学習システムの凍結層を、共有潜在アダプタを介して接続する言語モデルである。本研究では、RWKV-Raven-7B（再帰型）と Tulu-Pythia-6.9b（Transformer 型）を対象に、対応層間の表現が単純な変換で接続可能か、またその接続が機能的な合成に使えるかを検証する。主な結果は四つである。(i) 同一トークナイザ・幅・層数・学習領域という条件下で、中心化潜在相関  $\rho_{\text{ctr}}=0.901$  を得た。行対応をシャッフルすると整合は消失する一方、生表現の CKA は同一層で最大にならず、WikiText への領域シフトでも性能が大きく低下する。したがって、本結果が示すのは一般的な意味空間ではなく、好条件下で学習可能なトークン対応表現である。(ii) 四経路の読み出しは RWKV 自己再構成 / RWKV→Pythia / Pythia 自己再構成 / Pythia→RWKV の順に 0.695/0.559/0.711/0.590 であり、圧縮を除いても再構成誤差が残る。(iii) 最良直接アフィン写像は RWKV→Pythia / Pythia→RWKV で 0.487/0.535 に達する一方、学習済みアダプタ出力の 13.4%/12.0% はアフィン写像で説明できない。同一アダプタの非線形枝を無効化すると両横断読み出しは負の  $R^2$  まで崩れる。(iv) 単一境界で合成したキメラは構文的に妥当な生成と多肢選択の遂行が可能だが、強い親モデルには届かない。Pythia→RWKV は深い境界の正答率が同層の RWKV→Pythia より 8.9–18.8 点高く、Pythia 前段→RWKV 後段の Pythia→RWKV ( $L=4$ ) は Transformer を 5 層だけ残して KV を 84.4% 削減しつつ、ARC-Easy 62.2%, SciQ 69.2% を保つ。ただし RWKV を有意には上回らず、配布既定値の選択も同じ二つのテスト集合上の事後選択である。未使用ブロックを除くと常駐重みは 14.11 GiB まで減るが、領域外 WikiText と参照実装の速度には大きな課題が残る。

## I. はじめに

本研究は NinaXander<sup>1</sup>——異なるシステムの凍結ブロックを、単一の学習済みアダプタで接続するキメラモデル——を構築し、その成立条件と限界を明らかにする。異種ブロックを組み替えるには、モデルの機能を保ったまま残差表現を系統間で受け渡す機構が必要である。

そこで本研究は共有潜在アダプタを導入し、二つの問いを検証する。第一に、異種モデルの対応層間に、低深度の写像で接続できる共通表現があるか。第二に、その表現を用いたキメラが、親モデルと比べてどの程度の機能を保ち、どれだけの推論メモリ削減を得るか。本研究の貢献は、(i) 共通モードを除いた整合測定、(ii) RWKV 自己再構成 / RWKV→Pythia / Pythia 自己再構成 / Pythia→RWKV の四経路を比較する対照実験、(iii) RWKV→Pythia / Pythia→RWKV の両方でアダプタの非線形性を測る同一写像内の介入実験、(iv) 単一境界キメラの RWKV→Pythia / Pythia→RWKV における精度・メモリ・領域汎化と経路非対称性の実測である。

<sup>1</sup>NinaXander は『鋼の錬金術師』のキメラ——少女ニーナ (Nina) と犬アレキサンダー (Alexander) を融合した存在——に由来する。合成が成立し、融合体として機能しても、元の存在には及ばない。本研究のキメラも動作はするが強い方の親には届かず、この名称はその対応になぞらえたものである。

## II. 手法

a) 残差ペア.: トークナイザを共有する凍結  $A, B$  に同一テキストを与え、位置  $t$ ・ブロック  $j$  の出力  $r_A^j[t]$  と  $r_B^j[t]$  を対応づける。残差は各ブロックへの forward hook で直接取得し、両系統・全 32 層（層 0 を含む）を同種の量として扱う（取得実装と整合性検査の詳細は付録 A）。

b) 共有潜在アダプタ.: 各モデルに符号器・復号器を 1 組ずつ置き、全層に共通する単一潜在  $z$  へ写す：

$$z_A = \text{LN}(E_A(r_A)), \quad z_B = \text{LN}(E_B(r_B)), \\ \mathcal{L} = \|D_A(z_A + \xi_A) - r_A\|^2 + \|D_B(z_B + \xi_B) - r_B\|^2 \\ + \lambda \|z_A - z_B\|^2.$$

$\xi_A, \xi_B \sim \mathcal{N}(0, \sigma^2 I)$  (枝ごとに独立にサンプルする),  $\lambda=1$ , LN は非アフィン,  $\sigma$  は 0.4 とした。 $E, D$  は浅い残差 MLP。横断写像  $A \rightarrow B := D_B(z_A) = D_B(\text{LN}(E_A(r_A)))$  と  $B \rightarrow A := D_A(z_B) = D_A(\text{LN}(E_B(r_B)))$  のいずれにも横断的教師目標を与えない ( $r_A$  は  $B$  の再構成損失に、 $r_B$  は  $A$  の再構成損失に現れない) が「教師なし」でもない。仮説は単純な変換で空間が揃うことなので、表現力の大きい重いアダプタによる高い横断読み出しは共有空間の証拠にならない。そこで写像の深さを残差ブロック 1 個に制限し、パラメータ数と RWKV→Pythia / Pythia→RWKV の線形対照を併記する (§V)。

c) アダプタの構造.:  $E_A, E_B, D_A, D_B$  は同一形：潜在幅への線形射影,  $b$  個の pre-norm 残差ブロック, 出力への線形射影。報告する構成は  $z=d=4096$  (圧縮なし),  $b=1$ , 内部幅  $h=4096$  である。各残差ブロックの第 2 行列はゼロ初期化なので、初期状態で各ブロックは恒等写像であり、アダプタ全体は線形写像から学習を始める。ただしこれは初期化の性質であって学習後の性質ではない：§V で測るように、収束後の写像は RWKV→Pythia / Pythia→RWKV の出力分散の 13.4%/12.0% が非線形であり、同じ非線形枝が両横断読み出しを担う。親モデルの合計 14.2B パラメータに対し、アダプタは 268.5M (1.9%) である。「軽量」は絶対的な小ささではなく、親モデルに対する相対量と低い深度を指す。

d) 設計上重要な二つの選択.: 非アフィン LN は整合項を  $z$  の縮小で満たすのを防ぎ、ノイズ  $\xi$  はトークン非依存の共通モードへの逃避を抑えることを意図している——定数はノイズを回避できないため、 $z$  はトークンごとの情報を担わざるを得なくなる。 $\sigma=0.4$  は固定して用い、本論文では  $\sigma$  を掃引していない。

e) 4 経路の名称とキメラ.: 数式では  $A$  を RWKV,  $B$  を Tulu-Pythia と置くが、本文と図表では二文字コードを




Fig. 1. 共有潜在アダプタ。各凍結モデルの残差を単一の潜在  $z$  (非アフィン LayerNorm) に符号化し、自系統へ復号する (実線; この 2 つの再構成と整合項  $\lambda \|z_A - z_B\|^2$  が損失の全て)。ガウスノイズ  $\xi_A, \xi_B \sim \mathcal{N}(0, \sigma^2)$  (独立) は復号の直前にのみ  $z$  へ加わり、整合項には乗らない。実線の  $A \rightarrow A$  (RWKV 自己再構成) と  $B \rightarrow B$  (Pythia 自己再構成) は自系統再構成、破線の  $A \rightarrow B$  (RWKV  $\rightarrow$  Pythia) と  $B \rightarrow A$  (Pythia  $\rightarrow$  RWKV) は横断読み出しである。後二者は横断目標に一度も適合されず、整合項が  $z_A \approx z_B$  を作って初めて成立する。

使わず、前段と後段を明示する。四経路は RWKV 自己再構成, RWKV  $\rightarrow$  Pythia, Pythia 自己再構成, Pythia  $\rightarrow$  RWKV である。RWKV  $\rightarrow$  Pythia と Pythia  $\rightarrow$  RWKV は系統横断キメラ, RWKV 自己再構成 と Pythia 自己再構成 は同じ境界・アダプタを通る自系統再構成対照である。切替層  $L$  は前段親が最後に実行するブロックの添字 (0 始まり) であって、実行する層数ではない——ブロック 0 を含むため前段は  $L+1$  個になる。RWKV  $\rightarrow$  Pythia では、 $A$  の最初の  $L+1$  ブロック (ブロック 0 から  $L$ ) を走らせ、残差を一度だけ  $B$  空間へ翻訳する:  $h_B = \text{unstd}_B(D_B(\text{LN}(E_A(\text{std}_A(h_A))))$ 。続いて  $B$  の残り  $31-L$  ブロック ( $L+1$  以降) と言語モデルヘッドを走らせる。Pythia  $\rightarrow$  RWKV も同じ学習済みアダプタで別個に評価し、 $h_A = \text{unstd}_A(D_A(\text{LN}(E_B(\text{std}_B(h_B))))$  を RWKV ブロック  $L+1$  の入力へ挿入する。いずれも合計は 32 ブロック、内訳は  $L+1$  と  $31-L$  であり、翻訳は 1 回だけである。配線の正しさは境界ゲート——後段親自身の該当層残差を再挿入して親ロジックが回復すること——で担保し、全境界で  $\text{rel}=0$  を確認した (検査の詳細は付録 A)。

f) 評価指標.: 未学習の文章に対する決定係数  $R^2$  (層内の全トークン・全次元をプールし、SST は次元ごとに中心化) を、系統をまたぐ写像 ( $A \rightarrow B$ ,  $B \rightarrow A$ ) と自系統の写像 ( $A \rightarrow A$ ,  $B \rightarrow B$ ) の双方について測る。潜在の整合は中心化相関  $\rho_{\text{ctr}}$  (共通モードを除いたもの) で測り、あわせてトークンごとに変動する成分の割合  $f$  を報告する。両者は整合項と  $2f(1-\rho_{\text{ctr}})$  の関係で結ばれる。各指標は層ごとに全トークン上で算出し ( $R^2$  の SST も  $\rho_{\text{ctr}} \cdot f$  の共通モード除去も各層内で行う), 32 層にわたる単純平均を報告する。層をまたいで一括集計はしない——層平均どうしの差が相関・分散を過大に見せるためである。キメラについては、英語プロンプトを原文どおり与え、温度 0 の決定的  $\text{argmax}$  (最大 40 新規トークン, EOS 出力時のみ早期終了) による生成例, 多肢選択の正答率, および次トークン交差エントロピーで評価する。

### III. 対応層間には学習可能な共通表現がある (好条件下)

7B 指示追従モデルのペア RWKV-Raven-7B (純 RNN)  $\leftrightarrow$  Tulu-Pythia-6.9b (Transformer) は、ともに 32 ブロック,  $d=4096$ , 共有 GPT-NeoX トークナイザ, 指示形式テキスト (Alpaca) で整合すると、残差ブロック 1 個のアダプタが未

学習の文章における中心化潜在相関  $\rho_{\text{ctr}}=0.901$  に達する。生の相関 (0.97) は共通モードにより高くなり得るため、それ自体は証拠としない。中心化相関 0.901 と、各復号器が自系統の残差を再構成できること ( $A \rightarrow A$  0.70,  $B \rightarrow B$  0.71) を併せて、共通表現の根拠とする。また、各横断課題へ直接あてはめた最良の線形写像だけでも  $A \rightarrow B$  0.487,  $B \rightarrow A$  0.535 に届く (§V)。したがって、観測された予測可能性の大部分は深い非線形写像の表現力だけでは説明できない。ただし同一層ペアが内在的に特別なわけではない: アダプタを介さない生の残差どうしを全  $32 \times 32$  層で比べると (図 2), 線形 CKA は総じて弱く (対角平均 0.05 対 非対角平均 0.03),  $A$  の層  $j$  が  $B$  の層  $j$  に最も似るのは 32 行中 2 行にすぎない (最類似は層 0 が 14 行, 最終層が 12 行を占める)。直接の線形回帰しやすさでも同一層は特別ではない: 同じ全層ペアへ層別の線形写像をあてはめると、適合  $R^2$  は対角平均 0.87 対 非対角平均 0.84 であり、同番号層が最良となるのは 32 行中 3 行にすぎない。ゆえに  $\rho_{\text{ctr}}=0.901$  は選んだ同一層ペア上で学習して回復した整合であって、層番号どうしに固有の対応ではない——ほぼ任意の層ペアに存在する回帰可能性の上に、同一層という選択を重ねたものとして読むべきである。




Fig. 2. 生残差の全  $32 \times 32$  層対応 (正準表 paper\_layer\_correspondence.csv から生成)。左: 線形 CKA は総じて弱く、高い値は層 0 の行・列と最終層の角に集中する——対角 (破線) は特別でない。右: 同じ各ペアへ層別の線形写像をあてはめた適合  $R^2$  は 0.62–0.94 とほぼ全ペアで高い。二つのパネルの色スケールは異なる。

整合が学習可能であることは確認できるが、その射程は

この意味でも限定的である (§IX)。

以降の数値はすべて、同一構成の単一の学習から得たものである。潜在の幅は  $z=d=4096$  (圧縮なし), 32 ブロックすべてを対応付け、アダプタは 268.5M パラメータ,  $\sigma=0.4$ , 学習率は  $10^{-3}$  から plateau 方式で下限  $10^{-5}$  まで下げた。学習信号は Alpaca 学習分割の 2,075 窓 (各 112 トークン, 独立トークン位置  $\approx 232k$ ) から取った残差で, 32 層で 7.44M ペアを成し, このペア集合を約 228 回反復した。報告値は, 保留  $A \rightarrow B$  が最良となる最深点 (415,000 反復) のチェックポイントのものである (学習走行と収束の記録は付録 A)。Pythia  $\rightarrow$  RWKV の系統横断写像は  $B \rightarrow A$  0.590 で, わずかに  $A \rightarrow B$  0.559 を上回る (RNN 側の残差の方が Transformer 潜在から復元しやすい)。両者とも自系統再構成 ( $A \rightarrow A$  0.695,  $B \rightarrow B$  0.711) を下回っており, 系統横断が整合ではなく復号で律速されることを裏づける。これらの整合・読み出しがトークンごとの真の対応であって分布の重なりではないことは, 負の対照で確かめた:  $A$  の行順を保ったまま  $B$  の残差行を単一の乱数置換で入れ替えて再対応させると,  $\rho_{\text{ctr}}$  は  $0.901 \rightarrow 0.000$ ,  $A \rightarrow B$  は  $0.561 \rightarrow -0.592$ ,  $B \rightarrow A$  は  $0.592 \rightarrow -0.609$  へ崩壊する (自系統写像  $A \rightarrow A$ ,  $B \rightarrow B$  は構成上不变)。すなわち両方向の読み出しとも, 正しいトークン対応なしには得られない。

a) 共通モードは些末な問題ではない。: 潜在のうちトークンごとに変動する成分の割合  $f = \|z - \bar{z}\|^2 / \|z\|^2$  を導入すると, この落とし穴を定量化できる。要素ごとの係数を持たない層正規化のもとで, 生の相関は  $\rho_{\text{raw}} = (1 - f) + f \rho_{\text{ctr}}$ , すなわち  $\text{align} = 2f(1 - \rho_{\text{ctr}})$  と分解される。ここで報告する  $f$  は  $A, B$  それぞれの変動割合の平均であり, この形が等式として成り立つのは両者が等しく, かつ両者の共通モードが平行な場合である。実測では, 学習が進んだ後の評価点でこの関係は  $3 \times 10^{-4}$  程度の精度で成り立つ。ただし学習初期には成り立たず, 0 反復目では残差が  $6.6 \times 10^{-2}$  に達する。等式が語るのは, 生の相関が混合物だということである——そのうち  $1 - f$  の割合は, 情報を持たない定数項として無償で与えられている。最深点の  $f$  は 0.350 であるから, **潜在の持つエネルギーの 65% はトークンに依存しない定数**であり, 生の相関はその定数に支配される。実際, 中心化した  $\rho_{\text{ctr}}$  が 0.901 であるのに対し生の相関は 0.965 を示し, 等式はこれを  $(1 - 0.350) + 0.350 \times 0.901 = 0.965$  と過不足なく再現する。 $f$  の解釈上の限界 ( $f$  が大きくても情報を担うとは限らない) と, 生の相関が改善を捉え損なう学習動態の実例は付録 B に示す。

#### IV. 両横断読み出しは自系統再構成に制約される

測定した五つの診断値を図 3 に示す。

$$\begin{aligned} \rho_{\text{ctr}} &= 0.901, \\ R^2(B \rightarrow B) &= 0.711, \quad R^2(A \rightarrow B) = 0.559, \\ R^2(A \rightarrow A) &= 0.695, \quad R^2(B \rightarrow A) = 0.590. \end{aligned}$$

$\rho_{\text{ctr}}$  は相関係数, 後四者は決定係数であり, 数値の大小を同じ尺度として比較することはできない。本節の結論は,  $R^2$  同士では全 32 層で  $A \rightarrow B \leq B \rightarrow B$  かつ  $B \rightarrow A \leq A \rightarrow A$  であること, および §VII の自己符号器対照で復号のみの損失が下流性能にも現れることに基づく。

高い潜在相関は, 高い再構成精度を自動的に保証しない。RWKV  $\rightarrow$  Pythia は同一の復号器  $D_B$  を通る Pythia 自

己再構成 と, Pythia  $\rightarrow$  RWKV は同一の復号器  $D_A$  を通る RWKV 自己再構成 と比較でき, 入力が自系統潜在か他系統潜在かだけが異なる。両不等式は経験的な観測であって定理ではないが, いずれの方向でも自己再構成の段階すでに相当の誤差があり, 系統横断だけを改善してもその誤差は残る。

a) 圧縮では説明できないが, 上限の要因は未解決である。:  $B \rightarrow B$  が低いのは潜在が情報を圧縮するからにすぎない, という反論があり得る。これは議論ではなく, 圧縮そのものを取り除くことで確かめられる。 $z=d=4096$  では合成写像  $D \circ E$  は恒等写像を表現でき, 階数による制約は存在しない。それでも  $B \rightarrow B$  は 0.711 に留まる。ではノイズ  $\sigma$  が定める天井なのか——単純なスカラー近似では 0.711 を説明できず, 何が律速しているのかは  $\sigma$  を掃引するまで確定できないため, 本稿では**未解決**として残す。なお  $\sigma$  が別の役割——共通モードへの崩壊の抑止——を担うことは  $f$  の軌跡が支持しており, そこは変わらない: 圧縮の除去だけでは問題は解消せず, 幅の広い潜在は学習初期に潜在エネルギーの 98% が定数へ崩壊し, 回復は学習の終盤まで緩慢である ( $f$  の軌跡は付録 B)。これは広い潜在を用いたときにも残る退化であり, 共通モードの補正が些末な問題ではない理由でもある。

#### V. アダプタは両横断経路で非線形である

アダプタは 2 つの線形写像に挟まれたゼロ初期化の残差ブロック 1 個であり, 学習は純粋な線形写像から始まる。だがそれは 0 反復目の性質であって, 415,000 反復後の性質ではない。最深点のアダプタが実際どれだけ線形かを, RWKV  $\rightarrow$  Pythia / Pythia  $\rightarrow$  RWKV と同じ代表 5 層, 同じあてはめ行・保留行で測った。

**アダプタのどれだけ線形か。** アダプタ自身の出力を模倣する最良のアフィン写像が説明する出力分散は, RWKV  $\rightarrow$  Pythia で 86.6%, Pythia  $\rightarrow$  RWKV で 88.0% である。したがって**残る 13.4% / 12.0% はいかなるアフィン写像でも表現できない**。第二の行列がゼロ初期化だという事実は初期化を語るのみで, 学習後の写像は両経路で明確に非線形である。

**線形写像だけでどこまで届くか。** 比較対象はアダプタを近似したものではなく, 層ごとに各経路の標準化した入力残差から標準化した出力残差への最良のアフィン写像を, リッジ付き最小二乗で別々に**直接**あてはめた対照である (設定の詳細は付録 A)。代表 5 層 {4, 10, 16, 22, 28} の保留行で評価すると, 最良直接アフィン写像は RWKV  $\rightarrow$  Pythia 0.487, Pythia  $\rightarrow$  RWKV 0.535 に達する。対応するアダプタは同じ行で RWKV  $\rightarrow$  Pythia 0.558, Pythia  $\rightarrow$  RWKV 0.576 であり, 非線形写像の増分は  $+0.071 / +0.041$  である。低容量のアフィン写像でも両経路で相当な系統横断予測ができるため, **共有表現の主張はこの線形到達性で担保される**。

**別途適合したアフィン対照。** 表 III では, RWKV  $\rightarrow$  Pythia のアダプタを直接アフィン写像へ置き換えると正答率が 8–23 点崩れる。一方 Pythia  $\rightarrow$  RWKV では差が小さく, SciQ @8 ではアフィン対照の方が 3.4 点高い。これは経路差として重要だが, 二つの写像は学習目的・データ・正則化が異なるため, 非線形性の因果効果とはみなさない。

**交絡を抑えた介入: 同一アダプタの MLP 枝を無効化する。** そこで, 同一の学習済みアダプタの残差プロ




Fig. 3. 共有潜在から両方向の読み出しまでの診断値。高い中心化相関と不完全な自己再構成が共存し、RWKV→Pythia / Pythia→RWKV の横断読み出しは、それぞれ同じ復号器を使う Pythia 自己再構成 / RWKV 自己再構成 自己再構成を全層で下回る。相関係数と決定係数は異なる尺度であるため、尺度間の数値差そのものを損失量とは解釈しない。

ック（唯一の学習非線形性  $\text{fc}_2(\text{GELU}(\text{fc}_1(\cdot)))$ ）だけを係数  $\alpha$  でスケールする ( $\alpha=1$  完全,  $\alpha=0$  は枝を外した同一写像)。表現  $R^2$  の  $\alpha = 0, .25, .5, .75, 1$  掃引は、RWKV→Pythia で  $-0.41, -0.75, 0.35, 0.52, 0.56$ , Pythia→RWKV で  $-0.30, -0.66, 0.36, 0.53, 0.58$  となる。両経路で枝を外すと負の  $R^2$  まで崩れ、しかも非単調である。二つの線形層は残差ブロックと協調して学習されており、この学習済みアダプタでは、非線形枝は RWKV→Pythia だけでなく Pythia→RWKV の読み出しにも除去不能である。これは学習済み写像の性質であって、本課題が線形写像で原理的に解けないことを意味しない（同目的で学習した線形アダプタとの比較は行っていない）。多肢選択でも同じ  $\alpha = 0/1$  を同一問題上でペア化して評価する。

TABLE I

同一アダプタの非線形枝を無効化したときの長さ正規化正答率 (%)。各セルは  $\alpha : 1 \rightarrow 0$  (完全な学習済み写像 → 同じ写像から枝のみ除去) を表す。ARC-Easy 2376, SciQ 1000, 当て推量 25%。

| $L$ | ARC-Easy    |             | SciQ        |             |
|-----|-------------|-------------|-------------|-------------|
|     | RWKV→Pythia | Pythia→RWKV | RWKV→Pythia | Pythia→RWKV |
| 4   | 59.6 → 31.9 | 62.2 → 31.8 | 70.9 → 31.3 | 69.2 → 32.6 |
| 8   | 59.0 → 29.9 | 57.3 → 35.5 | 67.7 → 31.4 | 64.6 → 37.0 |
| 16  | 48.6 → 28.5 | 57.5 → 43.7 | 54.5 → 31.7 | 68.0 → 47.3 |
| 24  | 47.0 → 34.8 | 59.6 → 48.4 | 51.1 → 40.0 | 69.9 → 49.1 |

表 I の枝効果は RWKV→Pythia で  $+11.1$ – $+39.6$  点、Pythia→RWKV で  $+11.2$ – $+36.6$  点であり、16 比較すべてで同一問題上の McNemar 正確検定  $p < 2 \times 10^{-9}$  となる。したがって、非線形枝の必要性は一方の経路から推測したものではなく、RWKV→Pythia / Pythia→RWKV の両方の表現と下流精度で直接確認される。

## VI. 構文的に妥当な生成は得られるが事実性は劣化する

ここで実際に 7B で両横断経路を合成する。切替層  $L$  では、前段親をブロック 0 から  $L$  まで走らせ（合計  $L+1$  ブロック）、その残差を §II の境界式で一度だけ他方の空間へ翻訳し、後段親のブロック  $L+1$  以降と言語モデルヘッドを走らせる——ブロックごとの往復ではない。したがって RWKV→Pythia ( $L=16$ ) は RWKV 17 ブロックと Pythia 15 ブロック、Pythia→RWKV ( $L=16$ ) はその反対で、いずれも厳密な半分ではない。

最深点の同一アダプタを RWKV→Pythia / Pythia→RWKV とも  $L=4$  に挿入し、同じ四つの英語プロンプトを温度 0, 最大 40 新規トークンで貪欲復号

した。 $L=4$  は、二課題平均が各横断方向の四境界中で最大であり、SciQ の KV-精度平面でも両方向が非支配集合に入る共通境界である（図 5）。ただしこれは同じ報告タスクを見た後の代表点選択であり、独立な生成用選択基準ではない。本比較は網羅的な生成ベンチマークではないが、少なくとも一方の横断読み出しから他方の生成を推測せず、両方の end-to-end 配線を同条件で観察する。

これらの例から二点が観察できる。第一に、RWKV→Pythia / Pythia→RWKV とも構文的にもっともらしい出力を生成できる。両方がフランスの首都へ正答し、三原色も正しく開始する。RWKV→Pythia はブラックホールにも一文で正答するため、いずれか一方の表現指標だけから動作を推測した結果ではない。第二に、流暢さが保たれても内容や指示形式を失い得る。両方向とも水の補完を “hydrogen” と誤り、Pythia→RWKV は三原色への正答後に対話形式へ逸脱し、ブラックホールを循環的に説明する。したがって 0.559/0.590 の横断読み出しでも事実性は十分でない。より忠実なキメラには両横断読み出しと自系統再構成の改善が必要である。

## VII. 親モデルとの機能・推論メモリ比較

NinaXander の実用上の価値を評価するには、内部表現の指標だけでなく、凍結した両親との機能比較が必要である。ここでは、(i) 強い親モデルに対してどこまで性能を保てるか、(ii) 弱い親または同じ KV 容量の Transformer を上回るか、(iii) その代わりにどの程度のメモリを削減できるかを測る。

この比較は、各選択枝の対数尤度を求めて最大のものを選ぶ多肢選択形式で行う。生成も文字列の照合も主観的な判定も介在しないため、結果は一意に定まる。用いたのは全評価集合 (ARC-Easy test 2376, SciQ test 1000)、最深点 (415,000 反復) の  $z=4096$  のアダプタ、そして四つの切替位置である。同一問題集合上の構成間比較はペア化データなので、差はセルごとの独立な二項 SE ではなくペア化検定 (McNemar の正確検定と対応 bootstrap) で評価する。選択枝は長さが異なり総和 / 長さ正規化で順位が食い違い得るので両方を構造化データに保存し、本文は長さ正規化を報告・検定に用いる。また SciQ は付属の support 文を与えない closed-book 形式 (Question / Answer のみ) で評価するため、本稿の SciQ 値は support を与える標準プロトコルの公表値と直接比較できない。

四経路の同時比較から六つのことが読み取れる。(a) 7B の半分以上が外来であっても、RWKV→Pythia / Pythia→RWKV

$A = \text{RWKV (KV 不要)}$      $B = \text{Pythia (KV 要)}$




Fig. 4. RWKV→Pythia / Pythia→RWKV キメラの対称な構成。図中左側の親をブロック  $L$  まで実行し、残差を一度だけ翻訳して、右側の親のブロック  $L+1$  以降とヘッドへ渡す。青は RWKV-Raven、橙は Tulu-Pythia。したがって Transformer 層数は RWKV→Pythia で  $31-L$ 、Pythia→RWKV で  $L+1$  となる。

TABLE II

最差点アダプタの RWKV→Pythia / Pythia→RWKV による再生成結果（ともに  $L=4$ ）と、両親 pure Pythia / pure RWKV の同一プロンプト出力。英語原文をそのまま入力し、temperature 0 の argmax、最大 40 新規トークン、EOS のみ早期終了とした。各キメラは後段親の隣に置く。長い反復は要約し、逐語出力は paper\_cross\_family\_generation\_samples.csv に収録する。四つのプロンプトに限る定性的比較であり、生成品質の定量評価ではない。

| Prompt (verbatim)                                                                  | pure Pythia                                                                                                           | RWKV→Pythia<br>横断読み出し $R^2=0.559$                                                                                   | pure RWKV                                                                                                               | Pythia→RWKV<br>横断読み出し $R^2=0.590$                                                                                        |
|------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------|
| ### Instruction:<br>What is the capital of France?                                 | “The capital of France is Paris.”                                                                                     | “The capital of France is Paris.” ✓                                                                                 | “Paris.”                                                                                                                | “Paris.” ✓                                                                                                               |
| ### Response:<br>The three primary colors are                                      | “red, yellow, and blue. These colors are often used in combination to create a wide variety of colors.”               | “red, yellow, and blue.” ✓                                                                                          | “red, blue, and yellow.” と正答後、赤の反対色（緑）を問う Q&A へ逸脱                                                                       | “red, blue, and yellow.” と正答後、Bob/Alice の緑についての対話へ逸脱                                                                     |
| Question: Water is made of hydrogen and<br>Answer:                                 | “Hydrogen is made of hydrogen and oxygen.”                                                                            | “Hydrogen.” (誤り)                                                                                                    | “hydrogen.” (誤り)                                                                                                        | “hydrogen.” (誤り)                                                                                                         |
| ### Instruction:<br>Explain what a black hole is in one sentence.<br>### Response: | “A black hole is a region of spacetime where gravity is so strong that nothing, not even light, can escape its pull.” | “A black hole is a region in space where gravity is so strong that nothing, not even light, can escape its pull.” ✓ | “A black hole is a region of space where the gravitational pull is so strong that nothing, not even light, can escape.” | “A black hole is a type of celestial object that is formed when a star collapses and collapses into a black hole.” (循環的) |

TABLE III

RWKV→Pythia / Pythia→RWKV の学習済みアダプタと、各経路の入力・出力残差へ別々に適合した最良アフィン対照による長さ正規化多肢選択正答率（%, ARC-Easy 2376, SciQ 1000, 当て推量 25）。各値は同じ問題、同じ切替層、同じ後段実行を用いる。

| $L$ | ARC-Easy               |                       |                        |                       | SciQ                   |                       |                        |                       |
|-----|------------------------|-----------------------|------------------------|-----------------------|------------------------|-----------------------|------------------------|-----------------------|
|     | RWKV→Pythia<br>adapter | Pythia→RWKV<br>affine | RWKV→Pythia<br>adapter | Pythia→RWKV<br>affine | RWKV→Pythia<br>adapter | Pythia→RWKV<br>affine | RWKV→Pythia<br>adapter | Pythia→RWKV<br>affine |
| 4   | 59.6                   | 41.9                  | 62.2                   | 60.2                  | 70.9                   | 47.5                  | 69.2                   | 69.6                  |
| 8   | 59.0                   | 43.1                  | 57.3                   | 56.0                  | 67.7                   | 49.1                  | 64.6                   | 68.0                  |
| 16  | 48.6                   | 34.8                  | 57.5                   | 57.5                  | 54.5                   | 35.9                  | 68.0                   | 69.6                  |
| 24  | 47.0                   | 39.4                  | 59.6                   | 59.2                  | 51.1                   | 42.7                  | 69.9                   | 68.2                  |

TABLE IV

4 経路の長さ正規化正答率（%）。RWKV 自己再構成 / Pythia 自己再構成 は自系統再構成対照、RWKV→Pythia / Pythia→RWKV は系統横断キメラ。同じ問題・切替層の二つの横断経路差はペア化して検定した。

| $L$ | RWKV 自己再構成 |      | RWKV→Pythia |      | Pythia 自己再構成 |      | Pythia→RWKV |      |
|-----|------------|------|-------------|------|--------------|------|-------------|------|
|     | ARC        | SciQ | ARC         | SciQ | ARC          | SciQ | ARC         | SciQ |
| 4   | 62.8       | 68.5 | 59.6        | 70.9 | 62.2         | 74.8 | 62.2        | 69.2 |
| 8   | 59.8       | 66.7 | 59.0        | 67.7 | 62.7         | 74.8 | 57.3        | 64.6 |
| 16  | 54.8       | 59.8 | 48.6        | 54.5 | 57.4         | 71.1 | 57.5        | 68.0 |
| 24  | 52.2       | 57.9 | 47.0        | 51.1 | 59.4         | 70.1 | 59.6        | 69.9 |

とも実際に問いへ答えられる。全横断構成が当て推量を大きく上回り、SciQ では RWKV→Pythia 70.9%, Pythia→RWKV 69.9% に達する。(b) 深さ効果は経路依存である。RWKV→Pythia は  $L = 4 \rightarrow 24$  で SciQ 70.9  $\rightarrow$  67.7  $\rightarrow$  54.5  $\rightarrow$  51.1, ARC-Easy 59.6  $\rightarrow$  59.0  $\rightarrow$  48.6  $\rightarrow$  47.0 と単調に下がるが、Pythia→RWKV は SciQ 69.2  $\rightarrow$  64.6  $\rightarrow$  68.0  $\rightarrow$  69.9, ARC-Easy 62.2  $\rightarrow$  57.3  $\rightarrow$  57.5  $\rightarrow$  59.6 と非単調である。局所読み出しは同じ四層で RWKV→Pythia 0.570/0.555/0.575/0.567, Pythia→RWKV 0.552/0.517/0.604/0.608 であり、層番号や一つの局所  $R^2$  だけから end-to-end の順位は決まらない。(c) 強いほうの親はどちらの経路でも超えられない。全 8 横断構成が両タスクで Tulu-Pythia を下回り、各同一問題の McNemar 検定でも有意である。(d) RWKV に対する差も経路・課題依存である。RWKV→Pythia ( $L=4$ ) は SciQ で RWKV を +3.9 点 ( $p=0.018$ ) 上回る一方、ARC-Easy では -2.2 点 ( $p=0.042$ ) である。ただし総和スコアではこの優位は消える (RWKV→Pythia ( $L=4$ ) は SciQ -2.7 点, Pythia→RWKV ( $L=4$ ) は ARC -4.6 点 / SciQ -5.7 点) —弱い親に対する優劣の判定は長さ正規化の選

択に依存する。Pythia→RWKV はいずれの境界も RWKV を有意に上回らず、Pythia→RWKV ( $L=4$ ) は ARC +0.4 点 ( $p=0.66$ ), SciQ +2.2 点 ( $p=0.14$ ) で統計的に同等である。(e) 別途適合したアフィン対照の差も経路依存である。RWKV→Pythia ではアダプタが全セルで 8-23 点高いが、Pythia→RWKV では差が小さく、SciQ @8 ではアフィンが 3.4 点高い。この比較は写像自体が異なるため記述的であり、同一アダプタの非線形枝を操作する因果的な比較は  $\$V$  の  $\alpha$  介入で両経路について行う。(f) 自系統対照との差は翻訳誤差だけではない。B 後段では純 Pythia, Pythia 自己再構成, RWKV→Pythia の順に下がり、Pythia 自己再構成→RWKV→Pythia 差は SciQ 4-19 点, ARC 3-12 点である。一方 A 後段では Pythia→RWKV が RWKV 自己再構成を深い境界で逆に上回り、 $L = 16/24$  の差は ARC +2.7/+7.4 点, SciQ +8.2/+12.0 点となる。したがって自系統対照は復号段を切り分けるが、横断との差には前段親の能力と翻訳のずれがともに入り、普遍的な「翻訳コスト」にはならない。

a) RWKV→Pythia と Pythia→RWKV では深さ依存が異なる。表 IV のとおり、Pythia→RWKV は  $L=16, 24$  で同じ層の RWKV→Pythia を ARC で +8.9/+12.6 点, SciQ で +13.5/+18.8 点上回る (同一問題の McNemar 検定, すべて  $p < 3 \times 10^{-15}$ )。一方、 $L=4$  は ARC で +2.6 点 ( $p=0.015$ ) だが SciQ で -1.7 点 ( $p=0.28$ ) であり、浅い境界では経路差は様でない。したがって、RWKV→Pythia で見えた単調な深さ効果を「同じ番号の層をつなぐ難しさ」と一般化できない。どの Pythia→RWKV 構成も Pythia を有意に下回る。また RWKV に対して有意に優る Pythia→RWKV 構成はなく、Pythia→RWKV ( $L=4$ ) は ARC 62.2 対 61.8 ( $p=0.66$ ), SciQ 69.2 対 67.0 ( $p=0.14$ ) で同等である。

Pythia→RWKV の最良アフィン写像は、各切替層でアダプタと別に適合した対照である。ARC @4 ではアダプタが +2.0 点 ( $p=0.005$ ) だが、他の多くは差がなく、SciQ @8 では逆にアフィンが +3.4 点 ( $p=0.003$ ) である。この写像間比較とは別に、同一アダプタの非線形枝を  $\alpha = 0$  とする介入を RWKV→Pythia / Pythia→RWKV の同じ四層・同じ問題で実行し、因果的な非線形枝の寄与はそのペア化結果から評価する。A→A 自己符号器との比較も、RWKV 前段を Pythia 前段と横断翻訳へ同時に置き換えるため、翻訳誤差だけを分離しない。

b) 配布既定値は「最良実測」であって外部検証ではない。両タスクの正答率を単純平均すると、Pythia→RWKV ( $L=4$ ) は 65.70%, RWKV→Pythia ( $L=4$ ) は 65.25% で差はわずか 0.45 点である。完全版は経路を明示して分割し、ninaxander-tulu69-to-raven7b-best は Pythia→RWKV ( $L=4$ ), ninaxander-raven7b-to-tulu69-best は RWKV→Pythia ( $L=4$ ) を各経路内の既定値とする。runtime はパッケージ名と反対の経路への切替を拒否する一方、境界比較用の  $L=8, 16, 24$  plan は保持する。いずれも同じ二つの報告テスト集合上で各経路の四境界から選んだ事後の順位であり、独立な deployment-selection 分割を持たない。したがって、未知の実行経路一般への改善や汎化性能の優越を主張する根拠には用いない。

c) 合成によるメモリ上の効果：Transformer 層とともに KV キャッシュが消える。性能と推論メモリは同時に評価する必要がある。二つの系統は推論時の費用が同じ

ではないからである。Transformer の層はトークンごとに key/value をキャッシュするが、RNN 層が持つのは系列長に対して  $O(1)$  の再帰状態である。RWKV→Pythia は Transformer を  $31-L$  層、Pythia→RWKV は  $L+1$  層だけ保持する。Tulu-Pythia のキャッシュは仮定でなく実測した：層あたり 16.0 KiB/token, 32 層で 512 KiB/token ( $2Ld \cdot 2$  bytes と厳密に一致)。

RWKV→Pythia / Pythia→RWKV を含めると、Pythia→RWKV ( $L=4$ ) は RWKV→Pythia ( $L=4$ ) より Transformer 層を  $27 \rightarrow 5$  へ減らしながら、二タスク平均を 65.25% → 65.70% とほぼ保つ。置き換える RWKV の再帰状態は層あたり 40 KiB (5 状態ベクトル  $\times$  4096 次元  $\times$  fp16 からの算出値) で、構成上文脈長に依存しない。ただし純 RWKV は KV がゼロであり、順位はタスクに依存するため、図 5 は SciQ に限ったメモリ-精度フロンティアとして示す。




Fig. 5. RWKV→Pythia / Pythia→RWKV の SciQ 正答率と実測 KV 削減率。両経路を含む非支配点は pure Pythia → RWKV→Pythia ( $L=4$ ) → Pythia→RWKV ( $L=24$ ) → Pythia→RWKV ( $L=4$ ) → pure RWKV (緑) となる。これは SciQ 一課題上の事後のフロンティアであり、経路一般の優越や未知課題への汎化を意味しない。

Pythia 前段の経路を加えると、高削減点 Pythia→RWKV ( $L=4$ ) が得られる。この点は RWKV 前段の経路だけでは現れない。一方、pure RWKV は依然 KV ゼロであり、Pythia→RWKV ( $L=4$ ) が RWKV を有意に上回るわけでもない。したがって利点は、凍結親の間に追加の交換点を作れることであって、新しい構成が親を一律に支配することではない。

d) 等 KV の Transformer 基準と、未使用ブロックを除いた推論実装。Transformer 親側の効率化との比較を実測した。RWKV→Pythia では同じ  $31-L$  Transformer ブロックを持つ Pythia early exit と比べ、@16/@24 のカメラが ARC +11.2/+18.5, SciQ +12.8/+18.7 点上回る一方、@4 は同点である。Pythia→RWKV では、同じ  $L+1 = 5/9/17/25$  ブロックの early exit に対し、カメラは ARC +35.4/+27.6/+16.9/+2.1, SciQ +38.7/+31.6/+17.9/+0.5 点である。最初の三境界は有意、25 ブロックでは同点 (ARC

TABLE V  
RWKV→Pythia / Pythia→RWKV 両経路の正答率と推論メモリ。KV は実測値；RWKV 再帰状態は文脈長に対して定数である。

| 構成                     | Transformer 層 | KV / token | KV @ 4k 文脈 | 削減    | ARC / SciQ  |
|------------------------|---------------|------------|------------|-------|-------------|
| pure Tulu-Pythia       | 32            | 512 KiB    | 2.00 GiB   | —     | 65.3 / 81.0 |
| RWKV→Pythia ( $L=4$ )  | 27            | 432 KiB    | 1.69 GiB   | 15.6% | 59.6 / 70.9 |
| RWKV→Pythia ( $L=8$ )  | 23            | 368 KiB    | 1.44 GiB   | 28.1% | 59.0 / 67.7 |
| RWKV→Pythia ( $L=16$ ) | 15            | 240 KiB    | 0.94 GiB   | 53.1% | 48.6 / 54.5 |
| RWKV→Pythia ( $L=24$ ) | 7             | 112 KiB    | 0.44 GiB   | 78.1% | 47.0 / 51.1 |
| Pythia→RWKV ( $L=24$ ) | 25            | 400 KiB    | 1.56 GiB   | 21.9% | 59.6 / 69.9 |
| Pythia→RWKV ( $L=16$ ) | 17            | 272 KiB    | 1.06 GiB   | 46.9% | 57.5 / 68.0 |
| Pythia→RWKV ( $L=8$ )  | 9             | 144 KiB    | 0.56 GiB   | 71.9% | 57.3 / 64.6 |
| Pythia→RWKV ( $L=4$ )  | 5             | 80 KiB     | 0.31 GiB   | 84.4% | 62.2 / 69.2 |
| pure RWKV-Raven        | 0             | 0          | 0          | 100%  | 61.8 / 67.0 |

$p=0.069$ , SciQ  $p=0.80$ ) であり, Pythia 前段がごく浅いとき RWKV 後段が実際の機能を補う。

未使用ブロックを物理的に除く経路も RWKV→Pythia / Pythia→RWKV に実装した。Pythia→RWKV では Pythia 前段, RWKV 後段, 両者をつないだ完全経路をそれぞれ未剪定参照と比較し, 全 4 境界で  $\text{rel}=0$  である。常駐重みは RWKV→Pythia 13.93–14.55 GiB, Pythia→RWKV 13.49–14.11 GiB (既定の Pythia→RWKV ( $L=4$ ) は 14.11 GiB) で, 完全な両親 27 GiB のほぼ半分となる。ただし対応する Pythia early exit は Pythia→RWKV で 2.64–10.14 GiB とさらに軽い。さらに参照 runtime は最適化した serving engine ではない: HF RWKV を系列方向に逐次実行し, cacheless decode では prefix を毎回再計算する。Pythia→RWKV ( $L=4$ ) の文脈 2048 prefill は剪定後も 22.6 秒 (pure Pythia 0.378 秒), 未剪定の cacheless decode は 0.148 token/s (Pythia 9.49 token/s) である。これらは現在の正しさ優先実装の値であり, アーキテクチャ固有の速度限界ではない。KV 量子化・sliding-window との比較も行っていない。

親モデルとの比較結果は限定付きである: **機能は保つが, 正答率の一律な向上ではない**。RWKV→Pythia / Pythia→RWKV とともに強い Pythia を有意に下回る。RWKV→Pythia は RWKV を SciQ でのみ上回り, Pythia→RWKV はどの境界も RWKV を有意に上回らない。得られた主な利点は, Pythia→RWKV ( $L=4$ ) で Pythia の正答率の一部を保ちながら Transformer KV を 84.4% 除けることである。

e) 翻訳は領域特異的である。: 以上の正答率は, 指示形式に近い短い設問で測ったものである。KV キャッシュの節約が意味を持つのは長い文脈であり, そこでカメラが開放テキストの言語モデリングをどれだけ保つかは別に測る必要がある。文脈 512 の RWKV→Pythia ( $L=4$ ) は Alpaca で perplexity 6.40, WikiText-103 で 93.87 である。Pythia→RWKV ( $L=4$ ) は 3.85/45.00 と両領域で改善するが, WikiText はなお親の 11.33/16.22 から大きく離れる。文脈を 2048 へ伸ばすと Pythia→RWKV ( $L=4$ ) は Alpaca 3.50, WikiText 34.78 となり, 崩壊せずむしろ改善する。したがって主因は文脈長でなく**領域シフト**である。Pythia→RWKV はシフトを緩和するが, WikiText 34.78 は良い方の親 RWKV 8.27 の 4.2 倍であり, 問題を解消しない。

各切替層の線形対照は, Alpaca と WikiText の各先頭

40,000 token で**別々に再推定**し, それぞれの非重複 suffix で評価した supervised affine oracle である。WikiText の値は Alpaca で推定した写像の領域外汎化ではなく, 学習済みアダプタとも目的・データが異なる。ゆえにアフィンとの優劣から「非線形部分だけが領域に過適合した」とは結論しない。領域特異性の根拠は, 同じ学習済みアダプタが Alpaca と WikiText で親に対する相対性能を大きく変えることにある。




Fig. 6. 領域シフト (文脈 512, 対数軸)。Pythia→RWKV は RWKV→Pythia ( $L=4$ ) の WikiText perplexity を 93.87 → 45.00 に改善するが, 両親 11.33/16.22 には届かない。同じアダプタが Alpaca では親の近傍にあるため, 長さでなく領域が主要な差である。

## VIII. 関連研究

a) モデル・スティッチング: 凍結した 2 モデルの層を学習可能な接合層でつなぐ手法は, 表現の**等価性**を測るために Lenc と Vedaldi [1] が導入し, Bansal ら [2] が表現比較のプロープとして再訪した。いずれも**同一アーキテクチャ・同一課題**での接合であり, 本研究は異なる**系統** (RNN↔Transformer) を各層で 1 度だけ翻訳する共有潜在で接合する点で異なる。

b) 凍結 LLM の合成: 近年は凍結した LLM どうしを学習可能な接続で合成する研究が続いている。StitchLLM [3] は規模の異なる Transformer のブロックを stitching 層で接いで serving 時に経路を選び, BTS [4] は同一シードから分岐した専門家群を stitch 層でシードへ再結合する。CALM [5] は凍結した 2 つの Transformer の中間表現を cross-attention で融合し, Manticore [6] は Transformer と Mamba のブロックを射影で接いだハイブリッドを end-to-end に**微調整**する。ただし, これらは両側が

Transformer (BTS は同一シード) であるか、合成体を微調整する (Manticore)。我々の知る限り、凍結した純 RNN と凍結 Transformer の残差を**双方向**に翻訳して単一境界で合成し、KV 削減量まで実測した研究はない。

c) 表現類似度.: CKA [7] や (SV/PW)CCA [8], [9] はネットワーク間の表現類似度を測る標準的な道具である。本研究はこれらを補助指標として用いつつ (§III の全層対応)、主眼を**再構成を介した機能的な接合**に置く。

d) モデルマージ・知識統合.: 重み空間でモデルを統合する model soups [10], TIES [11], 進化的マージ [12] は、**同一または互換な重みを前提とする**。出力分布を融合する FuseLLM [13] は重みの互換を要しないが、語彙間のトークン整列と対象モデルの継続学習を必要とする。本研究は重みを一切マージせず**活性化空間**を翻訳して凍結ブロックを組み替える点で相補的である。

e) 対象モデル.: RWKV [14] は softmax 自己注意を持たず推論時に純粋な再帰として動作するアーキテクチャ、Pythia [15] とその Tulu SFT 版は Transformer である。両者が GPT-NeoX トークナイザを共有することが、位置対応した残差ペアを可能にしている。

## IX. 考察

本実験では、凍結した異種系統の対応層間に、共有表現を学習できる ( $\rho_{ctr}=0.90$ )。ただし**主張の射程は限定的である**: 本研究の対応は**同一トークナイザ・同一幅・同一層数・同一入力・Alpaca 近傍領域**という好条件で測ったものであり、シャッフル対照はトークン非依存の分布一致を排除するが、観測された対応が意味・語彙・位置・構文のいずれに由来するかは切り分けていない。実際、領域外 WikiText で翻訳が大きく劣化すること (§VII) は、これが**学習領域に固有の表現変換**である可能性を示す。ゆえに「一般的な共通意味空間」ではなく「好条件下でトークン対応した表現の共通空間」と読むのが正確である。高い潜在相関が高い読み出し精度を保証しない点も重要であり、共有表現の有無と復号可能性は分けて評価する必要がある。この空間上に組んだカメラは機能するものの損失を伴い、生成例では両経路とも流暢さを保ったまま内容または形式を誤る。また、深い境界で Pythia→RWKV が RWKV→Pythia を大幅に上回ることは、局所  $R^2$  や層番号だけで end-to-end 性能を予測できず、どちらの親を前段に置くかが重要であることを示す。競争力のあるカメラには、 $B \rightarrow B$  を律速する要因の特定 ( $\sigma$  掃引を含む)、領域をまたいだ学習、および事前学習側で相補的な親モデルの選定が必要である。

a) 限界.: アダプタの学習は乱数種一つのみである。評価用の文章は指示データを重なりなく分割して得たもので、構造上そこに学習データが混入することはなく、学習時と評価時の差が最後まで残ることもそれを裏づけるが、7B の規模で  $n$ -gram による監査までは行っていない。性能は**全評価集合** (ARC-Easy 2376, SciQ 1000) で測り、構成間の差は同一問題上のペア化検定 (McNemar の正確検定と対応 bootstrap) で評価した。RWKV→Pythia が弱い親を上回るのは SciQ のみ、かつ長さ正規化スコアに限られ (総和スコアでは成立しない)、Pythia→RWKV はどの境界も RWKV を有意に上回らない。2 タスク  $\times$  2 横断経路  $\times$  4 切替と複数対照を評価し、多重比較補正は行っていない。方向固定した二つの配布 runtime はいずれも  $L=4$  を既定値とするが、こ

れは同じ二つのテスト集合上で各経路の四境界から事後選択したものであり、独立な選択・確認分割を持たない。非線形枝の同一アダプタ介入は RWKV→Pythia / Pythia→RWKV と同じ層・問題で行ったが、単一チェックポイント上の介入であり、異なるアダプタ学習条件へ一般化できるとは限らない。また合成は常に境界を一箇所しか持たず、複数境界で翻訳誤差がどう累積するかは測定していない。さらにカメラの評価は尤度に基づいており、これは正しい選択肢を**選ぶ能力**を測るものであって、**生成する能力**を直接測るものではない。RWKV→Pythia / Pythia→RWKV 各四つの生成例は定性的な補足にとどまり、生成能力の包括的評価ではない。加えて、翻訳は**学習領域に特化**しており、WikiText では大きく劣化する。長文脈 CE は文脈 512/1024/2048 で測る (両親がいずれも文脈長  $\leq 2048$  のモデルであるため 2048 を上限とする)。これは言語モデリングの品質であって、遠距離依存を要する読解を直接測るものではない。推論実装については、未使用ブロックを実際に除くことで常駐重みが約半分に減ることを実測した (§VII) が、正しさ優先の未剪定 runtime は cacheless で prefix を再計算し、HF RWKV も逐次実行するため、カメラは純 Pythia より prefill/decode で約 63–70 $\times$  遅い。これは実装特性であってアーキテクチャの性質ではなく、最適化した推論経路での遅延・スループットは今後の課題である。KV 量子化・sliding-window との等メモリ比較も行っていない。 $\sigma \cdot \lambda \cdot$  潜在幅・残差ブロック数・学習データ量に対するアブレーション、および同一系統ペア (同一アーキテクチャ) での整合は本 32 層構成では実施しておらず、今後の課題である。

## References

- [1] K. Lenc and A. Vedaldi, “Understanding image representations by measuring their equivariance and equivalence,” Int. J. Comput. Vision, vol. 127, no. 5, p. 456–476, May 2019. [Online]. Available: <https://doi.org/10.1007/s11263-018-1098-y>
- [2] Y. Bansal, P. Nakkiran, and B. Barak, “Revisiting model stitching to compare neural representations,” in Proceedings of the 35th International Conference on Neural Information Processing Systems, ser. NIPS ’21. Red Hook, NY, USA: Curran Associates Inc., 2021.
- [3] B. Hu, S. Li, S. Agarwal, M. Lee, A. Jajoo, J. Li, L. Xu, G.-W. Kim, D. Kim, H. Xu, A. Zhang, and A. Akella, “StitchLLM: Serving LLMs, one block at a time,” in Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), W. Che, J. Nabende, E. Shutova, and M. T. Pilehvar, Eds. Vienna, Austria: Association for Computational Linguistics, Jul. 2025, pp. 26 887–26 903. [Online]. Available: <https://aclanthology.org/2025.acl-long.1305/>
- [4] Q. Zhang, P. Bhargava, C. Bi, C. X. Cai, J. N. Foerster, J. Fu, P. S. Koura, R. Silva, S. Shen, E. Dinan, S. Gururangan, and M. Lewis, “BTS: Harmonizing specialized experts into a generalist LLM,” in Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing, C. Christodoulopoulos, T. Chakraborty, C. Rose, and V. Peng, Eds. Suzhou, China: Association for Computational Linguistics, Nov. 2025, pp. 6816–6834. [Online]. Available: <https://aclanthology.org/2025.emnlp-main.347/>
- [5] R. Bansal, B. Samanta, S. Dalmia, N. Gupta, S. Ganapathy, A. Bapna, P. Jain, and P. Talukdar, “LLM augmented LLMs: Expanding capabilities through composition,” in The Twelfth International Conference on Learning Representations, 2024. [Online]. Available: <https://openreview.net/forum?id=jjA4O1vJRz>
- [6] N. Roberts, S. Guo, Z. Gao, S. S. S. N. GNVV, S. Crompt, C. Wu, C. Duan, and F. Sala, “Pretrained hybrids with MAD skills,”

- in Second Conference on Language Modeling, 2025. [Online]. Available: <https://openreview.net/forum?id=8xSbwT3763>
- [7] S. Kornblith, M. Norouzi, H. Lee, and G. Hinton, “Similarity of neural network representations revisited,” in Proceedings of the 36th International Conference on Machine Learning, ser. Proceedings of Machine Learning Research, K. Chaudhuri and R. Salakhutdinov, Eds., vol. 97. PMLR, 09–15 Jun 2019, pp. 3519–3529. [Online]. Available: <https://proceedings.mlr.press/v97/kornblith19a.html>
  - [8] M. Raghu, J. Gilmer, J. Yosinski, and J. Sohl-Dickstein, “Svcca: singular vector canonical correlation analysis for deep learning dynamics and interpretability,” in Proceedings of the 31st International Conference on Neural Information Processing Systems, ser. NIPS’17. Red Hook, NY, USA: Curran Associates Inc., 2017, p. 6078 – 6087.
  - [9] A. S. Morcos, M. Raghu, and S. Bengio, “Insights on representational similarity in neural networks with canonical correlation,” in Proceedings of the 32nd International Conference on Neural Information Processing Systems, ser. NIPS’18. Red Hook, NY, USA: Curran Associates Inc., 2018, p. 5732 – 5741.
  - [10] M. Wortsman, G. Ilharco, S. Y. Gadre, R. Roelofs, R. Gontijo-Lopes, A. S. Morcos, H. Namkoong, A. Farhadi, Y. Carmon, S. Kornblith, and L. Schmidt, “Model soups: averaging weights of multiple fine-tuned models improves accuracy without increasing inference time,” in Proceedings of the 39th International Conference on Machine Learning, ser. Proceedings of Machine Learning Research, K. Chaudhuri, S. Jegelka, L. Song, C. Szepesvari, G. Niu, and S. Sabato, Eds., vol. 162. PMLR, 17–23 Jul 2022, pp. 23 965–23 998. [Online]. Available: <https://proceedings.mlr.press/v162/wortsman22a.html>
  - [11] P. Yadav, D. Tam, L. Choshen, C. Raffel, and M. Bansal, “Ties-merging: resolving interference when merging models,” in Proceedings of the 37th International Conference on Neural Information Processing Systems, ser. NIPS ’23. Red Hook, NY, USA: Curran Associates Inc., 2023.
  - [12] T. Akiba, M. Shing, Y. Tang, Q. Sun, and D. Ha, “Evolutionary optimization of model merging recipes,” Nature Machine Intelligence, vol. 7, no. 2, pp. 195–204, Feb. 2025. [Online]. Available: <https://doi.org/10.1038/s42256-024-00975-8>
  - [13] F. Wan, X. Huang, D. Cai, X. Quan, W. Bi, and S. Shi, “Knowledge fusion of large language models,” in The Twelfth International Conference on Learning Representations, 2024. [Online]. Available: <https://openreview.net/forum?id=jiDsk12qcz>
  - [14] B. Peng, E. Alcaide, Q. Anthony, A. Albalak, S. Arcadinho, S. Biderman, H. Cao, X. Cheng, M. Chung, L. Derczynski, X. Du, M. Grella, K. Gv, X. He, H. Hou, P. Kazienko, J. Kocon, J. Kong, B. Koptyra, H. Lau, J. Lin, K. S. I. Mantri, F. Mom, A. Saito, G. Song, X. Tang, J. Wind, S. Wozniak, Z. Zhang, Q. Zhou, J. Zhu, and R.-J. Zhu, “RWKV: Reinventing RNNs for the transformer era,” in Findings of the Association for Computational Linguistics: EMNLP 2023, H. Bouamor, J. Pino, and K. Bali, Eds. Singapore: Association for Computational Linguistics, Dec. 2023, pp. 14 048–14 077. [Online]. Available: <https://aclanthology.org/2023.findings-emnlp.936/>
  - [15] S. Biderman, H. Schoelkopf, Q. Anthony, H. Bradley, K. O’Brien, E. Hallahan, M. A. Khan, S. Purohit, U. S. Prashanth, E. Raff, A. Skowron, L. Sutawika, and O. Van Der Wal, “Pythia: a suite for analyzing large language models across training and scaling,” in Proceedings of the 40th International Conference on Machine Learning, ser. ICML’23. JMLR.org, 2023.

## Appendix A 再現情報

- **モデル**: RWKV-Raven-7B (BlinkDL .pth を HF 形式へ変換し fp16 再保存) と allenai/open-instruct-pythia-6.9b-tulu (fp16)。ともに 32 層,  $d=4096$ , GPT-NeoX-20B トークナイザ。
- **アダプタ**:  $z=d=4096$ , 残差ブロック 1 (内部幅 4096, 第 2 行列ゼロ初期化), 非アフィン LN,  $\sigma=0.4$ ,  $\lambda=1$ ,

268.5M パラメータ。AdamW,  $4 \times V100$  で有効バッチ 4096, 学習率  $10^{-3} \rightarrow 10^{-5}$  (保留集合の  $A \rightarrow B$  が改善しなくなったら  $\times 0.5$ ), 416,000 反復走行 (報告チェックポイントは保留  $A \rightarrow B$  最良の 415,000 反復), 乱数種 0。

- **データ**: 残差は Alpaca 学習分割の先頭側 (窓 112 トークン,  $\approx 232k$  独立トークン位置) から, 評価窓は文字位置 2,000,000 以降から取り ( $N$  に依存しない固定オフセット), 両者は重ならない。標準化統計は各層の学習残差から算出し逆標準化に用いる。
- **評価**: 保留集合の  $R^2$  は各層で全トークン・全次元をプールして算出し (SST は次元ごとに中心化; 指標の厳密な定義は付録 B), 32 層の単純平均を報告する。多岐選択は各選択肢を連結した系列の対数尤度 (プロンプト以降のトークンの和/平均) で決定し, 全評価集合 (ARC-Easy test 2376, SciQ test 1000) を用いる。SciQ は support 文を与えない closed-book 形式で評価する。構成間の差はペア化検定 (McNemar・対応 bootstrap) で評価する。Pythia $\rightarrow$ RWKV の RWKV 後段では選択肢を常に batch 1 で評価する; 対照をバッチ軸で結合すると層ごとに  $\text{rel}=8.3 \times 10^{-4} - 1.8 \times 10^{-3}$  の差が生じたため棄却し, batch 1 のまま独立 CUDA stream で並行化した経路だけを逐次実行との  $\text{rel} < 10^{-4}$  ゲート後に用いる。Pythia $\rightarrow$ RWKV も RWKV $\rightarrow$ Pythia と同じ, 保留  $A \rightarrow B$  で選んだ step 415,000 の配布チェックポイントに固定し,  $B \rightarrow A$  または Pythia $\rightarrow$ RWKV QA を見たチェックポイントの再選択は行わない。ただし方向固定した二つの配布 runtime は, 評価後に各経路の四境界について報告テスト平均が最大だった  $L=4$  を既定値とし, 独立な deployment-selection 分割はない。
- **コード・構造化データ**: 本研究のリポジトリは <https://github.com/kotama7/NinaXander> である (2026 年 7 月 30 日時点では private repository; 公開予定)。実験コード, 各評価の生データと論文報告値の集約表, 再現手順, および本文の数値を表データと自動照合する検査を含む。フック取得の整合性検査・境界ゲート・学習走行と収束記録・ノイズ天井の解析・アフィン対照の適合手順の詳細は, リポジトリの文書 (docs/) に記載する。
- **Hugging Face 配布物**: 2026 年 7 月 30 日時点の推論用成果物を, 次の三つの private model repository へ保存した。アクセスには所有者による許可が必要であり, 未認証の読者からは閲覧できない。三つをまとめた private collection は <https://huggingface.co/collections/kotama7/ninaxander-private-inference-releases-6a6b02ec40c18d6b41ed040a> である。

- 共有アダプタ: <https://huggingface.co/kotama7/ninaxander-raven7b-tulu69-adapter>
- Pythia $\rightarrow$ RWKV (既定  $L=4$ ): <https://huggingface.co/kotama7/ninaxander-tulu69-to-raven7b-best>
- RWKV $\rightarrow$ Pythia (既定  $L=4$ ): <https://huggingface.co/kotama7/ninaxander-raven7b-to-tulu69-best>

各 repository は英語・日本語・簡体字中国語の model card と notice, SafeTensors, SHA-256 manifest を含む。配布 License はいずれも、より制約の強い親 (Tulu-Pythia) に合わせた AI2 AI Model License (非商用研究限定) であり、各 NOTICE に親モデルの帰属を記載する。

## Appendix B 指標の定義と共通モードの詳細分析

本節は指標の厳密な定義と、§III-§IV の共通モード補正の補足を与える。

a) 指標の定義: 残差は層ごとに、学習トークンから推定した次元別の平均・標準偏差で標準化して用いる (カメラ挿入時は逆標準化する)。損失の三項はいずれも全要素 (トークン  $\times$  次元) の平均であり、 $z$  は非アフィン LN により単位分散であるから、 $\lambda=1$  は要素あたりの誤差を同一スケールで加えることに相当する。ノイズ  $\xi_A, \xi_B$  は枝ごとに独立にサンプルする。 $R^2$  は層ごとに保留トークンと全 4096 次元をプールして  $1 - \text{SSE}/\text{SST}$  で計算する。SST は次元ごとにトークン平均を除いた全変動であり、分散の大きい次元ほど寄与が大きい。保留集合は二つある: 見出し値と学習曲線を与える学習時評価は 1,000 窓  $\times 112 = 112,000$  トークン、層別分析とシャッフル対照 (§III) は 400 窓  $\times 112 = 44,800$  トークンで、評価集合が異なるため層別表の 32 層平均 (0.561/0.592) は見出し値 (0.559/0.590) と厳密には一致しない。 $\rho_{\text{ctr}}$  は層内で各次元のトークン平均を除去した後、(トークン  $\times$  次元) を平坦化した単一の Pearson 相関である。 $f = \|z - \bar{z}\|^2 / \|z\|^2$  の  $\bar{z}$  は層内の次元別トークン平均で、 $A, B$  各モデルで計算して平均する。いずれの指標も層ごとに算出し、32 層の単純平均を報告する。§III の全層対応の適合  $R^2$  は、各層ペアの同一 22,400 行で適合・評価する in-sample のリッジ線形プロープである。

b)  $f$  が示すこと、示さないこと:  $f$  は二次モーメントであって情報量ではなく、そこから引ける推論は一方向に限られる。 $f \rightarrow 0$  は潜在が定数に崩壊したことを証明し、したがってトークンごとの情報を一切持たないことを示す—— $f$  を導入した目的はこの退化の検出にある。逆向きは成り立たず、しかもそれは本研究の学習過程そのものに現れている。無作為な初期値から 1 回だけ更新した 0 反復目において  $f=0.926$  であり、これは学習の全区間を通じた最大値であるが、同じ時点の四読み出しはすべて負値 (RWKV 自己再構成 / RWKV  $\rightarrow$  Pythia / Pythia 自己再構成 / Pythia  $\rightarrow$  RWKV の順に  $-0.042 / -0.108 / -0.029 / -0.135$ ) ——すなわちトークン平均を予測するより悪い。 $f$  が大きいことが意味するのは、トークンごとの潜在が角度方向に散らばっていることだけであり、係数を持たない層正規化のもとで  $f$  は倍率に対して厳密に不変である。散らばりは意味のある変動からも無意味な変動からも等しく生じる。したがって「変動する成分が情報を担っている」と言えるのは  $f$  ではなく読み出しの側であって、読み出しは**中心化した  $R^2$**  であるから、トークンに依存しない予測器はちょうど 0 点になる。 $B \rightarrow B = 0.711$  はいかなる定数からも得られない。さらに両者は併せて読む必要がある。学習後半 (85,000  $\rightarrow$  415,000 反復) で  $f$  が  $0.189 \rightarrow 0.350$  と増える一方、 $\rho_{\text{ctr}}$  は  $0.949 \rightarrow 0.901$  へ**下が**っており、増えた散らばりの一部は二つの系統が一致しない変動だからである。

c) 生の相関は改善を捉えない: 学習動態にみる実例: 学習率が下がった後の 58,000  $\rightarrow$  66,000 反復で  $f$  は  $0.138 \rightarrow 0.153$  へ増え、 $\rho_{\text{ctr}}$  ( $0.950 \rightarrow 0.952$ ) と四読み出し (RWKV 自己再構成  $0.562 \rightarrow 0.570$ , RWKV  $\rightarrow$  Pythia  $0.477 \rightarrow 0.486$ , Pythia 自己再構成  $0.545 \rightarrow 0.552$ , Pythia  $\rightarrow$  RWKV  $0.504 \rightarrow 0.514$ ) がそろって改善する。ところが同じ区間で  $\rho_{\text{raw}}$  は  $0.9931$  から  $0.9927$  へ、むしろわずかに**下がる**。モデルが共通モードを読み出し可能なトークン依存情報へ置き換えている間も、生の相関はその改善をまったく捉えない。整合の質を生の相関で測ってはならない理由が、ここに端的に表れている。

d) 広い潜在における  $f$  の軌跡: 潜在の持つエネルギーのほぼすべてが共通モードに収まり得るため、幅の広い潜在は学習の初期に  $f \approx 0.02$  ——潜在の 98% がトークンに依存しない定数——まで崩壊する (1,000 反復で  $f=0.015$ )。そこからの回復は緩慢で、25,000 反復でも  $f$  は  $0.058$ , 85,000 反復で  $0.189$  にとどまり、最深値  $0.350$  に達するのは学習の終盤である。その値に至ってもなお**潜在の持つエネルギーの 65% は共有された定数**であり、トークンごとの情報を担い**得る**のは残る 35% にすぎない。